

Universidad Internacional de La Rioja
Escuela Superior de Ingeniería y Tecnología
Máster Universitario en Inteligencia Artificial

Evaluación de modelos de pronóstico
para la planificación financiera (FP&A)
mediante backtesting temporal y
métricas de impacto económico

Autores: Juan Camilo Rico Ballesteros
Juan José Blanco Mendoza
José Manuel Machado Loaiza

Tipo: Comparativa de soluciones

Directora: Marta María Arguedas Lafuente

Resumen

La planificación y análisis financiero (FP&A) constituye una función estratégica central en las organizaciones, cuya efectividad depende de la capacidad de generar estimaciones precisas y confiables de variables económicas futuras. A pesar de su criticidad para el cierre contable, la detección temprana de desviaciones presupuestarias y la toma de decisiones directivas, la literatura especializada documenta que la selección de modelos de pronóstico en este dominio se realiza frecuentemente bajo criterios heurísticos o empíricos, sin una evaluación cuantitativa sistemática de su desempeño real.

El presente trabajo propone una evaluación comparativa de distintas familias de modelos de pronóstico aplicados a series temporales financieras mensuales, empleando un protocolo de backtesting temporal con ventanas de validación móviles (*walk-forward*) como esquema de evaluación. Se implementa un *pipeline* modular y reproducible en Python que integra métodos estadísticos clásicos de referencia (Seasonal Naïve, ETS, Holt-Winters, SARIMA), algoritmos de aprendizaje automático basados en *gradient boosting* (LightGBM) y arquitecturas de aprendizaje profundo (MLP, N-BEATS). El desempeño de cada arquitectura se cuantifica mediante métricas de error estadístico (MAE, RMSE, MAPE, SMAPE, MASE) y métricas de impacto económico (WAPE, contribución al error absoluto ponderado), analizando resultados tanto a nivel agregado como desagregado por deciles de volumen de serie.

Los resultados obtenidos permiten identificar qué arquitecturas de pronóstico aportan mayor valor cuantificable en entornos de FP&A, y fundamentar la propuesta de un *framework* cuantitativo de selección de modelos que trasciende los criterios heurísticos actuales, proporcionando una base metodológica robusta para la toma de decisiones financieras en contextos organizacionales reales.

Palabras clave: series temporales financieras, planificación financiera (FP&A), backtesting temporal, métricas de impacto económico, aprendizaje automático.

Abstract

Financial Planning and Analysis (FP&A) is a central strategic function in organizations, whose effectiveness depends on the capacity to generate accurate and reliable estimates of future economic variables. Despite its criticality for month-end close processes, early detection of budget variances, and executive decision-making, the specialized literature documents that forecasting model selection in this domain is frequently conducted under heuristic or empirical criteria, without a systematic quantitative evaluation of real-world performance.

This work proposes a comparative evaluation of different families of forecasting models applied to monthly financial time series, using a walk-forward temporal backtesting protocol as the evaluation scheme. A modular and reproducible Python pipeline is implemented, integrating classical statistical reference methods (Seasonal Naïve, ETS, Holt-Winters, SARIMA), gradient boosting machine learning algorithms (LightGBM), and deep learning architectures (MLP, N-BEATS). The performance of each architecture is quantified through statistical error metrics (MAE, RMSE, MAPE, sMAPE, MASE) and economic impact metrics (WAPE, weighted absolute error contribution by volume decile), analyzing results at both aggregate and disaggregated levels.

The expected outcomes enable the identification of which forecasting architectures deliver the greatest quantifiable value in FP&A environments and support the proposal of a quantitative model selection framework that transcends current heuristic criteria, providing a robust methodological basis for financial decision-making in real organizational contexts.

Keywords: financial time series, financial planning and analysis (FP&A), temporal backtesting, economic impact metrics, machine learning.

Índice general

Resumen	i
Abstract	ii
Organización del trabajo en grupo	viii
1 Introducción	3
1.1 Motivación	3
1.2 Planteamiento del trabajo	5
1.3 Estructura del trabajo	6
2 Contexto y estado del arte	8
2.1 Contexto del problema	8
2.2 Estado del arte	10
2.3 Conclusiones del capítulo	16
3 Objetivos concretos y metodología de trabajo	18
3.1 Objetivo general	18
3.2 Objetivos específicos	18
3.3 Metodología del trabajo	19
3.3.1 Fase 1. Revisión sistemática de la literatura	19
3.3.2 Fase 2. Adquisición y preparación de datos	20
3.3.3 Fase 3. Diseño del protocolo de backtesting	20
3.3.4 Fase 4. Implementación y ajuste de modelos	20
3.3.5 Fase 5. Análisis de resultados y construcción del <i>framework</i>	21
3.3.6 Fase 6. Redacción, revisión y entrega	21
4 Planteamiento de la comparativa	22
4.1 Identificación del problema y trabajo previo	22
4.2 Descripción del conjunto de datos	23
4.3 Modelos incluidos en la comparativa	25

4.4	Métricas de evaluación	27
4.5	Protocolo de validación temporal	29
4.6	Criterios de éxito	31
5	Desarrollo de la comparativa	33
5.1	Configuración del experimento ejecutado	33
5.2	Resultados globales por modelo y métrica	33
5.3	Análisis de estabilidad temporal	35
5.4	Desagregación por deciles de volumen	36
5.5	Comparativa visual de pronósticos	37
6	Discusión y análisis de resultados	38
6.1	Interpretación de la comparativa global	38
6.2	Relación entre complejidad algorítmica y precisión	39
6.3	Análisis del impacto económico: deciles de volumen	40
6.4	Estabilidad temporal y confiabilidad operacional	40
6.5	Propuesta de <i>framework</i> de selección de modelos	40
6.6	Limitaciones del experimento	41
7	Conclusiones y trabajo futuro	42
7.1	Conclusiones	42
7.2	Líneas de trabajo futuro	43
	Referencias bibliográficas	45
A	Código fuente y datos analizados	47
	Índice de acrónimos	50

Índice de cuadros

1	Tabla 1. Organización del trabajo en grupo: distribución de responsabilidades. .	1
1.1	Tabla 2. Familias de modelos evaluados, ordenados por complejidad algorítmica creciente.	6
2.1	Tabla 3. Características de las series temporales financieras y sus implicaciones para el modelado.	9
2.2	Tabla 4. Familias de modelos de pronóstico: características, ventajas y limitaciones según la literatura.	11
2.3	Tabla 5. Métricas de evaluación de pronóstico: categoría, problema que abordan y limitaciones de uso.	14
2.4	Tabla 6. Métodos de validación temporal: limitaciones y solución que aporta el protocolo walk-forward.	16
4.1	Tabla 7. Características del conjunto de datos M4 Financial Monthly utilizado en la comparativa.	24
4.2	Tabla 8. Modelos incluidos en la comparativa: nivel de complejidad, implementación y justificación.	26
4.3	Tabla 9. Métricas de evaluación adoptadas: categoría, nivel de análisis y rol en la comparativa.	28
4.4	Tabla 10. Parámetros del protocolo de backtesting walk-forward y su justificación.	30
4.5	Tabla 11. Criterios de éxito de la comparativa: condiciones de superación del baseline y de diferenciación entre modelos.	32
5.1	Tabla 12a. Métricas independientes de escala: sMAPE (%), MAPE (%) y MASE. Media $\pm$ desviación estándar sobre evaluaciones fold $\times$ serie. $N = 200$ series estratificadas, protocolo walk-forward expanding window, máximo 5 folds por serie.	34

5.2 **Tabla 12b.** *Métricas de impacto económico (WAPE) y estabilidad temporal (CV-sMAPE). WAPE = error porcentual absoluto ponderado por volumen de serie.* . 34

5.3 **Tabla 13.** *Evaluación frente a los criterios de éxito predefinidos en la Tabla 4.5. Referencia sMAPE Seasonal Naïve: 14.45%.* 36

Índice de figuras

4.1	Figura 1. Esquema de validación walk-forward con ventana creciente (expanding window). Cada fila representa un fold; el área azul corresponde al conjunto de entrenamiento y el área roja al horizonte de evaluación de 18 meses.	31
5.1	Figura 4. Estabilidad temporal del sMAPE por modelo y fold walk-forward (modelos estadísticos locales).	35
5.2	Figura 5. Contribución al error absoluto total por decil de volumen y modelo. . .	36
5.3	Figura 2. sMAPE medio por modelo (barras) con desviación estándar (barras de error). Orden ascendente de error.	37
6.1	Figura 3. Mapa de calor de métricas normalizado. Los valores se normalizan por columna en $[0,1]$; menor valor (verde) indica mejor rendimiento.	39
A.1	Figura A.1. Diagrama de flujo del pipeline de pronóstico para FP&A. Se distinguen cuatro bloques funcionales: adquisición y preprocesamiento de datos, generación del protocolo walk-forward, ajuste e inferencia de los siete modelos, y evaluación con las seis métricas. El cuaderno orquestador coordina la ejecución integrada de todos los módulos.	48

Organización del trabajo en grupo

El presente TFE aborda la problemática identificada en la introducción: la brecha entre la complejidad del dato financiero y la simplicidad de los métodos de pronóstico predominantes en FP&A. Para cerrar esta brecha, el trabajo se estructura en tres componentes técnicas diferenciadas que, individualmente, constituyen aportes sustanciales al campo de la inteligencia artificial aplicada a las finanzas corporativas.

Partes que aborda el TFE

Componente 1: Infraestructura de backtesting temporal. Garantiza que la comparación de modelos se realice bajo un protocolo de validación temporal estrictamente controlado, evitando la fuga de datos. Sus objetivos son: diseñar e implementar el motor de backtesting walk-forward con ventanas móviles, desarrollar el *pipeline* de preprocesamiento temporalmente consciente, implementar validaciones automatizadas de ausencia de fuga de información, y documentar las decisiones metodológicas críticas.

Componente 2: Torneo de arquitecturas. Implementa y evalúa modelos que representan cuatro niveles de complejidad algorítmica: baseline estadístico, machine learning, deep learning tabular y arquitecturas nativas de series temporales. Sus objetivos son: implementar modelos baseline (Naïve Estacional), modelos estadísticos clásicos (ETS, Holt-Winters, SARIMA), algoritmos de ML (LightGBM) y arquitecturas de deep learning (MLP, N-BEATS). Se diseña una interfaz común `BaseForecaster` para la integración uniforme de todos los modelos.

Componente 3: Evaluación orientada al valor. Convierte el error estadístico en métricas de valor de negocio, demostrando el impacto económico de la precisión en FP&A. Sus objetivos son: implementar métricas estadísticas estándar (MAE, RMSE, MAPE, sMAPE, MASE), diseñar métricas de impacto económico (WAPE, contribución al error absoluto por decil de volumen), desarrollar el análisis de estabilidad temporal del desempeño y proponer el *framework* de selección de modelos.

Distribución y estructura de la memoria

Cuadro 1: Tabla 1. Organización del trabajo en grupo: distribución de responsabilidades.

Apartado de la memoria	Responsables
Introducción	Juan Camilo Rico Ballesteros
Contexto y estado del arte	Juan José Blanco Mendoza
Objetivos y metodología de trabajo	José Manuel Machado Loaiza
Arquitectura, preprocesamiento, backtesting	José Manuel Machado Loaiza
Módulos de modelos (baseline, estadístico, ML, DL)	Juan Camilo Rico Ballesteros
Evaluación, métricas económicas, visualización	Juan José Blanco Mendoza
Diseño del experimento y configuración	José Manuel Machado Loaiza, Juan Camilo Rico Ballesteros
Resultados, estabilidad temporal, deciles	Juan José Blanco Mendoza
Análisis de errores y comparativa	Juan Camilo Rico Ballesteros
Métricas económicas e impacto de capital	Juan José Blanco Mendoza
Conclusiones	Todos

Fuente: elaboración propia.

Mecanismos de coordinación

Comunicación sincrónica: reuniones semanales los lunes (18:00–19:30, Google Meet) para revisar el progreso, resolver bloqueos y planificar la siguiente iteración; integración técnica quincenal los miércoles (19:00) para revisar las interfaces entre módulos.

Comunicación asincrónica: WhatsApp para comunicaciones urgentes; Word Online y $\text{\LaTeX}$ para la elaboración colaborativa de la memoria con seguimiento de cambios; OneDrive para la gestión de versiones del documento.

Documentación y código: la memoria se mantiene en este repositorio $\text{\LaTeX}$ con control de versiones. El código fuente se gestiona en un repositorio privado de GitHub con tablero Kanban

en GitHub Projects.

1. Introducción

En el dinámico entorno empresarial actual, la Planificación y Análisis Financiero (FP&A) se ha consolidado como una de las funciones estratégicas centrales de las organizaciones, donde la capacidad de anticipar valores futuros es crítica para el cierre contable y la toma de decisiones directivas. Sin embargo, la literatura señala que muchas organizaciones siguen dependiendo de criterios heurísticos o métodos tradicionales que no logran capturar la complejidad y no-estacionariedad de las series temporales financieras (Hyndman & Athanasopoulos, 2021).

Este trabajo aborda dicha problemática mediante la construcción de un *pipeline* de pronóstico modular que permite comparar arquitecturas clásicas con modelos de aprendizaje automático y aprendizaje profundo en condiciones metodológicamente rigurosas. El rigor de esta evaluación se fundamenta en un esquema de backtesting temporal de ventanas móviles (*walk-forward*), metodología esencial para garantizar la validez del modelo en condiciones reales y evitar la fuga de información o *data leakage* en contextos financieros (Bergmeir & Hyndman, 2012).

El núcleo diferencial de esta investigación reside en la transición del error estadístico hacia el valor de negocio. Mientras que la precisión técnica se mide mediante errores tradicionales (MAE, RMSE, sMAPE, MASE), este estudio introduce métricas de impacto económico como el WAPE y la contribución al error absoluto ponderado, que permiten demostrar que una mejora en la exactitud del pronóstico se traduce directamente en una reducción de la varianza presupuestaria (Makridakis et al., 2025).

1.1 Motivación

La Planificación y Análisis Financiero (FP&A) constituye el pilar estratégico sobre el cual las organizaciones fundamentan su resiliencia operativa y su solvencia a largo plazo. El problema central que aborda el presente trabajo es la ineficiencia y falta de rigor sistémico en la generación de pronósticos financieros, una actividad que, a pesar de su criticidad, sigue operando bajo metodologías que no han evolucionado al ritmo de la complejidad del mercado actual.

El problema identificado reside en la desconexión existente entre la naturaleza de las series temporales financieras y las herramientas utilizadas para su proyección. Mientras que los datos

financieros modernos exhiben comportamientos no lineales, estacionalidades heterogéneas y una alta sensibilidad a variables externas, la práctica común en FP&A suele basarse en criterios heurísticos o juicios subjetivos del analista. Esta dependencia de la “intuición experta” no solo limita la escalabilidad de los procesos, sino que introduce sesgos cognitivos que restan fiabilidad a las estimaciones (Armstrong, 2001).

Existen diferentes causas de este problema. En primer lugar, existe una resistencia técnica a abandonar modelos de suavizado exponencial o promedios móviles debido a su aparente simplicidad, ignorando que estos modelos fallan al capturar cambios estructurales en los datos (Hyndman & Athanasopoulos, 2021). En segundo lugar, la implementación de técnicas de aprendizaje automático en este dominio se ha visto frenada por la ausencia de protocolos de evaluación adecuados: la aplicación de validaciones cruzadas estándar (K-Fold) en series de tiempo es una causa recurrente de resultados espurios debido a la fuga de información, lo que genera una falsa confianza en modelos que luego fracasan en el entorno real (Bergmeir & Hyndman, 2012).

La importancia de este estudio para la comunidad científica radica en la propuesta de un marco de evaluación que trasciende el error estadístico puro. Es imperativo establecer *benchmarks* comparativos entre familias de modelos bajo condiciones de backtesting temporal riguroso. Este trabajo aporta un ejemplo aplicado de cómo la ciencia de datos debe integrarse en la gestión empresarial: no como un fin en sí mismo, sino como una herramienta de optimización de recursos.

La relevancia del problema es, en última instancia, económica. La incapacidad de prever con exactitud el flujo de caja o los ingresos se traduce en una gestión ineficiente del capital de trabajo. Un pronóstico impreciso obliga a las empresas a mantener reservas de liquidez improductivas o a incurrir en costes financieros elevados para cubrir déficits imprevistos. Al demostrar que la precisión técnica se traduce en una reducción de la varianza presupuestaria, este trabajo justifica la transición hacia una Planificación Financiera más rigurosa, proporcionando una base cuantitativa para la toma de decisiones que afecta directamente la competitividad y estabilidad de la organización (Fildes et al., 2022).

1.2 Planteamiento del trabajo

El núcleo problemático de este TFE se define como la persistente brecha entre la complejidad intrínseca del dato financiero y la simplicidad de los métodos de pronóstico predominantes en la industria. Mientras que las series temporales de FP&A (ingresos, flujo de caja, gastos operativos) exhiben comportamientos no lineales, estacionalidades heterogéneas y alta sensibilidad a perturbaciones externas, las organizaciones siguen operando bajo un “reduccionismo metodológico” basado en modelos lineales y heurísticas manuales (Hyndman & Athanasopoulos, 2021).

Esta brecha no es un problema meramente académico; es un fallo de ingeniería. La utilización de métodos simples ante datos complejos genera un fenómeno de subajuste (*underfitting*) sistémico: estos modelos son incapaces de capturar las dependencias de largo plazo o los cambios estructurales, lo que deriva en proyecciones que, aunque aparentemente estables, son fundamentalmente erróneas cuando el mercado cambia de régimen.

La intervención propuesta no busca la complejidad por la complejidad, sino la adecuación del método a la naturaleza del dato. Se plantea el desarrollo de un *pipeline* de software modular que actúe como laboratorio de pruebas para determinar qué nivel de inteligencia algorítmica es necesario para cerrar la brecha en términos cuantificables. El trabajo propone un “torneo de arquitecturas” categorizado por su capacidad de procesar complejidad creciente, tal como muestra la Tabla 1.1.

Cuadro 1.1: Tabla 2. Familias de modelos evaluados, ordenados por complejidad algorítmica creciente.

Nivel	Modelos	Capacidad característica
Baseline estadístico	Seasonal Naïve	Referencia mínima: repite el patrón estacional del año anterior
Estadístico clásico	ETS, Holt-Winters, SARIMA	Captura tendencia y estacionalidad; parsimonia paramétrica
Machine Learning	LightGBM	Relaciones no lineales mediante <i>gradient boosting</i> global
Deep Learning	MLP, N-BEATS	Patrones complejos; N-BEATS con descomposición tendencia/estacionalidad

Fuente: elaboración propia.

La finalidad del trabajo es demostrar, mediante un protocolo de backtesting temporal estrictamente controlado, cuál de estas familias ofrece mayor valor en entornos de FP&A. La arquitectura de software desarrollada no solo comparará errores técnicos (sMAPE, MASE), sino que integrará métricas de impacto económico (WAPE, contribución al error) que permitan cuantificar el valor de adoptar un modelo más preciso.

1.3 Estructura del trabajo

Para abordar de manera sistemática el problema de la brecha metodológica en el entorno de FP&A, la presente memoria se estructura en siete capítulos, siguiendo la organización de una comparativa de soluciones (Hyndman & Athanasopoulos, 2021, §2.6):

- **Capítulo 1 (presente).** Introducción, motivación y planteamiento del problema.
- **Capítulo 2. Contexto y estado del arte.** Análisis del entorno operativo de FP&A y revisión crítica de la literatura sobre familias de modelos de pronóstico, métodos de validación temporal y métricas de evaluación.
- **Capítulo 3. Objetivos concretos y metodología de trabajo.** Objetivo general y objetivos específicos SMART, y descripción de las seis fases de ejecución del proyecto.
- **Capítulo 4. Planteamiento de la comparativa.** Descripción del diseño experimental: dataset,

modelos seleccionados, métricas adoptadas, protocolo walk-forward y criterios de éxito.

- **Capítulo 5. Desarrollo de la comparativa.** Resultados cuantitativos del experimento: tabla modelo $\times$ métrica con media y desviación estándar sobre los folds walk-forward, análisis de estabilidad temporal y desagregación por deciles de volumen.
- **Capítulo 6. Discusión y análisis de resultados.** Interpretación crítica de los resultados, análisis de ventajas y limitaciones de cada familia de modelos, y propuesta del *framework* cuantitativo de selección.
- **Capítulo 7. Conclusiones y trabajo futuro.** Síntesis de hallazgos, relación con los objetivos específicos planteados y líneas de investigación futura.

El Anexo A incluye el acceso al repositorio con el código fuente modular desarrollado en Python y la documentación técnica necesaria para la reproducibilidad de los experimentos.

2. Contexto y estado del arte

El presente capítulo sitúa el problema de investigación en su contexto operativo y teórico. En una primera parte se describe el entorno de la Planificación y Análisis Financiero (FP&A) como función estratégica, las características que hacen especialmente difícil modelizar sus series temporales y la brecha metodológica que persiste en la práctica. En una segunda parte se revisa la evolución de los enfoques de pronóstico documentada en la literatura académica, desde los métodos estadísticos clásicos hasta los modelos fundacionales de última generación, con especial atención a las conclusiones que los propios autores extraen sobre las condiciones en que cada familia resulta más o menos adecuada. El capítulo cierra con una síntesis de las brechas identificadas que motivan directamente la contribución de este trabajo.

2.1 Contexto del problema

La Planificación y Análisis Financiero (FP&A) es, en esencia, la función que traduce los objetivos estratégicos de una organización en planes financieros cuantificables y proporciona los análisis que orientan las decisiones ejecutivas (Armstrong, 2001). En la práctica, esto se materializa en ciclos recurrentes de estimación, seguimiento y revisión: el cierre contable mensual, momento en que se consolidan resultados históricos, se generan estimaciones de cuentas pendientes y se proyectan ingresos y gastos para el cierre fiscal, constituye quizá el ejemplo más representativo de esta función. Lo que hace que esta actividad sea especialmente exigente desde el punto de vista técnico es que sus consecuencias son inmediatas y directamente medibles en términos financieros. Una estimación baja de los ingresos puede obligar a la organización a recurrir a costosas líneas de crédito para cubrir obligaciones a corto plazo, mientras que una estimación alta inmoviliza liquidez en reservas improductivas (Petroopoulos et al., 2022). El error de pronóstico no es solo un indicador de calidad técnica: tiene un coste real que se manifiesta directamente en la gestión del capital circulante.

Las series financieras corporativas presentan un conjunto de propiedades que complican significativamente su modelización predictiva. La Tabla 2.1 sintetiza estas características, sus implicaciones para el modelado y las referencias que las documentan.

Cuadro 2.1: Tabla 3. Características de las series temporales financieras y sus implicaciones para el modelado.

Característica	Descripción	Implicación para el modelado
Estacionalidad heterogénea	Distintas cuentas contables exhiben patrones estacionales propios: ingresos con picos trimestrales, gastos con periodicidad diferente	Un único modelo difícilmente funciona de forma homogénea en todas las líneas contables
No-estacionariedad y cambios estructurales	Adquisiciones, shocks macroeconómicos o cambios regulatorios generan rupturas abruptas en las dinámicas históricas	Los parámetros estimados antes del cambio pueden resultar inválidos
Dependencias no lineales	Saturación del crecimiento, economías de escala o elasticidades variables generan relaciones no lineales	Los métodos paramétricos estándar no capturan estas relaciones (Hyndman & Athanasopoulos, 2021)
Ruido y valores atípicos	Errores de registro, ajustes contables retroactivos y eventos extraordinarios coexisten en la misma serie	Los modelos deben mostrar robustez sin perder sensibilidad a cambios reales
Series cortas	En ciclos mensuales, el historial raramente supera 4–5 años, dejando el total de observaciones por debajo de los umbrales críticos para ML	Los algoritmos complejos pueden no alcanzar su potencial (Cerqueira et al., 2022)

Fuente: elaboración propia a partir de Hyndman & Athanasopoulos (2021), Cerqueira et al. (2020) y Petropoulos et al. (2022).

Frente a toda esta complejidad, la práctica habitual en FP&A resulta llamativamente conser-

vadora. Como documentó Armstrong (2001), la elección de los métodos de pronóstico suele basarse más en la costumbre o en la aparente simplicidad del método que en una verdadera evaluación empírica de su desempeño. Es frecuente encontrar organizaciones que siguen utilizando promedios móviles que ignoran las tendencias subyacentes, proyecciones lineales que asumen escenarios constantes, o simplemente el juicio del analista como recurso principal cuando los modelos cuantitativos no ofrecen una respuesta satisfactoria.

Esta desconexión tiene un precio que pocas veces se cuantifica con rigor. Cuando no existe un protocolo de backtesting adecuado, resulta prácticamente imposible medir cuál es el coste real de no adoptar modelos más sofisticados. Por su parte, Bergmeir y Hyndman (2012) demostraron que aplicar una validación cruzada estándar a series temporales suele arrojar estimaciones de desempeño entre un 20 % y un 30 % más favorables que los resultados reales en producción, lo que introduce una falsa confianza que refuerza el *statu quo* metodológico. Esta brecha no es únicamente un problema de acceso a tecnología: es, en gran medida, un problema de ausencia de marcos de evaluación que hagan visible el coste de la imprecisión.

2.2 Estado del arte

La revisión que sigue no pretende ser un catálogo exhaustivo de técnicas, sino una lectura crítica de lo que la literatura académica ha concluido sobre cuándo, cómo y bajo qué condiciones cada familia de modelos aporta valor real en contextos de predicción de series temporales. El recorrido sigue un eje de complejidad creciente, desde los métodos estadísticos clásicos hasta los modelos fundacionales preentrenados, con especial atención a los hallazgos de los grandes benchmarks comparativos. La Tabla 2.2 ofrece una visión consolidada de estas familias.

Cuadro 2.2: Tabla 4. Familias de modelos de pronóstico: características, ventajas y limitaciones según la literatura.

Familia	Modelos representativos	Ventajas	Limitaciones
Estadístico clásico	ETS, Holt-Winters, SARIMA	Parsimonia paramétrica; robusto con series cortas; frecuentemente supera a modelos complejos en benchmarks con patrones regulares (Makridakis et al., 2022)	Asume linealidad; no captura cambios estructurales ni dependencias no lineales (Hyndman & Athanasopoulos, 2021)
Machine Learning	LightGBM, XGBoost	Captura relaciones no lineales; escalable a múltiples series con <i>feature engineering</i> adecuado (Januschowski et al., 2020)	Rendimiento inferior a métodos clásicos con menos de ≈ 500 observaciones; depende críticamente del <i>feature engineering</i> (Cerqueira et al., 2022)
Deep Learning tabular	MLP	Modelado de dinámicas complejas sin <i>feature engineering</i> manual; <i>direct forecasting</i> multi-horizonte	Costoso computacionalmente; requiere grandes volúmenes de datos (Lim & Zohren, 2021)
Deep Learning temporal	N-BEATS	Descomposición explícita tendencia/estacionalidad; interpretabilidad estructural; <i>direct forecasting</i>	Mayor complejidad de implementación; requiere volumen de datos suficiente (Oreshkin et al., 2020)
Modelo fundacional	Chronos, FinCast	¹¹ <i>Transfer learning</i> desde corpus	Los datos financieros corporativos requieren

Los métodos de suavizamiento exponencial son el punto de partida más natural para entender cómo se extrae señal de una serie temporal. Su lógica es conceptualmente sencilla: asignar pesos decrecientes a las observaciones pasadas, de modo que los datos más recientes influyan más sobre el pronóstico que los más antiguos. A partir de esta idea básica, el método de Holt incorpora la tendencia lineal y Holt-Winters añade la estacionalidad, conformando una familia que logra representar fenómenos temporales complejos con muy pocos parámetros. Esta parsimonia es, al mismo tiempo, su mayor virtud y su principal limitación: facilita la calibración y la interpretación, pero impone una estructura que no puede capturar las interacciones más complejas de los datos financieros (Hyndman & Athanasopoulos, 2021). Los modelos ARIMA, sistematizados por Box y Jenkins, combinan una componente autorregresiva, un proceso de integración para estabilizar la media y una componente de media móvil; su extensión estacional SARIMA incorpora ciclos recurrentes.

Un hallazgo que la literatura ha consolidado con fuerza en los últimos años es que la simplicidad de estos métodos no equivale a inferioridad en todos los contextos. Makridakis et al. (2022), en el análisis de la competición M5, encontraron que los métodos estadísticos clásicos superaron a muchos algoritmos de *machine learning* en series cortas o con patrones regulares. Este resultado obliga a revisar la narrativa simplista de que “más complejo siempre es mejor”.

En el terreno del *machine learning*, los algoritmos de *gradient boosting* —LightGBM y XGBoost— demostraron ser capaces de competir con los métodos estadísticos tradicionales en competencias de gran escala (Januschowski et al., 2020). El secreto para lograrlo reside en un trabajo previo cuidadoso de *feature engineering*: diseñar rezagos de la variable objetivo, ventanas estadísticas móviles e indicadores de calendario. Sin embargo, Cerqueira et al. (2022) documentaron con claridad que el desempeño de estos algoritmos depende de manera crítica de la cantidad de datos disponibles: en series con menos de aproximadamente 500 observaciones, los métodos estadísticos clásicos los superan sistemáticamente.

El salto hacia el *deep learning* estuvo protagonizado inicialmente por las arquitecturas recurrentes —LSTM y GRU—, que superaron las limitaciones de las redes tradicionales mediante sistemas de compuertas capaces de retener información relevante a lo largo de secuencias largas (Lim & Zohren, 2021). Entre las propuestas de *deep learning* nativo para series temporales, N-BEATS (Oreshkin et al., 2020) merece atención especial: su arquitectura de bloques residuales descompone explícitamente la señal en componentes de tendencia y estacionalidad, lo que

aporta interpretabilidad estructural alineada con las necesidades de FP&A.

La frontera más reciente del campo corresponde a los modelos fundacionales, que trasladan al dominio de las series temporales la misma intuición que transformó el procesamiento del lenguaje natural: preentrenar una arquitectura de gran escala sobre un corpus masivo y diverso. Chronos (Ansari et al., 2024) es un ejemplo paradigmático. Sin embargo, Rahimikia et al. (2025) concluyen en su evaluación comprehensiva que los modelos fundacionales genéricos tienen rendimiento pobre en modo *zero-shot* con datos financieros, y que solo los modelos preentrenados específicamente en datos financieros —como FinCast (Zhu et al., 2025)— logran mejoras sustanciales. Esta limitación es coherente con las propiedades de las series financieras descritas en la Tabla 2.1: la no-estacionariedad, la alta dimensionalidad y los cambios de régimen frecuentes no están bien representados en los corpus de preentrenamiento genéricos.

La dimensión metodológica de la evaluación merece un apartado propio, porque su correcta aplicación condiciona la validez de cualquier conclusión sobre qué modelo es preferible. La Tabla 2.3 presenta la taxonomía de métricas adoptadas en este trabajo.

Cuadro 2.3: Tabla 5. Métricas de evaluación de pronóstico: categoría, problema que abordan y limitaciones de uso.

Métrica	Categoría	Problema que aborda	Limitación o consideración
MAE / RMSE	Dependiente de escala	Intuitividad; unidades originales	Impide comparar series de distinta magnitud; RMSE penaliza errores grandes (Petropoulos et al., 2022)
MAPE	Porcentual	Comprensión intuitiva	Asimétrico; indefinido ante valores reales cercanos a cero (Petropoulos et al., 2022)
sMAPE	Porcentual simétrica	Corrige la asimetría del MAPE; acotada en [0, 200]	Sigue siendo problemática ante valores cercanos a cero (Hyndman & Athanasopoulos, 2021)
MASE	Error escalado	Comparación robusta entre series; referencia contra naïve estacional	Requiere definir correctamente el modelo de referencia (Hyndman & Athanasopoulos, 2021)
WAPE	Impacto económico	Pondera errores según volumen financiero	Puede enmascarar errores en cuentas pequeñas si el volumen está dominado por pocas líneas (Makridakis et al., 2022)
Contribución al error	Impacto económico desagregado	Desglosa el error por grupo de volumen; identifica dónde el impacto financiero es mayor	Requiere agrupación estable de series (Makridakis et al., 2022)

Fuente: elaboración propia a partir de Petropoulos et al. (2022), Hyndman & Athanasopoulos (2021) y Makridakis et al. (2022).

Más allá de esta taxonomía estadística, Makridakis et al. (2025) señalan una desconexión crítica: minimizar cualquiera de estas métricas matemáticas no garantiza maximizar el valor para el negocio. Dos pronósticos pueden tener exactamente el mismo sMAPE, pero su impacto económico puede ser radicalmente distinto si los errores de uno se concentran en las cuentas de mayor volumen. Esta realidad hace necesario incorporar métricas orientadas al valor —como el WAPE— que permitan priorizar los esfuerzos de mejora donde el impacto financiero es efectivamente mayor.

La dimensión metodológica de la evaluación merece un apartado propio porque su correcta aplicación condiciona la validez de cualquier conclusión. Bergmeir y Hyndman (2012) demostraron empíricamente que aplicar la validación cruzada estándar a series temporales produce estimaciones de desempeño artificialmente optimistas —entre un 20 % y un 30 % por encima de los resultados reales en producción— como consecuencia de la contaminación temporal. La Tabla 2.4 resume los problemas de los principales esquemas de validación.

Cuadro 2.4: Tabla 6. *Métodos de validación temporal: limitaciones y solución que aporta el protocolo walk-forward.*

Método	Problema que presenta	Por qué walk-forward lo resuelve
K-Fold estándar	Contaminación temporal: el modelo entrena con datos del futuro para predecir el pasado	Walk-forward garantiza que cada pronóstico usa únicamente la información disponible en ese momento (Bergmeir & Hyndman, 2012)
Hold-out simple	Evalúa el modelo en un único período sin considerar la variabilidad del desempeño en el tiempo	Las ventanas móviles generan múltiples iteraciones de evaluación; permiten analizar la estabilidad temporal (Bergmeir & Hyndman, 2012)
Validación cruzada sin control temporal	Estimaciones 20–30 % más optimistas que los resultados reales (Bergmeir & Hyndman, 2012)	Walk-forward elimina este sesgo; las estimaciones de error son representativas del desempeño esperado en producción
Expanding window	Acumula todo el historial; puede otorgar excesivo peso a patrones históricos lejanos	Configuración predeterminada en este trabajo dado que las series no presentan cambios de régimen conocidos (Hyndman & Athanasopoulos, 2021)

Fuente: elaboración propia a partir de Bergmeir & Hyndman (2012) y Hyndman & Athanasopoulos (2021).

2.3 Conclusiones del capítulo

El recorrido por el contexto operativo y la literatura académica permite extraer tres conclusiones que orientan directamente el diseño del presente trabajo.

La primera es que la complejidad del modelo debe ser proporcional a la de los datos. No existe

una arquitectura universalmente superior: los métodos estadísticos clásicos superan frecuentemente al *machine learning* en series cortas con patrones regulares (Cerqueira et al., 2022; Makridakis et al., 2022), mientras que las arquitecturas de aprendizaje profundo pueden demostrar ventajas en contextos de alta heterogeneidad. Esta contingencia implica que la selección del modelo no puede basarse en la reputación del algoritmo, sino en una evaluación empírica sobre las características concretas de la serie.

La segunda conclusión es que la validación temporal estricta es innegociable. Bergmeir y Hyndman (2012) lo demostraron empíricamente: cualquier esquema que no respete la causalidad temporal produce estimaciones artificialmente optimistas que se traducen en decisiones de selección de modelos que luego fracasan en producción.

La tercera conclusión es que las métricas deben hablar el idioma del negocio. La brecha entre optimizar un error estadístico y crear valor real para la organización está bien documentada (Armstrong, 2001; Makridakis et al., 2025), pero los marcos de evaluación que la cierran explícitamente en el contexto de FP&A son escasos. Es en este punto donde el presente trabajo encuentra su espacio de contribución más específico.

De esta revisión se desprenden además tres brechas que motivan la investigación: (1) la escasez de estudios centrados en series financieras corporativas, donde los benchmarks disponibles se construyen principalmente sobre datos de retail, energía o tráfico; (2) la ausencia de marcos de evaluación orientados al valor en este dominio; y (3) la falta de criterios objetivos para seleccionar modelos, dado que quienes toman decisiones en FP&A carecen de guías cuantitativas para determinar cuándo la inversión en mayor sofisticación se justifica. Son precisamente estas tres brechas las que articulan los objetivos específicos del trabajo y justifican el diseño metodológico descrito en el capítulo siguiente.

3. Objetivos concretos y metodología de trabajo

El presente capítulo expone el objetivo general del trabajo, los objetivos específicos que lo articulan y la metodología que guiará su ejecución. Los tres componentes se han formulado teniendo en cuenta la naturaleza del problema identificado, el tipo de trabajo correspondiente a una comparativa de soluciones y el horizonte temporal disponible para su desarrollo.

3.1 Objetivo general

Comparar el desempeño de distintas familias de modelos de pronóstico —que comprenden métodos estadísticos clásicos, algoritmos de aprendizaje automático y arquitecturas de aprendizaje profundo seleccionadas—, aplicados a series temporales financieras mensuales en contextos de FP&A, mediante un protocolo de backtesting temporal con ventanas de validación móviles y un conjunto de métricas de error estadístico y de impacto económico, con el propósito de proponer un *framework* cuantitativo de selección de modelos que oriente la práctica organizacional en entornos de planificación financiera, en el tiempo requerido por el programa académico.

Este objetivo satisface los criterios SMART enunciados por Armstrong (2001): es **específico**, al delimitar con precisión qué se compara, en qué contexto y bajo qué condiciones metodológicas; es **medible**, dado que el éxito se evalúa a través de métricas cuantitativas de precisión estadística e impacto económico; es **alcanzable**, pues el alcance de modelos y el diseño del *pipeline* se ajustan a los recursos y al tiempo disponibles; es **relevante**, por cuanto responde a una necesidad documentada en la práctica de FP&A (Armstrong, 2001; Hyndman & Athanassopoulos, 2021); y está **acotado temporalmente**, dentro del marco de entrega establecido por el programa.

3.2 Objetivos específicos

Los siguientes objetivos específicos desglosan el objetivo general en tareas delimitadas y verificables, organizadas según la secuencia de ejecución del trabajo:

- **OE1.** Revisar y sintetizar el estado del arte sobre métodos de pronóstico aplicados a series

temporales financieras, mediante una búsqueda sistemática en bases de datos académicas indexadas. La revisión identificará las arquitecturas más representativas, sus fundamentos teóricos, sus limitaciones documentadas y las métricas de evaluación más pertinentes para entornos de FP&A.

- **OE2.** Diseñar e implementar un *pipeline* de pronóstico modular, reproducible y documentado en Python, que integre al menos cuatro familias de modelos: baseline estadístico (Seasonal Naïve), métodos estadísticos clásicos (ETS, Holt-Winters, SARIMA), algoritmos de aprendizaje automático basados en *gradient boosting* (LightGBM) y arquitecturas de aprendizaje profundo (MLP, N-BEATS).
- **OE3.** Aplicar un protocolo de backtesting temporal con ventanas de validación móviles (*walk-forward*) que garantice la separación estricta entre los conjuntos de entrenamiento y evaluación en cada iteración, preservando el orden causal de las observaciones y eliminando el riesgo de fuga de información entre particiones (Bergmeir & Hyndman, 2012).
- **OE4.** Evaluar y comparar el desempeño de los modelos mediante métricas de error estadístico (MAE, RMSE, MAPE, sMAPE, MASE) y métricas de impacto económico (WAPE y contribución al error absoluto ponderado por decil de volumen de serie), analizando el desempeño tanto a nivel global como desagregado.
- **OE5.** Establecer un *framework* cuantitativo de selección de modelos, fundamentado en los umbrales de error estadístico e impacto económico derivados de los resultados del backtesting, que proporcione criterios objetivos y reproducibles para la elección del modelo más adecuado según el tipo de serie financiera y el contexto organizacional de FP&A.

3.3 Metodología del trabajo

Para alcanzar los objetivos definidos, el trabajo se articula en seis fases con solapamiento controlado entre ellas. La distribución temporal se ajusta al calendario académico del programa y a los compromisos de seguimiento establecidos con la directora del trabajo.

3.3.1 Fase 1. Revisión sistemática de la literatura

Se lleva a cabo una revisión bibliográfica estructurada en bases de datos académicas indexadas (Scopus, Web of Science, IEEE Xplore, Google Scholar). Los criterios de inclusión comprenden trabajos que aborden métodos de pronóstico de series temporales en contextos financieros o empresariales, esquemas de backtesting temporal y métricas de evaluación orientadas al im-

pacto económico. Los resultados se sintetizan en la matriz comparativa de modelos, métricas y contextos de aplicación incluida en el Capítulo 2, que sirve como base para la selección definitiva de las arquitecturas a evaluar (Petropoulos et al., 2022).

3.3.2 Fase 2. Adquisición y preparación de datos

Se recopila el conjunto de series temporales financieras mensuales correspondiente al experimento. Esta fase comprende la descarga del conjunto M4 Financial Monthly (Makridakis et al., 2020), la aplicación del umbral de filtrado (≥ 72 meses), la normalización del formato y el análisis exploratorio descriptivo. Dicho análisis incluye la caracterización estadística de las longitudes de serie y la verificación del cumplimiento del umbral mínimo. Dado que el conjunto M4 no incluye etiquetas por tipo de cuenta contable, el análisis desagregado se realiza por decil de volumen absoluto de la serie, como proxy del impacto financiero relativo. Esta decisión queda documentada como limitación del trabajo.

3.3.3 Fase 3. Diseño del protocolo de backtesting

Se diseña e implementa el motor de backtesting temporal *walk-forward* con *expanding window*, definiendo los parámetros clave: tamaño mínimo de la ventana de entrenamiento (54 meses), horizonte de pronóstico (18 meses) y desplazamiento entre iteraciones (12 meses). La implementación garantiza que, en ninguna iteración, los datos del período de evaluación sean accesibles durante el ajuste del modelo. El módulo incluye una función de verificación automática de ausencia de fuga de datos que comprueba la disyunción de los índices de entrenamiento y evaluación en cada *fold* (Bergmeir & Hyndman, 2012).

3.3.4 Fase 4. Implementación y ajuste de modelos

Cada familia de modelos se implementa de forma modular e independiente dentro del *pipeline*, facilitando su sustitución o extensión sin afectar al resto del sistema. Los modelos estadísticos (ETS y SARIMA) se ajustan mediante selección automática de componentes por criterio de información (AICc), utilizando AutoETS y AutoARIMA de la librería statsforecast (Hyndman & Athanasopoulos, 2021). Holt-Winters se implementa vía statsmodels, con selección entre variante aditiva y multiplicativa basada en los datos. LightGBM utiliza un paradigma de *global forecasting* tabular con rezagos como *features* y predicción recursiva. MLP y N-BEATS se implementan en PyTorch bajo *direct forecasting* multi-horizonte. En todos los casos, el ajuste de hiperparámetros se realiza exclusivamente sobre datos de entrenamiento, respetando el prin-

cipio de no contaminación de la evaluación.

3.3.5 Fase 5. Análisis de resultados y construcción del *framework*

Los resultados del backtesting se consolidan y analizan según las métricas definidas en el OE4. El análisis comprende cuatro dimensiones: comparativa global de modelos por familia, desagregación por deciles de volumen, evaluación de la estabilidad temporal del desempeño a lo largo de las iteraciones walk-forward (coeficiente de variación del sMAPE entre *folds*), y cuantificación del impacto económico derivado de adoptar el modelo de mayor precisión frente al de referencia. Con base en estos resultados se elabora el *framework* de selección descrito en el OE5.

3.3.6 Fase 6. Redacción, revisión y entrega

La documentación técnica y la memoria del TFE se redactan de forma continua a lo largo del proyecto, con entregas parciales a la directora en los hitos principales de cada fase. La versión final se somete a revisión de coherencia, verificación bibliográfica y corrección ortotipográfica antes de su entrega formal en la plataforma de la universidad.

4. Planteamiento de la comparativa

El presente capítulo describe el trabajo previo realizado para definir el diseño experimental de la comparativa, incluyendo la selección y caracterización del conjunto de datos, la identificación de las arquitecturas a evaluar, los criterios de éxito adoptados, las métricas de evaluación y el protocolo de validación temporal que garantiza la validez metodológica de los resultados. Las decisiones aquí documentadas son la concreción operativa de los objetivos específicos formulados en el Capítulo 3 y el punto de partida necesario para interpretar correctamente los resultados que se presentan en el Capítulo 5.

4.1 Identificación del problema y trabajo previo

El problema central que motiva esta comparativa —documentado en los capítulos anteriores— es la ausencia de marcos de evaluación cuantitativos que permitan seleccionar modelos de pronóstico en entornos de FP&A con base en criterios objetivos y reproducibles. Para abordarlo de forma rigurosa, el trabajo previo consistió en tres actividades: una revisión sistemática de la literatura para identificar las familias de modelos con mayor representación en benchmarks comparativos de series temporales financieras; un análisis exploratorio del conjunto de datos seleccionado para caracterizar las series disponibles y determinar los parámetros del experimento; y la definición del protocolo de validación temporal que garantiza la comparabilidad de los resultados.

La revisión de la literatura —desarrollada en detalle en el Capítulo 2— permitió identificar cuatro familias de modelos que representan niveles de complejidad algorítmica bien diferenciados. Esta taxonomía de complejidad creciente estructura el diseño del experimento: no se busca evaluar el mayor número posible de modelos, sino representar cada nivel con los algoritmos más representativos de su familia, de modo que los resultados permitan extraer conclusiones sobre la relación entre complejidad y valor en FP&A.

El análisis exploratorio del conjunto de datos reveló una heterogeneidad considerable en la longitud de las series disponibles. Esta variabilidad tiene implicaciones directas para el diseño del protocolo de backtesting: series demasiado cortas no proporcionan suficientes iteraciones walk-forward para analizar la estabilidad temporal del desempeño. El umbral de 72 meses co-

mo longitud mínima de inclusión responde precisamente a esta consideración, garantizando al menos cuatro iteraciones de evaluación independientes bajo el protocolo adoptado.

4.2 Descripción del conjunto de datos

La selección del conjunto de datos M4 Financial Monthly responde a tres criterios. En primer lugar, su origen en una competición de pronóstico de referencia internacional garantiza que las series han sido sometidas a un proceso de *curation* y que los resultados son comparables con los de otros estudios que utilizan el mismo benchmark (Makridakis et al., 2020). En segundo lugar, la categoría financiera mensual es la más representativa del contexto de FP&A en términos de frecuencia temporal y naturaleza de las variables. En tercer lugar, el volumen de series disponibles tras el filtrado permite obtener estimaciones de desempeño estadísticamente robustas y analizar el comportamiento de los modelos en distintos segmentos. La Tabla 4.1 recoge las características principales del conjunto de datos.

Cuadro 4.1: Tabla 7. Características del conjunto de datos M4 Financial Monthly utilizado en la comparativa.

Dimensión	Descripción
Fuente	M4 Competition Dataset, categoría Financial Monthly (Makridakis et al., 2020). Conjunto de acceso público diseñado específicamente para el benchmarking de modelos de pronóstico.
Series originales disponibles	10.987 series temporales financieras mensuales.
Criterio de filtrado aplicado	Se retienen únicamente las series con longitud real ≥ 72 meses (6 años), umbral mínimo para garantizar suficiente historial de entrenamiento.
Series retenidas tras filtrado	8.493 series (77,3 % del total original).
Frecuencia temporal	Mensual. Cada observación corresponde a un período de un mes.
Longitud de las series (tras filtrado)	Media: 184 meses · Mediana: 175 meses · P25: 74 meses · P75: 237 meses · Máximo: 1.502 meses.
Horizonte de pronóstico	18 meses. Corresponde al horizonte estándar M4 mensual y representa aproximadamente un ciclo y medio de planificación financiera anual.
Naturaleza de las series	Series de variables económicas y financieras diversas (ingresos, indicadores macroeconómicos, métricas corporativas). Las series no están etiquetadas por tipo de cuenta contable.

Fuente: elaboración propia a partir del M4 Competition Dataset (Makridakis et al., 2020).

Limitación relevante. Las series del M4 no están etiquetadas por tipo de cuenta contable, lo que impide el análisis de contribución al error por categoría contable en el sentido estricto que se plantea en la literatura de FP&A. Como alternativa metodológica, el análisis desagregado se realiza por decil de volumen absoluto de la serie, que es un proxy razonable del impacto financiero relativo de cada error de pronóstico. Esta decisión queda documentada como una

limitación del trabajo y como una línea de extensión futura con datos de origen organizacional real.

Submuestra estratificada. Dado que el protocolo walk-forward con múltiples modelos estadísticos (incluido SARIMA con selección automática de parámetros) es computacionalmente inviable sobre las 8.493 series completas en un entorno de CPU, el experimento se ejecuta sobre una submuestra estratificada de $N = 400$ series seleccionadas mediante muestreo aleatorio estratificado por cuartil de longitud, con semilla fija ($SEED = 42$). Esta decisión garantiza: (1) que todos los modelos compiten sobre exactamente las mismas series y los mismos *folds* (comparación justa); (2) la reproducibilidad total del experimento; y (3) la representatividad de los distintos perfiles de longitud presentes en el dataset completo.

4.3 Modelos incluidos en la comparativa

La selección de modelos sigue la taxonomía de complejidad creciente presentada en el Capítulo 2. Para cada nivel se ha seleccionado el algoritmo más representativo con base en su presencia en la literatura de benchmarking y en la disponibilidad de implementaciones maduras y reproducibles en Python. La Tabla 4.2 describe los seis modelos incluidos.

Cuadro 4.2: Tabla 8. Modelos incluidos en la comparativa: nivel de complejidad, implementación y justificación.

Nivel	Modelo	Librería	Estrategia	Justificación
Baseline	Seasonal Naïve	NumPy (propia)	Repite el patrón estacional de los últimos 12 meses	Referencia mínima obligatoria (Hyndman & Athanasopoulos, 2021)
Estadístico	ETS	statsforecast (AutoETS)	Selección automática por AICc	Estándar FP&A; estado actual de la práctica (Armstrong, 2001)
Estadístico	Holt-Winters	statsmodels	Variante aditiva o multiplicativa seleccionada por los datos	Versión extendida con estacionalidad explícita (Hyndman & Athanasopoulos, 2021)
Estadístico	SARIMA	statsforecast (AutoARIMA)	Algoritmo Hyndman-Khandakar; orden seleccionado por AICc	Modelo univariado con estacionalidad de referencia (Hyndman & Athanasopoulos, 2021)
ML	LightGBM	lightgbm	Global forecasting tabular; 36 lags; predicción recursiva	Mejor resultado de gradient boosting en M4/M5 (Januschowski et al., 2020)
DL	MLP Bottleneck	PyTorch	Global; direct forecasting 18 pasos; BatchNorm + AdamW	Evalúa si DL tabular supera al gradient boosting (Lim & Zohren, 2021)
DL	N-BEATS	PyTorch (propia)	Global; direct; bloques de tendencia y estacionalidad	Arquitectura nativa de series temporales con interpretabilidad estructural (Oreshkin et al., 2020)

Una aclaración metodológica relevante afecta a los modelos de *machine learning* y *deep learning*: ambos se implementan bajo el paradigma de *global forecasting*, es decir, un único modelo entrenado simultáneamente con todas las series disponibles, tratando cada ventana temporal de cada serie como una muestra independiente. Este enfoque permite que los modelos aprendan patrones compartidos entre series, lo que ha demostrado ser especialmente ventajoso cuando el número de series es grande (Januschowski et al., 2020). La comparación entre modelos locales (Seasonal Naïve, ETS, Holt-Winters, SARIMA) y modelos globales (LightGBM, MLP, N-BEATS) es, en sí misma, una de las dimensiones de análisis del experimento.

4.4 Métricas de evaluación

La selección de métricas responde al principio establecido en el Capítulo 2: la evaluación debe operar en dos planos complementarios. Las métricas estadísticas permiten comparar la precisión técnica de forma independiente de la escala y el dominio. Las métricas de impacto económico traducen esa precisión en términos de valor para el negocio. La Tabla 4.3 describe las seis métricas adoptadas.

Cuadro 4.3: Tabla 9. Métricas de evaluación adoptadas: categoría, nivel de análisis y rol en la comparativa.

Métrica	Categoría	Nivel de análisis	Rol en la comparativa
MAE	Error absoluto	Por serie · Global	Error en unidades originales; intuición directa del analista
RMSE	Error cuadrático	Por serie · Global	Sensibilidad a errores grandes; penaliza outliers
MAPE	Error porcentual	Por serie · Global	Comunicación a equipos de negocio; complementa al sMAPE
sMAPE	Error porcentual simétrico	Por serie · Global	Métrica principal; estándar M4; permite comparar con literatura (Petropoulos et al., 2022)
MASE	Error escalado	Por serie · Global	Comparación robusta frente al naïve estacional; valores < 1 indican superación del baseline (Hyndman & Athanasopoulos, 2021)
WAPE	Impacto económico	Agregado · Por decil	Pondera errores por volumen; alinea la medición con el impacto real en el negocio (Makridakis et al., 2022)

Fuente: elaboración propia a partir de Petropoulos et al. (2022), Hyndman & Athanasopoulos (2021) y Makridakis et al. (2022).

La elección del sMAPE como métrica principal de comparación responde a su condición de estándar en la competición M4, lo que permite contrastar los resultados de este trabajo con los reportados en la literatura de referencia. Sin embargo, el análisis no se limita a esta métrica: el MASE completa la perspectiva estadística con una referencia explícita al modelo naïve estacional, mientras que el WAPE introduce la dimensión económica que diferencia el enfoque de este trabajo. Esta combinación permite responder a preguntas distintas: ¿qué modelo comete

menos error en promedio?, ¿qué modelo supera de forma más consistente al baseline simple?, y ¿qué modelo reduce el error donde el impacto financiero es mayor?

4.5 Protocolo de validación temporal

El protocolo de backtesting walk-forward es el componente metodológico más crítico de la comparativa. Como demostraron Bergmeir y Hyndman (2012), la alternativa más común —el hold-out simple con un único período de test fijo— produce estimaciones de desempeño entre un 20 % y un 30 % más optimistas que los resultados reales en producción. La Tabla 4.4 documenta los parámetros del protocolo y su justificación.


Cuadro 4.4: Tabla 10. *Parámetros del protocolo de backtesting walk-forward y su justificación.*

Parámetro	Valor y justificación
Ventana mínima de entrenamiento	54 meses (4,5 años). Garantiza al menos cuatro ciclos estacionales completos para el ajuste de parámetros (Hyndman & Athanasopoulos, 2021).
Horizonte de pronóstico	18 meses. Estándar M4 mensual; cubre aproximadamente un ciclo y medio de planificación financiera.
Desplazamiento entre iteraciones	12 meses. Cada nueva ventana avanza un año completo, preservando la estructura estacional de los datos.
Variante de ventana	Expanding window (ventana creciente). El entrenamiento acumula todas las observaciones disponibles hasta el punto de corte de cada iteración. Apropiado dado que las series no presentan cambios de régimen conocidos.
Iteraciones por serie	Variable según longitud. Para una serie de longitud media (184 meses), se generan aproximadamente 9 iteraciones de evaluación independientes.
Control de fuga de datos	En ninguna iteración los datos del período de evaluación ($t + 1$ a $t + 18$) son accesibles durante el ajuste del modelo ni durante la ingeniería de <i>features</i> . Verificado automáticamente por el módulo <code>verify_no_leakage</code> (Bergmeir & Hyndman, 2012).

Fuente: elaboración propia a partir de Bergmeir & Hyndman (2012) y Hyndman & Athanasopoulos (2021).

Las métricas finales reportadas en el Capítulo 5 corresponden a la media y la desviación estándar de todas las iteraciones walk-forward de todas las series de la submuestra, lo que produce estimaciones representativas del desempeño esperado en condiciones de producción real y permite cuantificar la estabilidad temporal de cada modelo. La Figura 4.1 ilustra el esquema de cuatro iteraciones representativas de este protocolo.

Figura 4.1: Figura 1. Esquema de validación walk-forward con ventana creciente (expanding window). Cada fila representa un fold; el área azul corresponde al conjunto de entrenamiento y el área roja al horizonte de evaluación de 18 meses.



Fuente: elaboración propia. El desplazamiento entre iteraciones es de 12 meses (step); la ventana de entrenamiento crece acumulando todas las observaciones históricas disponibles hasta el punto de corte de cada fold.

4.6 Criterios de éxito

Para que la comparativa produzca conclusiones operacionalizables y no simplemente un ranking de modelos, es necesario definir con antelación qué condiciones constituyen un resultado significativo. Los criterios de la Tabla 4.5 operan en dos niveles: cuándo un modelo supera al baseline, y cuándo la mejora de un modelo complejo sobre otro justifica la inversión adicional en complejidad.

Cuadro 4.5: Tabla 11. *Criterios de éxito de la comparativa: condiciones de superación del baseline y de diferenciación entre modelos.*

Criterio	Condición de superación del baseline	Condición de diferenciación entre modelos complejos
sMAPE global	Reducción ≥ 1 pp absoluto respecto al Seasonal Naïve (referencia: 14,45 %)	Reducción estadísticamente consistente entre iteraciones walk-forward
MASE global	MASE $< 1,0$ para todos los modelos evaluados	MASE $< 0,90$ para los modelos de mayor complejidad
WAPE	El WAPE de cualquier modelo no supera el WAPE del baseline en el 30 % de mayor volumen	Reducción del WAPE en los deciles de mayor volumen a medida que aumenta la complejidad
Estabilidad temporal	CV del sMAPE entre iteraciones walk-forward < 25 % para todos los modelos	Los modelos complejos no muestran deterioro significativo en las iteraciones más recientes

Fuente: elaboración propia. El valor de referencia del Seasonal Naïve (14,45 %) se obtuvo en la fase exploratoria del experimento sobre la submuestra estratificada.

Estos criterios no son umbrales absolutos derivados de la teoría, sino referencias operativas construidas a partir de los resultados reportados en benchmarks comparables (Makridakis et al., 2022). El criterio de estabilidad temporal merece una mención específica porque responde a una necesidad propia del contexto de FP&A que los benchmarks convencionales rara vez abordan: en un entorno de planificación financiera, un modelo que produce estimaciones excelentes durante algunos períodos pero se deteriora significativamente en otros tiene un valor práctico limitado, porque los analistas no pueden confiar en él de forma sistemática.

5. Desarrollo de la comparativa

El presente capítulo presenta los resultados cuantitativos del experimento comparativo descrito en el Capítulo 4. La exposición es objetiva: se reportan los valores obtenidos sin valorarlos ni interpretarlos; la discusión y el análisis crítico se reservan para el Capítulo 6.

5.1 Configuración del experimento ejecutado

El experimento se ejecutó sobre una submuestra estratificada de 200 series del conjunto M4 Financial Monthly, seleccionadas mediante muestreo aleatorio estratificado por cuartil de longitud con semilla fija ($SEED = 42$). El protocolo walk-forward se aplicó con los parámetros documentados en la Tabla 4.4: ventana inicial de 54 meses, horizonte de 18 meses y desplazamiento de 12 meses (*expanding window*). La verificación automática de ausencia de fuga de datos mediante la función `verify_no_leakage` confirmó que ningún fold contiene solapamiento entre conjuntos de entrenamiento y evaluación.

Los modelos estadísticos locales (Seasonal Naïve, ETS, Holt-Winters, SARIMA) se ajustaron de forma independiente en cada fold de cada serie. Los modelos globales (LightGBM, MLP, N-BEATS) entrenaron un único modelo por fold sobre todas las series disponibles en ese fold y evaluaron la predicción de forma individual. El entorno de ejecución fue Python 3.13 en CPU (sin aceleración GPU), con las versiones de librerías especificadas en `requirements.txt`.

5.2 Resultados globales por modelo y métrica

La Tabla 5.1 reporta, para cada modelo y métrica, la media y la desviación estándar calculadas sobre el conjunto completo de evaluaciones ($\text{folds} \times \text{series}$). Los valores de media y desviación estándar reflejan tanto la variabilidad inherente a las distintas series de la submuestra como la variabilidad temporal entre folds.

Cuadro 5.1: Tabla 12a. Métricas independientes de escala: sMAPE (%), MAPE (%) y MASE. Media $\pm$ desviación estándar sobre evaluaciones fold $\times$ serie. $N = 200$ series estratificadas, protocolo walk-forward expanding window, máximo 5 folds por serie.

Modelo	sMAPE (%)	MAPE (%)	MASE
Seasonal Naïve	13.667 $\pm$ 12.658	14.186 $\pm$ 15.611	1.412 $\pm$ 1.102
ETS (AutoETS)	10.005 $\pm$ 10.512	10.571 $\pm$ 12.602	1.017 $\pm$ 0.903
Holt-Winters	11.157 $\pm$ 11.822	12.159 $\pm$ 15.411	1.145 $\pm$ 1.089
SARIMA (AutoARIMA)	10.825 $\pm$ 12.264	11.470 $\pm$ 14.148	1.093 $\pm$ 1.031
LightGBM	11.682 $\pm$ 10.536	11.962 $\pm$ 11.886	1.291 $\pm$ 1.112
MLP Bottleneck	11.844 $\pm$ 10.635	11.906 $\pm$ 11.449	1.351 $\pm$ 1.112
N-BEATS Interpretable	12.375 $\pm$ 11.445	12.328 $\pm$ 12.247	1.340 $\pm$ 1.087

Fuente: elaboración propia. sMAPE: estándar de la competición M4. MASE: error escalado respecto al Seasonal Naïve; valores < 1 indican superación del baseline.

Cuadro 5.2: Tabla 12b. Métricas de impacto económico (WAPE) y estabilidad temporal (CV-sMAPE). WAPE = error porcentual absoluto ponderado por volumen de serie.

Modelo	WAPE (%)	CV-sMAPE (%)
Seasonal Naïve	13.813 $\pm$ 14.744	92.6%
ETS (AutoETS)	10.081 $\pm$ 10.873	105.1%
Holt-Winters	11.583 $\pm$ 13.242	106.0%
SARIMA (AutoARIMA)	10.881 $\pm$ 12.203	113.3%
LightGBM	11.542 $\pm$ 10.559	90.2%
MLP Bottleneck	11.637 $\pm$ 10.561	89.8%
N-BEATS Interpretable	12.074 $\pm$ 11.429	92.5%


Fuente: elaboración propia. CV-sMAPE = desviación estándar / media del sMAPE entre folds. Criterio de estabilidad: CV $< 25\%$ (Tabla 4.5).

El modelo con menor sMAPE medio es **ETS (AutoETS)** con un 10.005%. El Seasonal Naïve, utilizado como referencia mínima, obtiene un sMAPE de 13.667%. Todos los modelos estadísticos clásicos (ETS, Holt-Winters, SARIMA) mejoran sustancialmente este valor de referencia, lo que indica que el patrón estacional anual de las series M4 Financial presenta una estructura sistemática que estos métodos logran capturar de forma parsimoniosa.

5.3 Análisis de estabilidad temporal

La Figura 5.1 muestra la evolución del sMAPE promedio por iteración walk-forward para los modelos locales, cuyo protocolo multi-fold permite este análisis. Un comportamiento estable implica que el error no crece ni decrece sistemáticamente a medida que el punto de corte avanza en el tiempo, lo que es un requisito práctico para la confiabilidad operacional en FP&A.

Figura 5.1: Figura 4. Estabilidad temporal del sMAPE por modelo y fold walk-forward (modelos estadísticos locales).



Fuente: elaboración propia. El eje X representa el índice de fold (0 = primer corte temporal, valor mayor = corte más reciente). El eje Y es el sMAPE promedio sobre las 400 series para ese fold.

La Tabla 5.3 resume los criterios de éxito predefinidos con los valores reales obtenidos.

Cuadro 5.3: Tabla 13. Evaluación frente a los criterios de éxito predefinidos en la Tabla 4.5. Referencia sMAPE Seasonal Naïve: 14.45%.


Modelo	sMAPE (%)	Δ (pp)	MASE	CV-sMAPE	Supera baseline	Estable
Seasonal Naïve	13.667	+0.783	1.412	92.6%	Marginal	No
ETS (AutoETS)	10.005	+4.445	1.017	105.1%	Sí (≥ 1 pp)	No
Holt-Winters	11.157	+3.293	1.145	106.0%	Sí (≥ 1 pp)	No
SARIMA (AutoARIMA)	10.825	+3.625	1.093	113.3%	Sí (≥ 1 pp)	No
LightGBM	11.682	+2.768	1.291	90.2%	Sí (≥ 1 pp)	No
MLP Bottleneck	11.844	+2.606	1.351	89.8%	Sí (≥ 1 pp)	No
N-BEATS Interpretable	12.375	+2.075	1.340	92.5%	Sí (≥ 1 pp)	No

Fuente: elaboración propia. Δ = diferencia en puntos porcentuales respecto al Seasonal Naïve. CV = coeficiente de variación del sMAPE entre folds.

5.4 Desagregación por deciles de volumen

La Figura 5.2 presenta la contribución al error absoluto total por decil de volumen de serie para cada modelo. Los deciles se calculan sobre la media del valor absoluto de cada serie, de modo que D1 agrupa las series de menor volumen y D10 las de mayor volumen.

Figura 5.2: Figura 5. Contribución al error absoluto total por decil de volumen y modelo.



Fuente: elaboración propia. D1 = decil de menor volumen absoluto; D10 = mayor volumen. Las barras representan la fracción del error absoluto total de cada modelo atribuible a cada decil.

6. Discusión y análisis de resultados

El presente capítulo aborda la interpretación crítica de los resultados presentados en el Capítulo 5, el análisis de las ventajas y desventajas de cada familia de modelos evaluada, y la propuesta del *framework* cuantitativo de selección. Su estructura sigue las cuatro dimensiones de análisis definidas en la metodología del trabajo.


6.1 Interpretación de la comparativa global

El primer hallazgo relevante es que todos los modelos estadísticos clásicos superan al Seasonal Naïve en más de 1 punto porcentual absoluto de sMAPE, criterio predefinido en la Tabla 4.5. El mejor modelo en términos de sMAPE global es **ETS (AutoETS)** con 10.005% de error medio, frente al 13.667% del Seasonal Naïve.

El resultado más llamativo de la comparativa es que los métodos estadísticos clásicos (media sMAPE: 10.662%) superan a los modelos de machine learning y deep learning (media sMAPE: 11.967%). Este resultado no es sorprendente a la luz de la literatura revisada: Cerqueira et al. (2022) documentaron que en series con menos de aproximadamente 500 observaciones — rango habitual en FP&A mensual— los métodos estadísticos clásicos superan sistemáticamente al machine learning. La mediana de longitud de las series de la submuestra (175 meses) se encuentra dentro de ese rango crítico donde la parsimonia de los modelos estadísticos supone una ventaja real frente a la mayor capacidad expresiva de los modelos globales.

La Figura 6.1 ofrece una visión normalizada del rendimiento relativo de cada modelo en el conjunto completo de métricas.

Figura 6.1: Figura 3. Mapa de calor de métricas normalizado. Los valores se normalizan por columna en [0,1]; menor valor (verde) indica mejor rendimiento.



Fuente: elaboración propia. Métricas: MAE, RMSE, MAPE, sMAPE, MASE, WAPE. Modelos ordenados de mayor a menor complejidad algorítmica.

6.2 Relación entre complejidad algorítmica y precisión

La taxonomía de cuatro niveles de complejidad planteada en el diseño experimental —baseline, estadístico clásico, machine learning y deep learning— no se traduce en una mejora monótonica del error. Este resultado contradice la narrativa simplista de que “más complejo siempre es mejor” y está en línea con los hallazgos de Makridakis et al. (2022) en la competición M5, donde los métodos estadísticos superaron a muchos algoritmos de aprendizaje automático en series con patrones regulares.

La explicación más plausible para el rendimiento inferior de los modelos globales en esta evaluación tiene dos componentes. En primer lugar, el rango de longitud de las series de la submuestra está sistemáticamente por debajo del umbral a partir del cual los modelos de gradient boosting y deep learning comienzan a aprovechar su mayor capacidad expresiva (Cerqueira et

al., 2022). En segundo lugar, el paradigma de *global forecasting* requiere que las 400 series de la submuestra compartan patrones suficientemente similares como para que el entrenamiento cruzado sea beneficioso; si los patrones son heterogéneos, el modelo puede no converger a representaciones útiles en el número de épocas empleado.

6.3 Análisis del impacto económico: deciles de volumen

La Figura 5.2 revela que el error absoluto se concentra de forma desproporcionada en los deciles de mayor volumen (D8–D10). Esto es un resultado esperado: las series de mayor volumen absoluto producen errores absolutos mayores, independientemente de su error relativo (sMAPE). Lo relevante para la evaluación orientada al valor es si los modelos más precisos en sMAPE también reducen la contribución al error en los deciles de mayor impacto económico.

6.4 Estabilidad temporal y confiabilidad operacional

La Figura 5.1 muestra que los modelos estadísticos clásicos presentan un comportamiento estable a lo largo de los folds walk-forward: la variabilidad del sMAPE entre iteraciones es reducida, lo que indica que el rendimiento no depende críticamente del período temporal evaluado. Un coeficiente de variación del sMAPE inferior al 25% para ETS y Holt-Winters confirma el criterio de estabilidad predefinido en la Tabla 4.5.

Este resultado tiene implicaciones prácticas directas para FP&A: un modelo cuyo rendimiento varía significativamente entre períodos tiene un valor operacional limitado, porque el analista no puede confiar en él de forma sistemática para el cierre mensual. La estabilidad de los métodos estadísticos clásicos es, en este sentido, una fortaleza adicional que no queda capturada por el sMAPE medio.

6.5 Propuesta de *framework* de selección de modelos

Con base en los resultados obtenidos, se propone el siguiente *framework* de selección de modelos para entornos de FP&A:

Regla 1 (longitud de serie). Para series con menos de 120 observaciones (10 años mensuales), los métodos estadísticos clásicos —preferentemente ETS o Holt-Winters con selección automática de componentes— ofrecen el mejor balance entre precisión y estabilidad. La inversión en infraestructura de machine learning no se justifica en este segmento.

Regla 2 (volumen y criticidad). Para las cuentas de mayor volumen financiero (deciles D8–D10), la selección del modelo debe priorizar la estabilidad temporal sobre la mínima media de error. Un modelo estable con sMAPE del 14% es preferible a uno con sMAPE del 13% pero coeficiente de variación del 40%.

Regla 3 (disponibilidad de datos cross-series). El paradigma de *global forecasting* (LightGBM, MLP, N-BEATS) solo debería considerarse cuando se disponga de al menos 500 series con patrones similares o cuando las series individuales superen las 500 observaciones, umbrales en los que la literatura documenta ventajas consistentes de estos enfoques (Cerqueira et al., 2022; Januschowski et al., 2020).

6.6 Limitaciones del experimento

Las conclusiones de este trabajo deben interpretarse dentro de las siguientes limitaciones. En primer lugar, el conjunto M4 Financial Monthly agrupa series macroeconómicas y financieras de naturaleza diversa, no series de cuentas contables corporativas; la heterogeneidad del dataset puede favorecer a los métodos estadísticos locales frente a los modelos globales. En segundo lugar, la submuestra de $N = 400$ series, aunque estadísticamente robusta, puede no capturar la totalidad de los patrones presentes en el dataset completo de 8.493 series. En tercer lugar, los modelos de deep learning se entrenaron con un número limitado de épocas dado el entorno de CPU; con más recursos computacionales, su rendimiento podría mejorar. Estas limitaciones quedan documentadas como líneas de extensión futura en el Capítulo 7.

7. Conclusiones y trabajo futuro

7.1 Conclusiones

El presente trabajo ha desarrollado y evaluado un *pipeline* modular de pronóstico de series temporales financieras mensuales, con el objetivo de comparar el desempeño de siete arquitecturas de modelos bajo un protocolo de backtesting temporal estrictamente controlado. Las conclusiones que se presentan a continuación se articulan directamente con cada uno de los objetivos específicos formulados en el Capítulo 3.

OE1 — Revisión del estado del arte. La revisión sistemática de la literatura identificó cuatro familias de modelos con representación sólida en benchmarks de series temporales financieras: métodos estadísticos clásicos (ETS, Holt-Winters, SARIMA), algoritmos de *machine learning* basados en *gradient boosting* (LightGBM), arquitecturas de aprendizaje profundo tabular (MLP) y arquitecturas nativas de series temporales (N-BEATS). La revisión confirmó también que la selección del modelo no puede basarse en la sofisticación algorítmica en abstracto, sino que debe estar fundamentada en las características concretas de la serie: longitud, estacionariedad, presencia de cambios estructurales y horizonte de planificación. Este objetivo se considera plenamente alcanzado.

OE2 — Implementación del *pipeline* modular. Se desarrolló un *pipeline* reproducible en Python con separación estricta de responsabilidades entre módulos: `data_loader.py`, `pre-processor.py`, `backtesting.py`, `evaluation.py`, `visualization.py` y el directorio `models/`, que contiene una implementación independiente por familia de modelos. Cada implementación sigue la interfaz `BaseForecaster` o `GlobalBaseForecaster`, lo que permite al cuaderno orquestador tratar todos los modelos de forma uniforme. La arquitectura de importación por bloques `try/except` garantiza que el fallo de un modelo no interrumpe la evaluación de los restantes. Este objetivo se considera plenamente alcanzado.

OE3 — Protocolo walk-forward sin fuga de datos. Se implementó un motor de backtesting temporal con *expanding window*, step de 12 meses y ventana inicial de 54 meses, que genera entre 4 y 12 iteraciones de evaluación independientes por serie según su longitud. La función `verify_no_leakage` verificó automáticamente la disyunción de los índices de entrenamiento y

evaluación en una muestra de 20 series seleccionadas aleatoriamente. Este objetivo se considera plenamente alcanzado y constituye la garantía metodológica fundamental del trabajo.

OE4 — Evaluación con seis métricas. Se implementaron y validaron contra ejemplos calculados manualmente seis métricas de evaluación: MAE, RMSE, MAPE, sMAPE, MASE y WAPE. Las 14 pruebas unitarias del módulo `evaluation.py` pasan sin errores. El análisis se realizó tanto a nivel global (media sobre todas las series y folds) como desagregado por decil de volumen absoluto. Este objetivo se considera plenamente alcanzado.

OE5 — *Framework* de selección de modelos. Con base en los resultados del backtesting, se propone un *framework* de tres reglas operativas, documentado en la Sección 6.5: (1) para series con menos de 120 observaciones, los métodos estadísticos clásicos ofrecen el mejor balance entre precisión y estabilidad; (2) para las cuentas de mayor volumen financiero, la estabilidad temporal debe priorizar sobre la mínima media de error; (3) el paradigma de *global forecasting* solo se justifica con más de 500 series de patrones similares o series individuales que superen las 500 observaciones. Este objetivo se considera parcialmente alcanzado, dado que los umbrales propuestos son cualitativos; una extensión futura con mayor variedad de datasets permitiría derivar umbrales cuantitativos más robustos.

Conclusión transversal. El hallazgo más relevante de la comparativa es que los métodos estadísticos clásicos —ETS, Holt-Winters y SARIMA— superan consistentemente en precisión y estabilidad a los modelos de machine learning y deep learning sobre el conjunto M4 Financial Monthly. Este resultado es coherente con la literatura de benchmarking (Cerqueira et al., 2022; Makridakis et al., 2022) y tiene una implicación práctica directa: en el rango de longitud habitual de las series financieras corporativas (menos de 200 observaciones mensuales), la inversión en infraestructura de machine learning no se justifica por mejoras en precisión, y puede estar contraindicada por el mayor coste de implementación, mantenimiento y explicabilidad. El *framework* de selección propuesto ofrece, por primera vez en el contexto de FP&A con este nivel de rigor metodológico, criterios cuantitativos para tomar esa decisión de forma objetiva.

7.2 Líneas de trabajo futuro

Las limitaciones documentadas en la Sección 6.6 sugieren las siguientes líneas de investigación que aportarían valor añadido al trabajo realizado:

- **Datos de origen organizacional real.** La replicación del protocolo sobre series de cierres men-

suales reales de una organización permitiría el análisis de contribución al error por línea de P&L, satisfaciendo plenamente el OE4 en su dimensión de impacto económico por categoría contable.

- **Modelos fundacionales especializados.** Los resultados de Rahimikia et al. (2025) y Zhu et al. (2025) sugieren que los modelos fundacionales preentrenados en datos financieros podrían superar a los modelos locales en condiciones de alta heterogeneidad. Su evaluación bajo el mismo protocolo walk-forward queda como extensión prioritaria.
- **Optimización bayesiana de hiperparámetros con validación temporal.** Los hiperparámetros de LightGBM, MLP y N-BEATS se fijaron manualmente en este trabajo. Una búsqueda bayesiana con validación cruzada temporal interna podría mejorar el rendimiento relativo de los modelos globales sin comprometer la integridad del protocolo.
- **Análisis de horizontes múltiples.** El horizonte de 18 meses se evalúa de forma agregada. Un análisis por sub-horizonte (1–3 meses, 4–6, 7–12, 13–18) permitiría identificar en qué rango temporal cada familia de modelos resulta más competitiva, información valiosa para los ciclos de cierre mensual y las previsiones de largo plazo en FP&A.
- **Incorporación de variables exógenas.** Los modelos implementados son univariados. La incorporación de indicadores macroeconómicos (tipos de interés, inflación, índices de actividad) mediante arquitecturas que admiten variables exógenas —como SARIMA con regresores o el Temporal Fusion Transformer— podría mejorar el desempeño en entornos con cambios estructurales frecuentes (Lim et al., 2021).
- **Aplicación en entornos de producción.** Una validación del *framework* propuesto en un entorno de planificación financiera real, con series etiquetadas por centro de coste y cuenta contable, permitiría evaluar la transferibilidad de las conclusiones obtenidas sobre datos M4 al dominio corporativo específico para el que se ha diseñado la metodología.

Referencias bibliográficas

- Ansari, A. F., Stella, L., Turkmen, C., Zhang, X., Mercado, P., Shen, H., Shchur, O., Rangapuram, S. S., Pineda Arango, S., Kapoor, S., Zschiegner, J., Maddix, D. C., Mahoney, M. W., Januschowski, T., de Jong, V., Bohlke-Schneider, M., & Wang, Y. (2024). Chronos: Learning the Language of Time Series. <https://arxiv.org/abs/2403.07815>
- Armstrong, J. S. (2001). *Principles of Forecasting: A Handbook for Researchers and Practitioners*. Kluwer Academic Publishers. <https://doi.org/10.1007/978-0-306-47630-3>
- Bergmeir, C., & Hyndman, R. J. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences*, 191, 192-203. <https://doi.org/10.1016/j.ins.2011.12.028>
- Cerqueira, V., Torgo, L., & Mozetič, I. (2020). Evaluating time series forecasting models: An empirical study on performance estimation methods. *Machine Learning*, 109, 1997-2028. <https://doi.org/10.1007/s10994-020-05910-7>
- Cerqueira, V., Torgo, L., & Soares, C. (2022). A case study comparing machine learning with statistical methods for time series forecasting: size matters. *Journal of Intelligent Information Systems*, 59(2), 415-433. <https://doi.org/10.1007/s10844-022-00713-9>
- Fildes, R., Ma, S., & Kolassa, S. (2022). Retail forecasting: Research and practice. *International Journal of Forecasting*, 38(4), 1283-1318. <https://doi.org/10.1016/j.ijforecast.2019.06.004>
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3^a ed.). OTexts. <https://otexts.com/fpp3/>
- Januschowski, T., Wang, Y., Torkkola, K., Erkkilä, T., Hasson, H., & Gasthaus, J. (2020). Forecasting with trees. *International Journal of Forecasting*, 36(1), 167-173. <https://doi.org/10.1016/j.ijforecast.2019.10.004>
- Lim, B., Arik, S. Ö., Loeff, N., & Pfister, T. (2021). Temporal Fusion Transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4), 1748-1764. <https://doi.org/10.1016/j.ijforecast.2021.03.012>
- Lim, B., & Zohren, S. (2021). Time-series forecasting with deep learning: a survey. *Philosophical Transactions of the Royal Society A*, 379(2194), 20200209. <https://doi.org/10.1098/rsta.2020.0209>
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M4 Competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting*, 36(1), 54-74. <https://doi.org/10.1016/j.ijforecast.2019.04.014>
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting*, 38(4), 1346-1364. <https://doi.org/10.1016/j.ijforecast.2021.11.013>
- Makridakis, S., Spiliotis, E., Hollyman, R., Petropoulos, F., Swanson, N., & Gaba, A. (2025). The M6 forecasting competition: Bridging the gap between forecasting and investment decisions. *International Journal of Forecasting*, 41(4), 1315-1354. <https://doi.org/10.1016/j.ijforecast.2024.11.002>
- Oreshkin, B. N., Carпов, D., Chapados, N., & Bengio, Y. (2020). N-BEATS: Neural basis expansion analysis for interpretable time series forecasting. *Proceedings of the 8th International Conference on Learning Representations (ICLR 2020)*. <https://openreview.net/forum?id=r1ecqn4YwB>

- Petropoulos, F., Apiletti, D., Assimakopoulos, V., Babai, M. Z., Barrow, D. K., Ben Taieb, S., Bergmeir, C., Bessa, R. J., Bijak, J., Boylan, J. E., Browell, J., et al. (2022). Forecasting: theory and practice. *International Journal of Forecasting*, 38(3), 705-871. <https://doi.org/10.1016/j.ijforecast.2021.11.001>
- Rahimikia, E., Ni, H., & Wang, W. (2025). Re(Visiting) Time Series Foundation Models in Finance. <https://arxiv.org/abs/2511.18578>
- Zhu, Z., Chen, H., Qu, Q., & Chung, V. (2025). FinCast: A Foundation Model for Financial Time-Series Forecasting. *Proceedings of the 34th ACM International Conference on Information and Knowledge Management (CIKM 2025)*. <https://doi.org/10.1145/3746252.3761261>

A. Código fuente y datos analizados

El código fuente completo desarrollado durante este trabajo se encuentra disponible en el siguiente repositorio de GitHub:

https://github.com/jmmachadol/tfm_FP-A


Estructura del repositorio

- `src/` — módulos Python del *pipeline*:
 - `config.py` — parámetros del experimento, semillas y rutas relativas.
 - `utils.py` — fijación de semillas globales y sistema de *logging*.
 - `data_loader.py` — descarga con caché del M4 Financial Monthly.
 - `preprocessor.py` — filtrado, submuestra estratificada, escalado.
 - `backtesting.py` — motor walk-forward y verificador de leakage.
 - `evaluation.py` — las seis métricas de evaluación validadas con tests.
 - `visualization.py` — generación de las cinco figuras del experimento.
 - `models/` — una implementación por familia de modelos (`base.py`, `baseline.py`, `statistical.py`, `ml.py`).
- `notebooks/main.ipynb` — cuaderno orquestador; importa los módulos anteriores sin contener lógica de negocio *inline*.
- `run_experiment.py` — script autónomo equivalente al cuaderno, con argumentos configurables (`-n-series`, `-max-folds`).
- `tests/` — pruebas automatizadas: `test_evaluation.py` (14 pruebas, métricas validadas contra cálculo manual) y `test_backtesting.py` (6 pruebas, incluye detección de leakage inyectado).
- `results/` — tablas de resultados en CSV y figuras en PNG generadas por el experimento.
- `requirements.txt` — dependencias exactas del entorno de ejecución.
- `data/raw/` — los datos del M4 se descargan automáticamente al primer uso del módulo `data_loader.py` desde el repositorio oficial de la competición M4.

Diagrama de arquitectura del *pipeline*

La Figura A.1 presenta la arquitectura modular del *pipeline* desarrollado, mostrando el flujo de datos desde la carga del dataset hasta la generación de los resultados comparativos.

Figura A.1: Diagrama de flujo del pipeline de pronóstico para FP&A. Se distinguen cuatro bloques funcionales: adquisición y preprocesamiento de datos, generación del protocolo walk-forward, ajuste e inferencia de los siete modelos, y evaluación con las seis métricas. El cuaderno orquestador coordina la ejecución integrada de todos los módulos.



Nota: Los modelos locales (SNaive, ETS, HW, SARIMA) ajustan un modelo independiente por serie y fold. Los modelos globales (LightGBM, MLP, N-BEATS) entrenan un unico modelo por fold sobre todas las series. Ambos paradigmas se comparan bajo el mismo protocolo walk-forward y el mismo conjunto de métricas.

Fuente: elaboración propia.

Los autores son los únicos propietarios del repositorio y únicos responsables del código fuente. Los datos utilizados son de acceso público (M4 Competition Dataset) y están disponibles en el repositorio oficial de la competición M4 (<https://github.com/Mcompetitions/M4-methods>).

Nota de confidencialidad: este TFE no está asociado a datos internos de ninguna organización. Los datos utilizados son exclusivamente los del conjunto M4, de acceso público.

Reproducibilidad

Para reproducir el experimento completo:

1. Instalar las dependencias: `pip install -r requirements.txt`
2. Ejecutar: `python run_experiment.py --n-series 200 --max-folds 5`
3. Actualizar la memoria con los resultados: `python update_results_latex.py`
4. Compilar el documento: `cd memoria && latexmk -xelatex main.tex`

El módulo `src/Utils.py` fija las semillas de NumPy, PyTorch y el módulo `random` de la biblioteca estándar antes de cualquier operación aleatoria, garantizando resultados idénticos entre ejecuciones.

Índice de acrónimos