



Evaluación de modelos de pronóstico para la planificación financiera mediante backtesting temporal y métricas ponderadas por materialidad



Juan Camilo Rico Ballesteros · Juan José Blanco Mendoza · José Manuel Machado Loaiza

Directora: Marta María Arguedas Lafuente

Máster Universitario en Inteligencia Artificial · Julio de 2026

ÍNDICE

- 01 – Problema y propuesta
- 02 – Diseño del experimento
- 03 – Resultados
- 04 – Interpretación
- 05 – Cierre y conclusiones

Los modelos se eligen sin evidencia comparativa suficiente

FP&A

- ✓ Traduce los objetivos estratégicos en planes financieros cuantificables.
- ✓ El error de pronóstico tiene consecuencias directas: crédito a corto plazo o capital inmovilizado.
- ✓ La práctica recurre con frecuencia a criterios heurísticos o al juicio del analista.

El problema

- La selección de modelos carece de evidencia comparativa suficiente.
- No se sabe qué grado de complejidad algorítmica es adecuado para cada contexto.
- La validación cruzada estándar puede dar estimaciones optimistas en series temporales.

La necesidad

- ✓ Comparar familias de modelos bajo un mismo protocolo de validación temporal.
- ✓ Ir más allá del error estadístico: aproximar la materialidad del error.
- ✓ Aportar evidencia reproducible para decidir.

Fuente: TFM, 1.1–1.2 y 2.1 (Armstrong, 2001; Petropoulos et al., 2022; Bergmeir y Benítez, 2012).

La literatura deja tres brechas abiertas

01

Pocos estudios con series financieras corporativas

Los benchmarks existentes se basan sobre todo en retail, energía o tráfico (Makridakis et al., 2022).

Respuesta: un benchmark financiero mensual, antes de datos corporativos.

Cubierta parcialmente

02

Faltan marcos de evaluación orientados al valor

Minimizar el error estadístico no garantiza maximizar el valor para el negocio (Armstrong, 2001; Makridakis et al., 2025).

Respuesta: WAPE y contribución al error por decil de volumen.

Cubierta parcialmente

03

Faltan criterios objetivos para seleccionar modelos

Quienes deciden en FP&A carecen de guías cuantitativas sobre cuándo se justifica más sofisticación.

Respuesta: tres reglas heurísticas preliminares, sin validación externa.

Cubierta parcialmente

Pregunta guía: ¿qué grado de complejidad algorítmica resulta adecuado para cada contexto?

Fuente: TFM, Tabla 8 (2.3) y 1.2.

01 · Problema y propuesta

Siete modelos en cuatro niveles de complejidad creciente

Nivel 1 · Baseline

Seasonal Naïve

Repite el patrón estacional del año anterior

Nivel 2 · Estadístico clásico

ETS (AutoETS)
Holt-Winters
SARIMA (AutoARIMA)

Tendencia y estacionalidad;
parsimonia paramétrica

Nivel 3 · Machine Learning

LightGBM

Relaciones no lineales mediante
gradient boosting global

Nivel 4 · Deep Learning

MLP Bottleneck

N-BEATS Interpretable

Patrones complejos; N-BEATS
descompone tendencia y
estacionalidad

Modelos locales: un ajuste independiente por serie y fold

Modelos globales: un único modelo por fold sobre todas las series

Asimetría reconocida: AutoETS y AutoARIMA optimizan por AICc y por serie; LightGBM, MLP y N-BEATS usan hiperparámetros fijados manualmente.

Fuente: TFM, Tablas 2, 12 y 13 (1.2, 4.3).

Un objetivo general y cinco objetivos verificables


Comparar siete modelos de pronóstico sobre 200 series de M4 Financial Monthly mediante backtesting walk-forward y formular una propuesta preliminar de criterios heurísticos de selección para FP&A.

OE1	Revisar y sintetizar el estado del arte (revisión estructurada)
OE2	Implementar un pipeline modular y reproducible en Python
OE3	Aplicar backtesting walk-forward sin fuga de información
OE4	Evaluar con seis métricas y un análisis por deciles de volumen
OE5	Formular criterios heurísticos preliminares de selección

Fuente: TFM, 3.1–3.2 y Tabla 9.

02 · Diseño del experimento

Un pipeline modular y reproducible, de los datos a los resultados



Fuente: TFM, Figura 7 y Anexo A (3.3, Fase 4).

02 · Diseño del experimento

De 10.987 series M4 a una submuestra estratificada de 200

10.987



8.493



200

series M4 Financial Monthly

Categoría financiera mensual; acceso público.

series con al menos 72 meses

77,3 % del total; garantiza una iteración walk-forward.

series de la submuestra

Estratificada por cuartil de longitud · SEED = 42.

¿Es representativa la submuestra?

Longitud

KS = 0,053 · p = 0,63

Longitud media

218,0 frente a 218,2 meses

CV mediano

0,293 frente a 0,275

Tendencia positiva

82,0 % frente a 79,5 %


Población (N = 8.493) frente a muestra (N = 200).

M4 Financial Monthly es un proxy metodológico: no equivale a cuentas contables (P&L) corporativas; la correspondencia en escala y tendencia no está garantizada por el diseño de muestreo.


Fuente: TFM, Tablas 10 y 11 (4.2) y 3.3, Fase 2.

02 · Diseño del experimento

Walk-forward con ventana creciente y hasta cinco folds



Series según folds retenidos (N = 200)



El 86,5 % de las series conserva los cinco folds; las 20 series con un solo fold se excluyen del CV temporal.

Fuente: TFM, Figura 1, Tabla 15 y 4.5.

200/200

series sin fuga de información

verify_no_leakage comprueba la disyunción entre entrenamiento y evaluación en cada fold.

20/20

pruebas automatizadas superadas

14 pruebas de métricas y 6 de backtesting, validadas contra ejemplos manuales.

SEED = 42

semilla fija y entorno documentado

Muestreo y bootstrap con semilla fija; versiones en requirements.txt.

Favorece la reproducibilidad, sujeta a las limitaciones de determinismo de las librerías y del entorno (Python 3.13, CPU).

Fuente: TFM, 4.5, Tabla 9 y Anexo A.

02 · Diseño del experimento

Los criterios de éxito se fijaron antes de ejecutar

Criterio	Condición de superación del baseline	Matiz
sMAPE global	Reducción ≥ 1 pp frente al Seasonal Naïve	Referencia: 13,667 % (resultado del baseline)
MASE global	MASE $< 1,0$, evaluado por modelo	Denominador en muestra; ver nota del TFM
WAPE	No superar al baseline en el 30 % de mayor volumen (D8–D10)	Proxy de materialidad
Estabilidad temporal	CV del sMAPE < 25 % entre folds	Criterio exploratorio propio, no estándar
Significación	$\geq 0,5$ pp en más del 60 % de folds; IC bootstrap sin el cero	Reglas fijadas a priori

El umbral $CV < 25$ % es un criterio exploratorio definido en este trabajo; no existe un consenso publicado que lo respalde como estándar universal.

Fuente: TFM, Tabla 16 y 4.6.

Seis métricas; WAPE es un proxy de materialidad

Error estadístico

MAE Error absoluto en las unidades originales de cada serie

RMSE Penaliza con más fuerza los errores grandes

MAPE Error porcentual; fácil de comunicar a negocio

sMAPE Métrica principal, estándar de la competición M4

MASE Error escalado frente al naïve estacional

Ponderada por magnitud

WAPE

Pondera el error por el volumen de la serie: proxy de materialidad.

Contribución por decil

Análisis complementario del error absoluto por decil de volumen (D1–D10).

WAPE y el análisis por volumen aproximan la materialidad financiera; no miden el impacto económico en unidades monetarias comparables.

Fuente: TFM, Tabla 14 y 4.4.

ETS obtiene el menor error en las seis métricas

10,0 %

sMAPE medio de ETS (AutoETS)

El menor error en MAE, RMSE, MAPE, sMAPE, MASE y WAPE.

13,7 %

sMAPE medio del Seasonal Naïve

Baseline estacional de referencia.

−3,85 pp

diferencia media pareada por serie


IC bootstrap al 95 %: $[-4,52; -3,26]$ pp · N = 200 series.

Mejora estadísticamente significativa bajo el protocolo utilizado; resultado condicionado a M4 Financial Monthly y a las condiciones experimentales.

Fuente: TFM, Tablas 18, 22 y 24 (5.2–5.3).

03 · Resultados

Los estadísticos clásicos lideran el ranking de sMAPE



10,662 %

sMAPE medio de los estadísticos clásicos

11,967 %

sMAPE medio de ML y deep learning

13,667 %

Seasonal Naïve (baseline)

Fuente: TFM, Tabla 18, Figura 4 y 6.1.

03 · Resultados

ETS lidera también MAE, RMSE, MAPE, MASE y WAPE

Modelo	MAE	RMSE	MAPE (%)	sMAPE (%)	MASE	WAPE (%)
Seasonal Naïve	658	759	14,2	13,7	1,41	13,8
ETS (AutoETS)	476	559	10,6	10,0	1,02	10,1
Holt-Winters	547	643	12,2	11,2	1,15	11,6
SARIMA (AutoARIMA)	519	608	11,5	10,8	1,09	10,9
LightGBM	553	639	12,0	11,7	1,29	11,5
MLP Bottleneck	565	652	11,9	11,8	1,35	11,6
N-BEATS Interpretable	584	677	12,3	12,4	1,34	12,1

Normalizado por columna

Mejor

Peor


Valores medios sobre fold × serie (N = 200); MAE y RMSE en unidades originales.

Fuente: TFM, Tablas 17–19 y 24 (Figura 5 reconstruida con estos valores).

03 · Resultados

La mejora es significativa y resiste Bonferroni

Frente al Seasonal Naïve (6 comparaciones)



Entre modelos (4 comparaciones)




SARIMA vs Holt-Winters: no significativo

Fuente: TFM, Tablas 22 y 23 (5.3). Valores negativos = menor error que la referencia.

03 · Resultados

Ningún modelo alcanza el umbral de estabilidad

sMAPE medio por posición de fold · 173 series con cinco folds



47,2–55,1 %

CV temporal medio por serie (7 modelos; 180 series con dos o más folds)

84,4–90,6 %

de las series individuales presentan un CV superior al 25 %

0 de 7

modelos por debajo del umbral exploratorio CV < 25 %

El error baja con folds más recientes (más historial en la ventana creciente), sin que ello fije una causa única. CV < 25 % es un umbral exploratorio propio, no un estándar.

Fuente: TFM, Figura 2 y Tabla 20 (5.3, 6.4).


ETS mantiene su ventaja en las series de mayor volumen

35,7 %

del error absoluto total se concentra en D8–D10 (mayor volumen)

22,1 %

del error absoluto total corresponde a D1–D3 (menor volumen)



En D8–D10: WAPE de ETS 7,7 % frente a 10,0 % del Seasonal Naïve (–22,9 %).

Deciles calculados con los primeros 54 meses de cada serie: aproximación a la materialidad, no una medición del impacto económico.

Fuente: TFM, 5.4, 6.3 y Tabla 25 (Figura 3).

03 · Resultados

Se cumplen sMAPE, WAPE y significación; no MASE ni CV

Criterio	Umbral predefinido	Resultado experimental	Estado
sMAPE global	Reducción ≥ 1 pp frente al baseline	Todos reducen $\geq 1,065$ pp; ETS $-3,852$ pp	Cumplido
MASE global	MASE $< 1,0$ por modelo	Mejor valor $1,017$ (ETS); ninguno baja de $1,0$	No cumplido
WAPE por volumen	No superar al baseline en D8–D10	ETS reduce el WAPE de D8–D10	Cumplido
Estabilidad temporal	CV del sMAPE $< 25\%$	CV temporal por serie entre $47,2\%$ y $55,1\%$	No cumplido (aspiracional)
Significación	IC bootstrap excluye el cero	El IC al 95% excluye el cero en los seis modelos	Cumplido

Consistencia en más del 60 % de folds: ETS 71,4 %, SARIMA 68,2 %, Holt-Winters 64,6 % y LightGBM 62,5 % la superan; N-BEATS 59,0 % y MLP 57,8 % no.

Fuente: TFM, Tabla 26 y 4.6.

04 · Interpretación

Más complejidad no implicó mejor precisión



Cautelas del propio TFM

- Hiperparámetros de LightGBM, MLP y N-BEATS fijados manualmente.
- Entrenamiento en CPU con épocas limitadas (40 en MLP, 20 en N-BEATS).
- N-BEATS simplificado: 2 stacks de 3 bloques.
- Submuestra de 200 series heterogéneas.

No significa que los modelos simples siempre sean mejores ni que la complejidad sea inútil.

Fuente: TFM, 6.1–6.2, Tabla 18 (medias: 10,662 % clásicos; 11,967 % ML/DL).

El paradigma global no garantiza menor coste


Modelo	Ajuste total (s)	Memoria pico (MB)	CPU medio (%)	CPU máx. (%)	Tamaño (KB)
Seasonal Naïve	< 0,001	635,3	No registrado ¹	No registrado ¹	0,3
ETS	24,1	730,7	98,0	115,2	15,0
Holt-Winters	32,1	732,0	96,6	129,7	28,2
SARIMA	46,5	734,7	98,3	124,2	10,3
LightGBM	1,0 *	775,8	641,0	1.153,8	736,3
MLP	45,4 *	848,9	708,9	1.092,6	63,4
N-BEATS	80,8 *	859,0	837,7	1.091,4	1.345,1

LightGBM es el más rápido de ajustar (1,0 s) pero usa mucha CPU en paralelo; N-BEATS es el más lento y pesado (80,8 s; 859 MB; 1.345 KB). La memoria incluye ≈ 635 MB de entorno base; 100 % de CPU = un núcleo lógico.

** Ajuste único sobre las 200 series (modelos globales). ¹ No registrado: la ejecución terminó antes del primer intervalo de muestreo. Mediciones sobre el mismo fold y equipo: Windows 11, Intel Core i7-1355U, 31,7 GB, sin GPU.*

Fuente: TFM, Tabla 27 (benchmark_timing.py) y 6.2.

Propuesta preliminar de tres criterios, sin validar



Propuesta preliminar, no validada externamente. El valor de 120 observaciones es una convención práctica, no derivada de una fuente específica; R2 es una orientación cualitativa.

Fuente: TFM, Tablas 28 y 29, Figura 6 y 6.5 (aplicación secuencial $R1 \rightarrow R2 \rightarrow R3$).

Las conclusiones están condicionadas por sus límites

Datos y muestra

- M4 Financial Monthly es un proxy: no equivale a cuentas P&L corporativas.
- N = 200 series (reducido desde 400) y una única frecuencia mensual.

Configuración

- Hiperparámetros ML/DL fijados manualmente frente a la búsqueda automática de AutoETS y AutoARIMA.
- Épocas limitadas por el entorno de CPU.

Métricas y materialidad

- MAE y RMSE promedian series de escalas distintas: son descriptivas.
- WAPE y volumen aproximan la materialidad; no miden impacto económico.

Alcance y validación

- Sin variables exógenas ni intervalos de predicción.
- Sin validación con profesionales de FP&A: el framework es preliminar.

Además: el CV temporal excluye 20 series con un solo fold; la memoria se mide como RSS total ($\approx$ 635 MB de base); la CPU de Seasonal Naïve no se registró.

Fuente: TFM, 6.6 y 4.2.

Cuatro objetivos alcanzados y uno parcialmente

OE1	Estado del arte	Alcanzado
OE2	Pipeline modular y reproducible	Alcanzado
OE3	Walk-forward sin fuga de datos	Alcanzado
OE4	Evaluación con seis métricas	Alcanzado
OE5	Criterios heurísticos preliminares	Parcialmente alcanzado

- 01Se cumplen los objetivos OE1–OE4; OE5 es una propuesta preliminar.
- 02Bajo estas condiciones, ETS (10,0 % frente a 13,7 %) y los estadísticos clásicos lideran; ningún modelo alcanza la estabilidad exploratoria.
- 03No implica que lo simple siempre gane ni que la complejidad sea inútil: falta validar con datos corporativos.

Conclusiones condicionadas a M4 Financial Monthly, N = 200, la configuración de modelos y las condiciones experimentales del estudio.

Fuente: TFM, 7.1 y Tabla 30.

Primero validar el framework, después ampliar la técnica

Imprescindibles para validar el framework

- ✓ Validación longitudinal en una organización real.
- ✓ Panel de expertos de FP&A.
- ✓ Viabilidad económica y costes de implantación.



Ampliaciones técnicas

- ✓ Ensamblado y selección dinámica por serie.
- ✓ Modelos fundacionales especializados (Chronos, FinCast).
- ✓ Optimización bayesiana de hiperparámetros con validación temporal.
- ✓ Análisis por horizontes múltiples.
- ✓ Variables exógenas.

El marco requiere validación externa empírica con profesionales del sector antes de guiar decisiones de inversión tecnológica corporativa.

Fuente: TFM, 7.1–7.2.

muchas gracias