

# Texto de la exposición (registro académico): diapositivas 1 a 9

Para leer en voz alta. Los términos técnicos se introducen y se explican brevemente en el propio discurso. Tiempo aproximado: 10 a 12 minutos.

## Diapositiva 1 · Portada (30 s)

Buenos días. Agradecemos al tribunal su presencia. Somos Juan Camilo Rico Ballesteros, Juan José Blanco Mendoza y José Manuel Machado Loaiza, y presentamos nuestro Trabajo Fin de Máster, dirigido por la profesora Marta María Arguedas Lafuente, titulado «Evaluación de modelos de pronóstico para la planificación financiera mediante backtesting temporal y métricas ponderadas por materialidad».

El título resume el enfoque: el pronóstico es la estimación de valores futuros a partir de datos históricos; el backtesting temporal consiste en validar un modelo sobre el pasado, simulando que no conocemos los datos más recientes; y la ponderación por materialidad significa que el error se mide otorgando mayor peso a lo que es más relevante en términos monetarios. Mi intervención abarca el planteamiento del problema y el diseño experimental.

## Diapositiva 2 · Índice (30 s)

La exposición se estructura en cinco bloques. El primero plantea el problema y la propuesta. El segundo describe el diseño del experimento. El tercero presenta los resultados empíricos. El cuarto los interpreta. Y el quinto recoge las conclusiones y el cierre. Me corresponde desarrollar el primer bloque y la parte inicial del segundo; mis compañeros continuarán con el resto.

## Diapositiva 3 · Los modelos se eligen sin evidencia comparativa suficiente (1 min 15 s)

Partimos del contexto. El FP&A, siglas de planificación y análisis financiero, es la función organizativa que traduce los objetivos estratégicos de una empresa en planes financieros cuantificables, como presupuestos y proyecciones. En este ámbito, el error de pronóstico tiene consecuencias directas: puede inducir a contratar crédito a corto plazo innecesario o a inmovilizar capital. No obstante, la práctica recurre con frecuencia a criterios heurísticos, esto es, reglas empíricas no contrastadas, o al juicio del analista.

De ahí se deriva el problema que abordamos: la selección de modelos carece de evidencia comparativa suficiente. Se desconoce qué grado de complejidad algorítmica, es decir, de sofisticación del método, resulta adecuado en cada

contexto. A ello se añade una limitación metodológica: la validación cruzada estándar, que reparte las observaciones de forma aleatoria entre entrenamiento y prueba, puede producir estimaciones optimistas en series temporales, porque rompe el orden cronológico y permite que el modelo se entrene con información posterior a la que debe predecir.

La necesidad que se desprende es triple. Primero, comparar familias de modelos bajo un mismo protocolo de validación temporal, de modo que todos se evalúen en condiciones idénticas. Segundo, trascender el error puramente estadístico y aproximar la materialidad del error, que es su relevancia económica. Y tercero, aportar evidencia reproducible, entendida como aquella que un tercero puede replicar y verificar de forma independiente.

#### **Diapositiva 4 · La literatura deja tres brechas abiertas (1 min 15 s)**

La revisión de la literatura identifica tres brechas, es decir, tres vacíos que justifican esta investigación.

La primera es la escasez de estudios con series financieras corporativas. Los benchmarks existentes, entendidos como conjuntos de datos y reglas estándar para comparar métodos, se basan principalmente en comercio minorista, energía o tráfico. Nuestra respuesta es un benchmark financiero mensual, con datos públicos, como paso previo al uso de datos corporativos.

La segunda es la ausencia de marcos de evaluación orientados al valor. Minimizar el error estadístico no garantiza maximizar el valor para el negocio. Para abordarlo empleamos el WAPE, el error porcentual absoluto ponderado, que divide la suma de los errores absolutos entre la suma de los valores reales, de modo que las series de mayor volumen pesan más. Lo complementamos con la contribución al error por decil de volumen: un decil es cada una de las diez partes iguales en que se ordenan las series, de menor a mayor volumen.

La tercera es la falta de criterios objetivos de selección de modelos. Quienes toman decisiones en FP&A carecen de guías cuantitativas que indiquen cuándo se justifica una mayor sofisticación. Proponemos tres reglas heurísticas preliminares, que carecen de validación externa.

Cabe señalar que, como indican las etiquetas, estas brechas se cubren de forma parcial, no completa. Todo el trabajo se articula en torno a una pregunta guía: ¿qué grado de complejidad algorítmica resulta adecuado para cada contexto?

#### **Diapositiva 5 · Siete modelos en cuatro niveles de complejidad creciente (1 min 30 s)**

Para responder a esa pregunta comparamos siete modelos, agrupados en cuatro niveles de complejidad creciente.

El nivel uno es el baseline, el modelo de referencia mínimo: el Seasonal Naïve, o ingenuo estacional, que repite el valor observado en el mismo mes del año anterior. Cualquier método más complejo debe superarlo para justificar su uso.

El nivel dos reúne los modelos estadísticos clásicos: ETS, Holt-Winters y SARIMA. ETS y Holt-Winters pertenecen a la familia del suavizado exponencial, que estima el nivel, la tendencia y la estacionalidad de la serie otorgando mayor peso a las observaciones recientes. SARIMA modela la serie a partir de sus propios valores y errores pasados, incorporando un componente estacional. En ETS y SARIMA empleamos versiones automáticas, AutoETS y AutoARIMA, que seleccionan su configuración por sí mismas. Se caracterizan por su parsimonia paramétrica, es decir, utilizan pocos parámetros.

El nivel tres corresponde al aprendizaje automático, representado por LightGBM, un algoritmo de gradient boosting que combina secuencialmente muchos árboles de decisión pequeños, cada uno corrigiendo los errores del anterior, y que permite capturar relaciones no lineales, en las que el efecto no es proporcional a la causa.

El nivel cuatro es el aprendizaje profundo, con dos redes neuronales: el MLP Bottleneck, un perceptrón multicapa cuyas capas se estrechan progresivamente, y N-BEATS en su versión interpretable, una arquitectura diseñada para series temporales que descompone la señal en tendencia y estacionalidad.

Estos modelos se dividen además en locales y globales. Los locales, de los niveles uno y dos, ajustan un modelo independiente por cada serie y fold. Los globales, de los niveles tres y cuatro, entrenan un único modelo por fold con todas las series conjuntamente.

Reconocemos expresamente una asimetría: AutoETS y AutoARIMA optimizan sus parámetros de forma automática y por serie mediante el criterio AICc, un criterio de información que equilibra la calidad del ajuste frente a la complejidad del modelo. En cambio, LightGBM, MLP y N-BEATS utilizan hiperparámetros, esto es, ajustes definidos antes del entrenamiento, fijados manualmente. Lo declaramos porque podría favorecer relativamente a los modelos estadísticos.

## **Diapositiva 6 · Un objetivo general y cinco objetivos verificables (1 min)**

Pasamos al diseño del experimento. El objetivo general consiste en comparar siete modelos de pronóstico sobre 200 series de M4 Financial Monthly, mediante backtesting walk-forward, y formular una propuesta preliminar de criterios heurísticos de selección para FP&A. M4 es una colección pública de series temporales procedente de una competición internacional de pronóstico; utilizamos su categoría financiera mensual. El backtesting walk-forward es una validación que avanza cronológicamente, y lo detallaré en la diapositiva nueve.

Este objetivo se descompone en cinco objetivos específicos, todos verificables. El primero, revisar y sintetizar el estado del arte mediante una revisión estructurada. El segundo, implementar un pipeline modular y reproducible en Python, entendiendo por pipeline una cadena automatizada de etapas que va de los datos a los resultados. El tercero, aplicar el backtesting walk-forward sin fuga de información, es decir, sin que el modelo acceda a datos futuros durante el entrenamiento. El cuarto, evaluar con seis métricas y un análisis por deciles de volumen. Y el quinto, formular criterios heurísticos preliminares de selección.

### **Diapositiva 7 · Un pipeline modular y reproducible (1 min)**

El experimento se ha implementado como un pipeline de cuatro etapas, cada una en un módulo independiente. Esta arquitectura es modular, porque permite modificar un componente sin alterar los demás, y reproducible, porque su ejecución puede repetirse con idéntico resultado.

La primera etapa es la de datos: se descargan las series de M4, se filtran, se construye la submuestra y se calculan los deciles de volumen. La segunda es la validación temporal: se fijan los parámetros del experimento, entre ellos la semilla aleatoria igual a 42, un valor que fija el generador de números aleatorios para que el muestreo sea siempre el mismo, y se generan los folds del walk-forward. En esta etapa se ejecuta la función `verify_no_leakage`, que verifica de forma explícita la ausencia de fuga de información. La tercera son los modelos: cuatro locales y tres globales, todos bajo una interfaz común, es decir, un mismo conjunto de operaciones de ajuste y predicción, lo que garantiza una comparación equitativa. La cuarta es la evaluación: se calculan las seis métricas y se aplica bootstrap sobre diferencias pareadas. El bootstrap es una técnica de remuestreo que repite el cálculo miles de veces sobre muestras generadas a partir de los propios datos, para estimar la incertidumbre de un resultado; y las diferencias pareadas comparan dos modelos serie a serie, sobre los mismos datos.

El conjunto se orquesta desde un notebook y un script, y las salidas, tablas en CSV, figuras en PNG y código, se publican en un repositorio abierto de GitHub, lo que permite su auditoría.

### **Diapositiva 8 · De 10.987 series M4 a una submuestra estratificada de 200 (1 min 15 s)**

En cuanto a los datos, partimos de las 10.987 series de M4 Financial Monthly. Impusimos un mínimo de 72 meses de historia, es decir, seis años, lo que dejó 8.493 series, el 77,3 % del total. Este umbral no es arbitrario: con 54 meses de entrenamiento y 18 de evaluación se garantiza al menos una iteración completa del walk-forward.

A partir de esas 8.493 series extrajimos una submuestra de 200, estratificada por cuartil de longitud, con semilla 42. El muestreo estratificado consiste en dividir la población en subgrupos, aquí cuatro cuartiles según la longitud de la serie, y muestrear en cada uno, de modo que queden representadas series cortas, medianas y largas. El tamaño de 200 responde al coste computacional de entrenar siete modelos en múltiples folds.

Para evaluar la representatividad de la submuestra la contrastamos con la población. La prueba de Kolmogorov-Smirnov, que compara si dos distribuciones son equivalentes, arrojó un estadístico de 0,053 y un p-valor de 0,63; al ser muy superior a 0,05, no hay evidencia de diferencias en la distribución de longitudes. La longitud media es prácticamente idéntica: 218,0 frente a 218,2 meses. La variabilidad relativa, medida con el coeficiente de variación mediano, que es la desviación estándar dividida entre la media, es de 0,293 frente a 0,275. Y la proporción de series con tendencia positiva es de 82,0 % frente a 79,5 %.

Debe subrayarse una limitación: M4 Financial Monthly es un proxy metodológico, es decir, un sustituto aproximado. No equivale a estados contables corporativos, como una cuenta de pérdidas y ganancias, y la correspondencia en escala y tendencia con datos reales no está garantizada por el diseño muestral.

## **Diapositiva 9 · Walk-forward con ventana creciente y hasta cinco folds (1 min 30 s)**

Llegamos al núcleo metodológico: el backtesting walk-forward. Este procedimiento reproduce el uso real de un modelo: se entrena con la información disponible hasta una fecha, se predice el periodo siguiente, se contrasta con lo ocurrido y se avanza en el tiempo.

Cada barra del gráfico representa un fold, una iteración de entrenamiento y evaluación. El tramo azul claro es el conjunto de entrenamiento; el azul oscuro es el horizonte de evaluación, de 18 meses, que el modelo debe predecir sin haberlo observado. En el primer fold se entrena con 54 meses y se evalúan los 18 siguientes. En el segundo, la ventana de entrenamiento se amplía 12 meses, hasta 66, y se vuelve a evaluar sobre 18 meses. El proceso se repite hasta el quinto fold, con 102 meses de entrenamiento. Dado que la ventana crece en cada iteración, se denomina ventana creciente, o expanding window.

Los parámetros son: 54 meses de ventana inicial, 18 de horizonte, 12 de paso entre folds, y un máximo de cinco folds por serie, los más recientes. Este diseño garantiza que nunca se emplee información posterior a la fecha de corte para entrenar, evitando la fuga de información.

La longitud de cada serie condiciona el número de folds. De las 200 series, 173 conservan los cinco folds, cinco tienen cuatro, dos tienen dos y veinte tienen uno

solo. Es decir, el 86,5 % conserva los cinco folds. Las veinte series con un único fold se excluyen solo del análisis de estabilidad temporal, porque con una única observación del error no puede medirse su variabilidad.

En síntesis, cada modelo se evalúa repetidamente sobre datos no vistos durante el entrenamiento. Con ello queda definido el diseño experimental: el problema, los modelos, los datos y el protocolo de validación. Cedo la palabra a mi compañero, que continuará con las garantías del experimento.