

Texto de la exposición: diapositivas 1 a 9

Para leer en voz alta, tal como está escrito. Tiempo total aproximado: 10 minutos.

Diapositiva 1 · Portada (30 s)

Buenos días a todos y gracias por estar aquí. Somos Juan Camilo Rico, Juan José Blanco y yo, José Manuel Machado, y hoy les presentamos nuestro Trabajo Fin de Máster, dirigido por la profesora Marta María Arguedas. Se titula: «Evaluación de modelos de pronóstico para la planificación financiera mediante backtesting temporal y métricas ponderadas por materialidad».

En palabras sencillas: probamos distintos métodos para predecir cifras financieras, los comparamos de forma justa, y medimos el error dando más importancia a lo que más pesa en dinero. Yo me encargaré de la primera parte: el problema y el diseño del experimento.

Diapositiva 2 · Índice (30 s)

La presentación sigue una historia en cinco partes. Primero, el problema y nuestra propuesta. Segundo, el diseño del experimento: cómo lo hicimos. Tercero, los resultados. Cuarto, su interpretación. Y quinto, las conclusiones y el cierre.

Yo expondré las dos primeras partes, hasta la mitad del diseño del experimento, y mis compañeros continuarán con el resto.

Diapositiva 3 · Los modelos se eligen sin evidencia comparativa suficiente (1 min 15 s)

Empecemos por el contexto. FP&A significa planificación y análisis financiero: es el área de una empresa que convierte los objetivos estratégicos en planes con cifras, como presupuestos y proyecciones. En esta área, equivocarse al pronosticar tiene consecuencias directas: se puede pedir un crédito a corto plazo que no hacía falta, o dejar dinero inmovilizado sin necesidad. Y, sin embargo, en la práctica el método de pronóstico se elige muchas veces por costumbre, por reglas prácticas o por el juicio del analista.

Ese es precisamente el problema: la selección de modelos carece de evidencia comparativa suficiente. No se sabe cuánta sofisticación es la adecuada para cada situación. ¿Necesitamos una red neuronal compleja, o basta con un método sencillo? A esto se suma otro riesgo: la validación cruzada estándar, que mezcla los datos al azar, puede dar resultados demasiado optimistas en series de tiempo, porque el modelo termina «viendo el futuro» sin querer.

Por eso planteamos tres necesidades. Primera: comparar familias de modelos con las mismas reglas para todos, bajo un mismo protocolo de validación temporal.

Segunda: ir más allá del error estadístico y aproximar la materialidad del error, porque no todos los errores cuestan lo mismo. Y tercera: aportar evidencia reproducible, es decir, que cualquier persona pueda repetir y verificar. En resumen: hoy se elige el modelo sin comparar bien, y eso es lo que queremos corregir.

Diapositiva 4 · La literatura deja tres brechas abiertas (1 min 15 s)

Al revisar la literatura encontramos tres brechas, tres vacíos que justifican este trabajo.

La primera: hay pocos estudios con series financieras corporativas. Las comparaciones de referencia, los llamados benchmarks, se basan sobre todo en comercio minorista, energía o tráfico. Nuestra respuesta es construir un benchmark financiero mensual con datos públicos, como paso previo a usar datos corporativos reales.

La segunda: faltan marcos de evaluación orientados al valor. Minimizar el error estadístico no garantiza maximizar el valor para el negocio. Nuestra respuesta es usar el WAPE, que es un error porcentual ponderado por volumen, de modo que las series grandes pesan más, y analizar cuánto error aporta cada decil de volumen; un decil es cada una de las diez partes iguales en que dividimos las series, de la más pequeña a la más grande.

La tercera: faltan criterios objetivos para seleccionar modelos. Quienes deciden en FP&A no tienen guías cuantitativas que indiquen cuándo se justifica usar más sofisticación. Nuestra respuesta es proponer tres reglas prácticas preliminares, que todavía no tienen validación externa.

Quiero ser claro en algo: como ven en las etiquetas, estas brechas las cubrimos parcialmente, no por completo. Preferimos ser honestos con el alcance. Todo el trabajo gira alrededor de una pregunta guía: ¿qué grado de complejidad algorítmica resulta adecuado para cada contexto?

Diapositiva 5 · Siete modelos en cuatro niveles de complejidad creciente (1 min 30 s)

Para responder esa pregunta comparamos siete modelos, organizados como una escalera de cuatro niveles, de menos a más sofisticado.

En el nivel uno está el punto de partida, o baseline: el Seasonal Naïve. Es el método más simple: repite el patrón estacional del año anterior. Si en marzo pasado vendimos una cantidad, predice esa misma cantidad para este marzo. Es la vara mínima: cualquier modelo más complejo debe superarlo para justificarse.

En el nivel dos están los modelos estadísticos clásicos: ETS, Holt-Winters y SARIMA. Capturan la tendencia y la estacionalidad con pocos parámetros. ETS y

Holt-Winters suavizan los datos dando más peso a lo reciente, y SARIMA predice a partir de los valores y errores pasados de la propia serie. En ETS y SARIMA usamos versiones automáticas, que eligen solas su mejor configuración.

En el nivel tres está el aprendizaje automático, con LightGBM, que construye muchos árboles de decisión pequeños, cada uno corrigiendo los errores del anterior, y así capta relaciones que no son proporcionales.

Y en el nivel cuatro está el aprendizaje profundo, con dos redes neuronales: MLP y N-BEATS. N-BEATS, además, descompone la serie en tendencia y estacionalidad, por eso lo llamamos interpretable.

Abajo vemos otra distinción importante. Los modelos de los niveles uno y dos son locales: se ajusta un modelo independiente para cada serie y cada ronda de prueba. Los de los niveles tres y cuatro son globales: un único modelo por ronda, entrenado con todas las series a la vez.

Y queremos dejar constancia de una asimetría: AutoETS y AutoARIMA optimizan sus parámetros automáticamente, serie por serie, con un criterio llamado AICc, mientras que LightGBM, MLP y N-BEATS usan hiperparámetros, es decir, ajustes, fijados manualmente. Lo declaramos porque podría favorecer a los modelos estadísticos.

Diapositiva 6 · Un objetivo general y cinco objetivos verificables (1 min)

Pasamos ahora al diseño del experimento. Nuestro objetivo general fue comparar siete modelos de pronóstico sobre 200 series de M4 Financial Monthly, mediante backtesting walk-forward, y formular una propuesta preliminar de criterios de selección para FP&A. M4 es una colección pública de series de tiempo, y de ella tomamos la categoría financiera mensual. El backtesting walk-forward, que explicaré en un momento, consiste en probar los modelos avanzando en el tiempo, como si estuviéramos viviendo cada fecha.

Este objetivo general lo desglosamos en cinco objetivos específicos, todos verificables. El primero: revisar y sintetizar el estado del arte. El segundo: implementar un pipeline modular y reproducible en Python; un pipeline es una cadena automática de pasos, que veremos enseguida. El tercero: aplicar el backtesting walk-forward sin fuga de información, es decir, sin que el modelo use datos del futuro. El cuarto: evaluar con seis métricas y un análisis por deciles de volumen. Y el quinto: formular criterios heurísticos preliminares de selección, o sea, reglas prácticas de orientación.

Diapositiva 7 · Un pipeline modular y reproducible (1 min)

Todo el experimento está programado como un pipeline de cuatro etapas, cada una en su propio módulo de código. Es modular, porque se puede cambiar una

pieza sin romper las demás, y reproducible, porque cualquiera puede repetirlo y obtener lo mismo.

La primera etapa son los datos: descargamos las series de M4, las filtramos, armamos la submuestra y calculamos los deciles de volumen. La segunda es la validación temporal: aquí se fijan los parámetros del experimento, incluida una semilla de azar, el número 42, que garantiza que el sorteo de series sea siempre el mismo, y se generan las rondas del walk-forward. En esta etapa hay una función clave, que se llama `verify_no_leakage`, y comprueba que no haya fuga de información. La tercera etapa son los modelos: cuatro locales y tres globales, todos con una interfaz común, es decir, se usan exactamente de la misma forma, lo que asegura una comparación justa. Y la cuarta es la evaluación: se calculan las seis métricas, se aplica una técnica llamada bootstrap, que remuestrea los datos muchas veces para medir qué tan seguro es un resultado, y se generan las figuras.

Todo se coordina desde un notebook y un script, y las salidas, es decir, tablas, figuras y código, están en un repositorio público de GitHub, abierto a cualquier auditoría.

Diapositiva 8 · De 10.987 series M4 a una submuestra estratificada de 200 (1 min 15 s)

Hablemos de los datos. Partimos de 10.987 series de M4 Financial Monthly, públicas y de categoría financiera mensual. Exigimos como mínimo 72 meses de historia, es decir, seis años. Con ese filtro nos quedaron 8.493 series, el 77,3 % del total. Elegimos 72 porque con 54 meses para entrenar y 18 para evaluar garantizamos al menos una ronda completa de walk-forward.

De esas 8.493 series tomamos una submuestra de 200, estratificada por cuartil de longitud. Eso significa que ordenamos las series por su longitud, las dividimos en cuatro grupos iguales y sacamos series de cada grupo, para que haya series cortas, medianas y largas. El sorteo usó la semilla 42. Usamos 200 series porque entrenar siete modelos en varias rondas es costoso en cómputo.

¿Es representativa esta submuestra? Lo comprobamos. En la longitud de las series, la prueba de Kolmogorov-Smirnov da 0,053 con un p-valor de 0,63; como es mucho mayor que 0,05, no hay diferencias estadísticas entre la muestra y la población. La longitud media es prácticamente idéntica: 218,0 frente a 218,2 meses. La variabilidad, medida con el coeficiente de variación mediano, es muy parecida: 0,293 frente a 0,275. Y la proporción de series con tendencia al alza es similar: 82,0 % frente a 79,5 %.

Pero hay una cautela importante que queremos subrayar: M4 Financial Monthly es un proxy metodológico, es decir, un sustituto de prueba. No equivale a las cuentas contables reales de una empresa, y la correspondencia en escala y tendencia con

datos corporativos no está garantizada. Es un buen banco de pruebas para comparar métodos, pero no son datos de una empresa real.

Diapositiva 9 · Walk-forward con ventana creciente y hasta cinco folds (1 min 30 s)

Llegamos al corazón del método: el walk-forward. La idea es simular cómo se usaría un modelo en la vida real: con el pasado hacemos una predicción, vemos qué ocurrió, y avanzamos en el tiempo.

Cada barra del gráfico es un fold, una ronda de prueba. La parte azul clara es el entrenamiento, los datos que el modelo puede ver. La parte azul oscura es el horizonte de evaluación: 18 meses que el modelo debe predecir y que nunca ha visto. En el primer fold entrenamos con 54 meses y predecimos los 18 siguientes. En el segundo fold, la ventana de entrenamiento crece 12 meses, llega a 66, y volvemos a predecir 18 meses. Y así hasta el quinto fold, con 102 meses de entrenamiento. Como la ventana de entrenamiento va creciendo, se llama ventana creciente.

En resumen: 54 meses de ventana inicial, 18 meses de horizonte, 12 meses de paso entre folds, y como máximo cinco folds por serie, siempre los más recientes. Lo más importante es que nunca se usa información posterior a cada fecha de corte para entrenar: así evitamos la fuga de información.

No todas las series tienen la misma longitud, y las más cortas permiten menos folds. De las 200 series, 173 conservan los cinco folds; 5 tienen cuatro; 2 tienen dos; y 20 tienen un solo fold. Es decir, el 86,5 % de las series conserva los cinco folds. Las 20 series de un solo fold solo se excluyen del análisis de estabilidad en el tiempo, porque con un único fold no se puede medir cuánto varía el error.

Con esto, cada modelo se evalúa varias veces, siempre sobre datos que no vio al entrenar. Hasta aquí el diseño del experimento: el problema, los modelos, los datos y la forma justa de evaluarlos. Le cedo la palabra a mi compañero, que continuará con las garantías del experimento.