

Guión de defensa: diapositivas 1 a 9

Tiempo total: unos 9 a 10 minutos. El guión está escrito para decirlo en voz alta; no lo leas literal. Memoriza la idea de cada diapositiva y usa las frases como guía. Los términos técnicos van explicados en cada diapositiva, con una frase corta que puedes decir si quieres aclararlos al tribunal.

Diapositiva 1: Portada (~30 s)

Cómo presentarla: de pie, sin prisa, mirando al tribunal.

"Buenos días/tardes. Somos Juan Camilo Rico, Juan José Blanco y yo, José Manuel Machado. Les presentamos nuestro Trabajo Fin de Máster, dirigido por la profesora Marta María Arguedas: *Evaluación de modelos de pronóstico para la planificación financiera mediante backtesting temporal y métricas ponderadas por materialidad*. Voy a abrir la presentación con el problema y el diseño del experimento."

Términos del título, en sencillo:

- **Modelo de pronóstico:** un método matemático que usa datos del pasado para predecir el futuro, por ejemplo cuánto se va a vender el próximo mes.
- **Planificación financiera (FP&A):** el área de una empresa que arma presupuestos y proyecciones.
- **Backtesting temporal:** probar un modelo "como si estuviéramos en el pasado". Escondemos los datos más recientes, el modelo predice y comparamos con lo que realmente pasó.
- **Métricas ponderadas por materialidad:** medir el error dando más peso a lo que más importa en dinero. Un error en una cuenta grande pesa más que uno en una cuenta pequeña.

Diapositiva 2: Índice (~30 s)

Cómo presentarla: señala los cinco bloques con la mano. No te detengas.

"La presentación sigue una historia en cinco partes. Primero, el problema y nuestra propuesta. Segundo, cómo diseñamos el experimento. Tercero, los resultados. Cuarto, su interpretación. Y quinto, las conclusiones y el cierre. Yo me encargo de las dos primeras, hasta mitad del diseño del experimento. Mis compañeros continuarán con el resto."

Idea clave: vamos a pasar de "qué problema hay" a "qué hicimos" y luego a "qué encontramos".

Diapositiva 3: "Los modelos se eligen sin evidencia comparativa suficiente" (~1 min 15 s)

Cómo presentarla: son tres columnas; léelas de izquierda a derecha como una historia: contexto, problema, necesidad. Señala cada columna al nombrarla.

Columna 1: FP&A (contexto)

"FP&A significa *Financial Planning & Analysis*, planificación y análisis financiero. Es el área que traduce los objetivos estratégicos de una empresa en planes con números. Y aquí el error de pronóstico importa: si predigo mal, la empresa puede pedir un crédito a corto plazo que no necesitaba, o dejar dinero inmovilizado. En la práctica, además, muchas veces se elige el método por criterios heurísticos o por el juicio del analista."

- **Heurístico:** regla práctica basada en experiencia, no en evidencia medida. "Siempre hemos usado este modelo."

Columna 2: El problema

"Aquí está el problema: la selección de modelos carece de evidencia comparativa suficiente. No se sabe cuánta complejidad algorítmica es adecuada para cada contexto. ¿Hace falta un modelo de

inteligencia artificial sofisticado o basta uno sencillo? Y hay un segundo riesgo: la validación cruzada estándar puede dar estimaciones demasiado optimistas en series temporales."

- **Complejidad algorítmica:** qué tan sofisticado es un modelo. Un promedio es simple; una red neuronal es compleja.
- **Validación cruzada estándar:** técnica que mezcla los datos al azar para probar un modelo. Con series temporales es un problema, porque el modelo puede "ver el futuro" sin darse cuenta. Por eso los resultados salen demasiado buenos.

Columna 3: La necesidad

"Por eso necesitamos tres cosas. Primera, comparar familias de modelos bajo un mismo protocolo de validación temporal, es decir, con las mismas reglas para todos. Segunda, ir más allá del error estadístico y aproximar la materialidad del error: no todos los errores cuestan lo mismo. Y tercera, aportar evidencia reproducible para decidir."

- **Reproducible:** cualquier persona puede repetir el experimento y obtener lo mismo.

Frase de cierre: "Dicho simple: hoy se elige el modelo sin comparar bien, y eso es lo que vamos a corregir."

Diapositiva 4: "La literatura deja tres brechas abiertas" (~1 min 15 s)

Cómo presentarla: tres tarjetas. En cada una lee el título, di la idea y termina con la "Respuesta". Al final, señala la franja azul inferior.

"Al revisar la literatura encontramos tres brechas, es decir, tres vacíos."

Brecha 1: Pocos estudios con series financieras corporativas

"Los benchmarks existentes se basan sobre todo en retail, energía o tráfico. Casi no hay comparaciones con series financieras. Nuestra respuesta es un benchmark financiero mensual, con datos públicos, como paso previo a usar datos corporativos."

- **Benchmark:** conjunto de datos y reglas estándar para comparar modelos de manera justa.

Brecha 2: Faltan marcos de evaluación orientados al valor

"Minimizar el error estadístico no garantiza maximizar el valor para el negocio. Nuestra respuesta es usar el WAPE y la contribución al error por decil de volumen."

- **WAPE:** error porcentual ponderado por volumen. Se suman todos los errores en valor absoluto y se dividen entre el total real. Las series grandes pesan más. Es una aproximación a "cuánto dinero está en juego".
- **Decil de volumen:** ordenamos las series de menor a mayor volumen y las dividimos en 10 grupos iguales. D1 es el 10 % más pequeño; D10, el 10 % más grande.

Brecha 3: Faltan criterios objetivos para seleccionar modelos

"Quienes deciden en FP&A no tienen guías cuantitativas sobre cuándo se justifica más sofisticación. Nuestra respuesta es proponer tres reglas heurísticas preliminares, sin validación externa."

Punto importante: las tres etiquetas dicen "Cubierta parcialmente". Dilo de forma natural: "Aclaro que las cubrimos parcialmente, no totalmente. Somos honestos con el alcance." Esto juega a favor, porque da credibilidad.

Franja azul (Pregunta guía):

"Todo el trabajo gira alrededor de una pregunta: ¿qué grado de complejidad algorítmica resulta adecuado para cada contexto?"

Diapositiva 5: "Siete modelos en cuatro niveles de complejidad creciente" (~1 min 30 s)

Cómo presentarla: es una escalera. Recórrela de izquierda a derecha, subiendo.

"Para responder la pregunta comparamos siete modelos, organizados en cuatro niveles. Es como una escalera: cada escalón es más sofisticado que el anterior."

Nivel 1, Baseline: Seasonal Naïve

"Es el punto de partida. Repite el patrón estacional del año anterior. Si en marzo del año pasado vendimos X, predice X para este marzo."

- **Baseline:** la vara mínima. Cualquier modelo sofisticado debe superarla para justificarse.
- **Estacionalidad:** patrón que se repite cada año (diciembre alto, enero bajo).

Nivel 2, Estadísticos clásicos: ETS, Holt-Winters y SARIMA

"Son modelos estadísticos tradicionales que capturan tendencia y estacionalidad con pocos parámetros."

- **ETS (AutoETS):** suaviza los datos dando más peso a los más recientes, separando nivel, tendencia y estacionalidad. "Auto" significa que elige solo la mejor configuración.
- **Holt-Winters:** parecido a ETS; es el clásico suavizado exponencial con tendencia y estacionalidad.
- **SARIMA (AutoARIMA):** modelo que predice usando los valores y errores pasados de la propia serie, con componente estacional. "Auto" también elige solo su configuración.
- **Parsimonia paramétrica:** usan pocos "botones" que ajustar. Son modelos simples y compactos.

Nivel 3, Machine Learning: LightGBM

"Es un modelo de aprendizaje automático basado en árboles de decisión. Captura relaciones no lineales mediante gradient boosting global."

- **Gradient boosting:** construye muchos árboles de decisión pequeños, uno tras otro, cada uno corrigiendo los errores del anterior.
- **Relaciones no lineales:** cuando el efecto no es proporcional. Duplicar una variable no duplica el resultado.

Nivel 4, Deep Learning: MLP Bottleneck y N-BEATS Interpretable

"Son redes neuronales. Buscan patrones complejos. N-BEATS, además, descompone la serie en tendencia y estacionalidad, por eso lo llamamos interpretable."

- **MLP (perceptrón multicapa):** red neuronal básica, con capas de neuronas conectadas. Bottleneck significa que se estrecha (128 a 64 neuronas).
- **N-BEATS:** red neuronal diseñada específicamente para pronóstico de series temporales.

Las dos barras inferiores

"Los modelos del nivel 1 y 2 son locales: se ajusta un modelo independiente para cada serie y cada fold. Los de nivel 3 y 4 son globales: un único modelo por fold, entrenado con todas las series a la vez."

- **Fold:** cada una de las rondas de prueba. Se explica en la diapositiva 9.
- **Local vs. global:** local es un modelo por serie, como contratar un entrenador para cada jugador. Global es un solo modelo que aprende de todas, como un solo entrenador para todo el equipo.

Franja gris (Asimetría reconocida)

"Reconocemos una asimetría: AutoETS y AutoARIMA optimizan sus parámetros automáticamente por serie, con un criterio llamado AICc. En cambio, LightGBM, MLP y N-BEATS usan hiperparámetros fijados manualmente. Lo declaramos porque puede favorecer a los modelos estadísticos."

- **Hiperparámetros:** ajustes que define quien construye el modelo antes de entrenarlo (cuántas capas, qué velocidad de aprendizaje).
- **AICc:** criterio estadístico que elige el modelo que mejor ajusta sin complicarse de más. Premia el ajuste y castiga la complejidad innecesaria.

Idea clave: "Siete modelos, de menos a más sofisticados, para ver si la complejidad realmente compensa."

Diapositiva 6: "Un objetivo general y cinco objetivos verificables" (~1 min)

Cómo presentarla: lee el objetivo general (texto superior) y recorre OE1 a OE5 rápido, con una frase cada uno. Aquí empieza el bloque 02.

"Entrando al diseño del experimento: nuestro objetivo general es comparar siete modelos de pronóstico sobre 200 series de M4 Financial Monthly, mediante backtesting walk-forward, y formular una propuesta preliminar de criterios heurísticos de selección para FP&A."

"Lo desglosamos en cinco objetivos específicos, todos verificables: OE1, revisar el estado del arte con una revisión estructurada. OE2, implementar un pipeline modular y reproducible en Python. OE3, aplicar backtesting walk-forward sin fuga de información. OE4, evaluar con seis métricas y un análisis por deciles de volumen. OE5, formular criterios heurísticos preliminares de selección."

Términos:

- **M4 Financial Monthly:** subconjunto de datos públicos de la competencia de pronóstico M4. Son series financieras mensuales.
- **Walk-forward:** forma de hacer el backtesting avanzando en el tiempo (diapositiva 9).
- **Pipeline:** cadena automática de pasos, de los datos a los resultados (diapositiva 7).
- **Fuga de información (data leakage):** cuando el modelo usa, sin querer, datos del futuro para predecir. Los resultados salen artificialmente buenos.
- **Seis métricas:** seis formas de medir el error. Las explica mi compañero en resultados; basta decir que miramos el error desde varios ángulos.

Frase de transición: "Veamos ahora cómo se implementó."

Diapositiva 7: "Un pipeline modular y reproducible, de los datos a los resultados" (~1 min)

Cómo presentarla: son 4 cajas con flechas. Recórrelas de izquierda a derecha, sin leer los nombres de archivos uno por uno. Menciona un ejemplo por caja.

"Todo el experimento está programado como un pipeline: una cadena de cuatro etapas, cada una en su propio módulo de código. Esto lo hace modular, porque se puede cambiar una pieza sin romper las demás, y reproducible, porque cualquiera puede repetirlo."

- **Datos:** "Primero se descargan los datos de M4 y se preprocesan: filtramos las series, armamos la submuestra y calculamos los deciles de volumen."
- **Validación temporal:** "Segundo, se definen los parámetros del experimento, incluida la semilla, y se generan los folds del walk-forward. Aquí hay una función clave, `verify_no_leakage`, que comprueba que no haya fuga de información."
- **Modelos:** "Tercero, los siete modelos: cuatro locales y tres globales. Todos comparten una interfaz común, es decir, se usan de la misma forma, y eso garantiza que la comparación sea justa."
- **Evaluación:** "Cuarto, se calculan las seis métricas, se hace un bootstrap sobre diferencias pareadas, y se generan las figuras."

"Todo se orquesta desde un notebook y un script, y las salidas, tablas en CSV, figuras en PNG y el código, están en un repositorio público en GitHub."

Términos:

- **Modular:** dividido en piezas independientes e intercambiables.
- **SEED = 42 (semilla):** número fijo que controla el azar. Con la misma semilla, el sorteo de series sale igual cada vez. Es una de las razones por las que es reproducible.
- **Bootstrap:** técnica que remuestrea los datos muchas veces para estimar qué tan seguro es un resultado (calcula intervalos de confianza). No necesita suposiciones complicadas.
- **Diferencias pareadas:** comparar dos modelos serie por serie, restando sus errores en la misma serie, para que la comparación sea justa.
- **Interfaz común (BaseForecaster):** "molde" que obliga a todos los modelos a tener las mismas funciones (ajustar y predecir).
- **Repositorio en GitHub:** carpeta pública con todo el código y los resultados, para que se pueda auditar.

Idea clave: "No es un experimento hecho a mano; es un proceso automático, ordenado y repetible."

Diapositiva 8: "De 10.987 series M4 a una submuestra estratificada de 200" (~1 min 15 s)

Cómo presentarla: columna izquierda de arriba abajo (el embudo), luego el recuadro gris de la derecha, y termina con la franja inferior.

Embudo de datos

"Partimos de 10.987 series de M4 Financial Monthly, públicas y de categoría financiera mensual. Exigimos un mínimo de 72 meses de historia, es decir, 6 años. Con ese filtro quedan 8.493 series, el 77,3 % del total. ¿Por qué 72? Porque con 54 meses para entrenar y 18 para evaluar, garantizamos al menos una iteración del walk-forward. De esas 8.493 tomamos una submuestra de 200 series, estratificada por cuartil de longitud, con semilla 42."

- **Submuestra estratificada por cuartil de longitud:** ordenamos las series por cantidad de meses, las dividimos en 4 grupos iguales (cuartiles) y sacamos series de cada grupo. Así la muestra incluye series cortas, medianas y largas.
- **200 series:** un número manejable, porque entrenar siete modelos con muchos folds es costoso en cómputo.

Recuadro "¿Es representativa la submuestra?"

"Para comprobar que las 200 series representan bien a las 8.493, comparamos varias características. Longitud: la prueba KS da 0,053, con $p = 0,63$; no hay diferencia estadística entre la distribución de longitudes de la muestra y la población. Longitud media: 218,0 frente a 218,2 meses, prácticamente igual. CV mediano: 0,293 frente a 0,275, muy cercano. Tendencia positiva: 82,0 % frente a 79,5 %, también similar."

- **KS (Kolmogorov-Smirnov):** prueba estadística que compara si dos grupos de datos tienen la misma distribución. Un p-valor alto (0,63, mayor que 0,05) quiere decir que no hay evidencia de que sean diferentes. Es lo que queremos.
- **CV (coeficiente de variación):** qué tan variable es una serie respecto a su promedio. A mayor CV, más "saltona" es.
- **Tendencia positiva:** porcentaje de series que van al alza con el tiempo.

Franja inferior (la cautela)

"Y una cautela importante: M4 Financial Monthly es un proxy metodológico. No equivale a cuentas contables de una empresa, como un P&L. Es un buen banco de pruebas para comparar métodos, pero la correspondencia en escala y tendencia con datos corporativos no está garantizada."

- **Proxy:** sustituto o aproximación. Usamos M4 como "ensayo" porque los datos corporativos reales son confidenciales.
- **P&L (Profit & Loss):** estado de pérdidas y ganancias de una empresa.

Idea clave: "La muestra es pequeña pero representativa, y somos claros en que son datos públicos, no contabilidad real."

Diapositiva 9: "Walk-forward con ventana creciente y hasta cinco folds" (~1 min 30 s)

Cómo presentarla: es la diapositiva más conceptual. Señala las barras mientras hablas. Ve despacio y explica el Fold 1, luego muestra cómo crece.

"Este es el corazón del método. El walk-forward simula cómo se usaría el modelo en la vida real: con el pasado hacemos una predicción, vemos qué pasó, y vamos avanzando en el tiempo."

Cómo leer el gráfico

"Cada barra es un fold, una ronda de prueba. La parte azul clara es el entrenamiento; la parte oscura, el horizonte de evaluación, que son los 18 meses que el modelo debe predecir y que nunca ha visto. En el Fold 1 entrenamos con 54 meses y predecimos los siguientes 18. En el Fold 2 la ventana de entrenamiento crece 12 meses, llega a 66, y volvemos a predecir 18 meses. Así sucesivamente hasta el Fold 5, con 102 meses de entrenamiento. La ventana va creciendo, por eso se llama ventana creciente."

Los cuatro números de la derecha

"En resumen: 54 meses de ventana inicial, 18 meses de horizonte, 12 meses de paso entre folds, y hasta 5 folds por serie, tomando siempre los más recientes."

Términos:

- **Ventana creciente (expanding window):** el entrenamiento siempre empieza en el mismo punto y se alarga con cada fold, así se aprovecha toda la historia disponible.
- **Horizonte:** cuántos meses hacia adelante se predice (18).
- **Paso:** cuánto avanzamos de un fold al siguiente (12 meses).
- **Fold:** cada una de las rondas de entrenamiento y evaluación.
- **Sin fuga de información:** nunca se usan datos posteriores al corte para entrenar.

Los recuadros de abajo (series según folds retenidos)

"No todas las series tienen el mismo largo, y las cortas permiten menos folds. De las 200 series: 173 conservan los cinco folds, 5 tienen cuatro, 2 tienen dos, y 20 tienen un solo fold. Es decir, el 86,5 % conserva los cinco folds. Las 20 series de un solo fold se excluyen únicamente del análisis de estabilidad temporal (CV temporal), porque con un solo fold no se puede medir variación en el tiempo."

Cierre de tu parte:

"Con esto, cada modelo se evalúa varias veces, siempre sobre datos que no vio al entrenar. Hasta aquí el diseño del experimento: tenemos el problema, los modelos, los datos y la forma justa de evaluarlos. Le cedo la palabra a mi compañero."

Nota: confirma con tu equipo quién arranca en la diapositiva 10 (garantías de ausencia de fuga y pruebas automatizadas) y ajusta la despedida.

Glosario express para repasar en 1 minuto

Término	En una frase
FP&A	Área financiera que planifica y proyecta números
Backtesting	Probar un modelo contra el pasado "escondido"
Walk-forward	Backtesting que avanza en el tiempo ronda por ronda
Fold	Una ronda de entrenamiento y evaluación
Baseline	Modelo mínimo que hay que superar
Local / Global	Un modelo por serie / un modelo para todas
Hiperparámetros	Ajustes que fija quien diseña el modelo

WAPE	Error ponderado por volumen (proxy de materialidad)
Decil	Cada décima parte de las series, ordenadas por volumen
Fuga de información	El modelo "ve el futuro" sin querer
SEED = 42	Semilla que fija el azar para repetir resultados
Proxy	Aproximación o sustituto
KS / p-valor	Prueba de si dos distribuciones son iguales; p alto = parecidas
CV	Variabilidad relativa de una serie

Tres consejos para hoy

- **Ancla cada diapositiva en una sola idea** (están al final de cada bloque). Si te trabas, di esa idea y sigue.
- **Repite las cautelas con tranquilidad:** "proxy", "preliminar", "cubierta parcialmente". Muestran rigor, no debilidad.
- **Ritmo:** unos 1 a 1,5 minutos por diapositiva, y más lento en la 5 y la 9, que son las más densas.

Preguntas probables del tribunal sobre tus diapositivas

- **¿Por qué solo 200 series?** Por costo computacional de entrenar siete modelos con varios folds. La muestra es estratificada y se verificó que representa a la población (KS $p = 0,63$).
- **¿Por qué M4 y no datos reales?** Los datos corporativos son confidenciales. M4 es un proxy metodológico público y reproducible, y lo declaramos como limitación.
- **¿No favorece a ETS y ARIMA que se optimicen solos?** Sí, es una asimetría que reconocemos explícitamente (diapositiva 5). Los modelos de ML/DL usan hiperparámetros fijos, sin búsqueda automática.
- **¿Cómo saben que no hay fuga de información?** El walk-forward entrena solo con datos anteriores al corte, y la función `verify_no_leakage` lo comprueba sobre las 200 series, además de las pruebas automatizadas.
- **¿Por qué 54 meses iniciales y 18 de horizonte?** Con $54 + 18 = 72$ meses garantizamos al menos un fold, y 18 meses es un horizonte habitual de planificación financiera.