

Universidad Internacional de La Rioja
Escuela Superior de Ingeniería y Tecnología
Máster Universitario en Inteligencia Artificial

Evaluación de modelos de pronóstico para la planificación financiera mediante backtesting temporal y métricas ponderadas por materialidad.

Autores: Juan Camilo Rico Ballesteros

Juan José Blanco Mendoza

José Manuel Machado Loaiza

Tipo de trabajo: Comparativa de soluciones

Directora: Marta María Arguedas Lafuente

Curso académico: 2025-2026

Fecha: Julio de 2026

Índice de contenidos

Resumen	1
Abstract	2
Organización del trabajo en grupo	3
Partes que aborda el trabajo	3
Distribución y estructura de la memoria	4
Objetivos individuales por integrante	5
Mecanismos de coordinación	5
1. Introducción	8
1.1. Motivación	8
1.2. Planteamiento del trabajo	10
1.3. Estructura del trabajo	11
2. Contexto y estado del arte	13
2.1. Contexto del problema	13
2.2. Estado del arte	16
2.3. Conclusiones del capítulo	25
3. Objetivos concretos y metodología de trabajo	27
3.1. Objetivo general	27
3.2. Objetivos específicos	27
3.3. Metodología del trabajo	28
4. Planteamiento de la comparativa	34
4.1. Identificación del problema y trabajo previo	34
4.2. Descripción del conjunto de datos	35
4.3. Modelos incluidos en la comparativa	39
4.4. Métricas de evaluación	43

4.5.	Protocolo de validación temporal	46
4.6.	Criterios de éxito	49
5.	Desarrollo de la comparativa	52
5.1.	Configuración del experimento ejecutado	52
5.2.	Resultados globales por modelo y métrica	52
5.3.	Análisis de estabilidad temporal	55
5.4.	Desagregación por deciles de volumen.....	61
5.5.	Comparativa visual de pronósticos	63
6.	Discusión y análisis de resultados	65
6.1.	Interpretación de la comparativa global	65
6.2.	Relación entre complejidad algorítmica y precisión	67
6.3.	Análisis de materialidad: deciles de volumen	70
6.4.	Estabilidad temporal y confiabilidad operacional	71
6.5.	Propuesta preliminar de criterios de selección de modelos	72
6.6.	Limitaciones del experimento	76
7.	Conclusiones y trabajo futuro	78
7.1.	Conclusiones.....	78
7.2.	Líneas de trabajo futuro	81
	Referencias bibliográficas	84
8.	Anexo A. Código fuente y datos analizados	87
8.1.	Estructura del repositorio	87
8.2.	Diagrama de arquitectura del pipeline.....	88
8.3.	Reproducibilidad	90

Índice de figuras

Figura 1. Esquema de validación walk-forward con ventana creciente (expanding window). Cada fila representa un fold; el área azul corresponde al conjunto de entrenamiento y el área roja al horizonte de evaluación de 18 meses.	48
Figura 2. Estabilidad temporal del sMAPE por modelo y fold walk-forward (modelos estadísticos locales; n = 173 series con historial completo de cinco folds).....	56
Figura 3. Contribución al error absoluto total por decil de volumen y modelo.	61
Figura 4. sMAPE medio por modelo (barras) con desviación estándar (barras de error). Orden ascendente de error.	63
Figura 5. Mapa de calor de métricas normalizado. Los valores se normalizan por columna en [0,1]; menor valor (verde) indica mejor rendimiento.	66
<i>Figura 6. Diagrama de decisión secuencial de la propuesta preliminar de criterios heurísticos de selección de modelos para FP&A. Propuesta no validada externamente.</i>	<i>75</i>
<i>Figura 7. Diagrama de flujo del pipeline de pronóstico para FP&A. Se distinguen cuatro bloques funcionales: adquisición y preprocesamiento de datos, generación del protocolo walk-forward, ajuste e inferencia de los siete modelos, y evaluación con las seis métricas. El cuaderno orquestador coordina la ejecución integrada de todos los módulos.</i>	<i>89</i>
<i>Figura 8. Salida de la ejecución de la suite de pruebas automatizadas (pytest), 20/20 superadas</i>	<i>91</i>

Índice de tablas

Tabla 1. Organización del trabajo en grupo: distribución de responsabilidades.	4
Tabla 2. Familias de modelos evaluados, ordenados por complejidad algorítmica creciente.	10
Tabla 3. Características de las series temporales financieras y sus implicaciones para el modelado.	14
Tabla 4. Familias de modelos de pronóstico: características, ventajas y limitaciones según la literatura.	16
Tabla 5. Resumen de estudios empíricos clave en predicción de series temporales.....	20
Tabla 6. Métricas de evaluación de pronóstico: categoría, problema que abordan y limitaciones de uso.....	22
Tabla 7. Métodos de validación temporal: limitaciones y solución que aporta el protocolo walk-forward.....	23
Tabla 8. Brechas identificadas en la literatura y respuesta metodológica del trabajo.	25
Tabla 9. Trazabilidad entre objetivos específicos, fases metodológicas, entregables y resultados.....	33
Tabla 10. Características del conjunto de datos M4 Financial Monthly utilizado en la comparativa.	35
Tabla 11. Comparación descriptiva entre la submuestra (N=200) y la población filtrada (N=8.493).	37
Tabla 12. Modelos incluidos en la comparativa: nivel de complejidad, implementación y justificación.	39
Tabla 13. Detalle de hiperparámetros e implementación de los modelos globales, con los valores efectivamente utilizados en la ejecución.....	41
Tabla 14. Métricas de evaluación adoptadas: categoría, nivel de análisis y rol en la comparativa.	44
Tabla 15. Parámetros del protocolo de backtesting walk-forward y su justificación.....	46

Tabla 16. Criterios de éxito de la comparativa: condiciones de superación del baseline y de diferenciación entre modelos.	50
Tabla 17. Métricas dependientes de escala.	53
Tabla 18. Métricas independientes de escala: sMAPE (%), MAPE (%) y MASE. Media $\pm$ desviación estándar sobre evaluaciones fold $\times$ serie. N = 200 series estratificadas, protocolo walk-forward expanding window, máximo 5 folds por serie.	54
Tabla 19. Métrica ponderada por magnitud (WAPE) y estabilidad temporal (CV-sMAPE). WAPE = error porcentual absoluto ponderado por volumen de serie.	54
Tabla 20. Coeficiente de variación (CV) temporal del sMAPE por modelo, calculado dentro de cada serie y promediado sobre la submuestra (n = 180 series con dos o más folds retenidos; se excluyen 20 series con un único fold).	56
Tabla 21. Evaluación frente a los criterios de éxito predefinidos en la Tabla 16. Referencia sMAPE Seasonal Naïve: 13,667 % (resultado experimental).....	57
Tabla 22. Intervalos de confianza bootstrap al 95 % para la diferencia de sMAPE respecto al Seasonal Naïve.	58
Tabla 23. Intervalos de confianza al 99,5 % (nivel ajustado por la corrección de Bonferroni, $\alpha = 0,05/10 = 0,005$) para las diez comparaciones pareadas evaluadas.	60
Tabla 24. Modelo con mejor rendimiento por métrica.....	60
Tabla 25. WAPE medio por modelo y decil de volumen.	62
Tabla 26. Cumplimiento de los criterios de éxito predefinidos.....	64
Tabla 27. Coste computacional de los siete modelos sobre el mismo fold, la misma muestra y el mismo entorno de ejecución.....	69
Tabla 28. Propuesta preliminar de criterios heurísticos de selección de modelos de pronóstico para FP&A, no validada externamente.	72
Tabla 29. Evidencia experimental y bibliográfica por regla del framework de selección.	73
Tabla 30. Grado de cumplimiento de los objetivos específicos: evidencia y limitaciones.	80

Resumen

La planificación y análisis financiero (FP&A) constituye una función estratégica central en las organizaciones, cuya efectividad depende de la capacidad de generar estimaciones precisas y confiables de variables económicas futuras. A pesar de su criticidad para el cierre contable, la detección temprana de desviaciones presupuestarias y la toma de decisiones directivas, la literatura documenta que la selección de modelos de pronóstico en este dominio se realiza frecuentemente bajo criterios heurísticos, sin una evaluación cuantitativa sistemática de su desempeño real.

El presente trabajo propone una evaluación comparativa de distintas familias de modelos de pronóstico aplicados a series temporales financieras mensuales, empleando un protocolo de backtesting temporal con ventanas de validación móviles (walk-forward). Se implementa un pipeline modular y diseñado para favorecer la reproducibilidad en Python que integra métodos estadísticos clásicos de referencia (Seasonal Naïve, ETS, Holt-Winters, SARIMA), un algoritmo de gradient boosting (LightGBM) y arquitecturas de aprendizaje profundo (MLP, N-BEATS). El desempeño se cuantifica mediante seis métricas principales —cinco de error estadístico (MAE, RMSE, MAPE, sMAPE, MASE) y una métrica ponderada por magnitud utilizada como aproximación a la materialidad financiera (WAPE)—, complementadas con un análisis de contribución al error absoluto por decil de volumen de serie.

ETS (AutoETS) obtiene el menor error en las seis métricas evaluadas, con un sMAPE medio del 10,0 % frente al 13,7 % del Seasonal Naïve (mejora de 3,7 puntos porcentuales; IC bootstrap al 95 %: [-4,52; -3,26] pp). Los métodos estadísticos clásicos obtienen el mejor rendimiento predictivo global bajo las condiciones experimentales del conjunto M4 Financial Monthly, aunque ninguno de los modelos alcanza el umbral aspiracional de estabilidad definido ($CV\text{-}sMAPE < 25\%$). Con base en estos hallazgos se formula una propuesta preliminar de criterios heurísticos de selección de modelos para entornos de FP&A mensuales, no validada externamente.

Palabras clave: backtesting temporal; FP&A; pronóstico de series temporales financieras; ETS; métricas de materialidad financiera.

Abstract

Financial Planning and Analysis (FP&A) is a strategic organizational function whose effectiveness depends on generating accurate and reliable forecasts of financial variables. Despite its criticality for monthly close cycles, budget deviation detection, and executive decision-making, model selection in this domain is frequently driven by heuristic criteria rather than systematic quantitative evaluation.

This study presents a comparative evaluation of forecast model families applied to monthly financial time series using a walk-forward temporal backtesting protocol. A modular Python pipeline, designed to facilitate reproducibility, integrates classical statistical methods (Seasonal Naïve, ETS, Holt-Winters, SARIMA), a gradient boosting algorithm (LightGBM), and deep learning architectures (MLP, N-BEATS). Performance is quantified using six main metrics—five statistical error metrics (MAE, RMSE, MAPE, sMAPE, MASE) and one magnitude-weighted metric used as a proxy for financial materiality (WAPE)—complemented by an absolute-error contribution analysis by volume decile. The experiment was conducted on a stratified subsample of 200 series from the M4 Financial Monthly dataset, applying up to five walk-forward folds per series (initial window: 54 months, forecast horizon: 18 months).

ETS achieved the lowest error across all six metrics (sMAPE = 10.0 % vs. 13.7 % for Seasonal Naïve), with all improvements statistically significant at the 95 % level (bootstrap percentile method, $B = 1,000$, $N = 200$ series; CI: [-4.52, -3.26] pp). Classical statistical methods achieved the best overall predictive performance under these experimental conditions, although none of the models met the predefined stability threshold ($CV\text{-}sMAPE < 25\%$). A preliminary three-rule set of heuristic criteria for model selection in FP&A environments is proposed and assessed for internal coherence with the experimental findings, without external validation against real organizational decisions.

Keywords: temporal backtesting; FP&A; financial time series forecasting; ETS; financial materiality metrics.

Organización del trabajo en grupo

El presente TFE aborda la problemática identificada en la introducción: la brecha entre la complejidad del dato financiero y la simplicidad de los métodos de pronóstico predominantes en FP&A. Para cerrar esta brecha, el trabajo se estructura en tres componentes técnicos diferenciados que, individualmente, constituyen aportes sustanciales al campo de la inteligencia artificial aplicada a las finanzas corporativas.

PARTES QUE ABORDA EL TRABAJO

Componente 1: Infraestructura de backtesting temporal. Garantiza que la comparación de modelos se realice bajo un protocolo de validación temporal estrictamente controlado, evitando la fuga de datos. Sus objetivos son: diseñar e implementar el motor de backtesting walk-forward con ventanas móviles, desarrollar el pipeline de preprocesamiento temporalmente consciente, implementar validaciones automatizadas de ausencia de fuga de información, y documentar las decisiones metodológicas críticas.

Entregables: módulo `src/backtesting.py` (motor walk-forward); `src/preprocessor.py` (pipeline temporalmente consciente); tests automatizados de ausencia de fuga de datos.

Componente 2: Comparativa experimental de familias de modelos. Implementa y evalúa modelos que representan cuatro niveles de complejidad algorítmica: baseline estadístico, machine learning, deep learning tabular y arquitecturas nativas de series temporales. Sus objetivos son: implementar modelos baseline (Naïve Estacional), modelos estadísticos clásicos (ETS, Holt-Winters, SARIMA), algoritmos de ML (LightGBM) y arquitecturas de deep learning (MLP, N-BEATS). Se diseña una interfaz común `BaseForecaster` para la integración uniforme de todos los modelos.

Entregables: siete implementaciones de modelos en `src/models/`; clase `BaseForecaster` con interfaz común; script de ejecución del experimento `run_experiment.py`.

Componente 3: Evaluación ponderada por magnitud. Complementa las métricas de error estadístico con indicadores ponderados por magnitud, analizando la relación entre el error predictivo, el volumen de las series y su posible materialidad para FP&A. Sus objetivos son: implementar métricas estadísticas estándar (MAE, RMSE, MAPE, sMAPE, MASE), diseñar métricas ponderadas por magnitud o proxies de materialidad (WAPE, contribución al error absoluto

por decil de volumen), desarrollar el análisis de estabilidad temporal del desempeño y proponer el framework de selección de modelos.

Entregables: módulo `src/evaluation.py` (seis métricas); figuras en `results/figures/`; tablas de resultados en `results/tables/`; repositorio diseñado para favorecer la reproducibilidad, con dependencias fijadas en `requirements.txt`.

DISTRIBUCIÓN Y ESTRUCTURA DE LA MEMORIA

Tabla 1. Organización del trabajo en grupo: distribución de responsabilidades.

Apartado de la memoria	Responsables	Entregable / evidencia
Introducción	Juan Camilo Rico Ballesteros	Capítulo de introducción de la memoria
Contexto y estado del arte	Juan José Blanco Mendoza	Capítulo de contexto y estado del arte
Objetivos y metodología de trabajo	José Manuel Machado Loaiza	Capítulo de objetivos y metodología
Arquitectura, preprocesamiento, backtesting	José Manuel Machado Loaiza	<code>src/backtesting.py</code> , <code>src/preprocessor.py</code> , <code>src/data_loader.py</code>
Módulos de modelos (baseline, estadístico, ML, DL)	Juan Camilo Rico Ballesteros	<code>src/models/</code> (<code>baseline.py</code> , <code>statistical.py</code> , <code>ml.py</code>)
Evaluación, métricas ponderadas por magnitud y visualización	Juan José Blanco Mendoza	<code>src/evaluation.py</code> , <code>src/visualization.py</code>
Diseño del experimento y configuración	José Manuel Machado Loaiza, Juan Camilo Rico Ballesteros	<code>src/config.py</code> , <code>run_experiment.py</code> , <code>notebooks/main.ipynb</code>
Resultados, estabilidad temporal, deciles	Juan José Blanco Mendoza	Capítulo de resultados; <code>results/tables/</code> y <code>results/figures/</code>

Análisis de errores y comparativa	Juan Camilo Rico Ballesteros	Capítulo de discusión (comparativa y análisis de errores)
Métricas de materialidad y ponderación por volumen	Juan José Blanco Mendoza	Capítulo de discusión (aproximación a la materialidad)
Conclusiones	Todos	Capítulo de conclusiones

Fuente: elaboración propia.

OBJETIVOS INDIVIDUALES POR INTEGRANTE

Juan Camilo Rico Ballesteros: implementar los módulos de modelos de pronóstico (baseline, estadísticos, ML y DL) con la interfaz común BaseForecaster; redactar la introducción del trabajo y desarrollar el análisis comparativo de errores entre arquitecturas.

Juan José Blanco Mendoza: diseñar e implementar el sistema de evaluación con métricas estadísticas y métricas ponderadas por magnitud utilizadas como aproximación a la materialidad financiera (WAPE, análisis por deciles de volumen) y sus visualizaciones; desarrollar el análisis de estabilidad temporal y redactar el capítulo de contexto y estado del arte.

José Manuel Machado Loaiza: diseñar e implementar la infraestructura de backtesting walk-forward y el pipeline de preprocesamiento; definir la metodología, el diseño del experimento y la configuración del pipeline diseñado para favorecer la reproducibilidad.

MECANISMOS DE COORDINACIÓN

Comunicación sincrónica: reuniones semanales los lunes (18:00–19:30, Google Meet) para revisar el progreso, resolver bloqueos y planificar la siguiente iteración; integración técnica quincenal los miércoles (19:00) para revisar las interfaces entre módulos.

Comunicación asincrónica: WhatsApp para comunicaciones urgentes; Word Online para la elaboración colaborativa de la memoria con seguimiento de cambios; OneDrive para la gestión de versiones del documento.

Documentación y código: la memoria se elaboró colaborativamente mediante Word Online y su historial de versiones se gestionó en OneDrive. El código fuente y los resultados del experimento se gestionan en un repositorio público de GitHub diseñado para favorecer la reproducibilidad, con tablero Kanban en GitHub Projects.

La distribución de responsabilidades y los mecanismos de coordinación descritos fueron acordados por los integrantes del grupo y revisados y avalados por la directora del trabajo, Dra. Marta María Arguedas Lafuente.

La revisión cruzada del trabajo se organizó según la responsabilidad técnica declarada en la Tabla 1: Juan Camilo Rico Ballesteros revisó la implementación de los modelos de pronóstico y el análisis comparativo de errores entre arquitecturas; Juan José Blanco Mendoza verificó el sistema de evaluación, las métricas ponderadas por magnitud o proxies de materialidad (WAPE, deciles de volumen) y el análisis de estabilidad temporal; José Manuel Machado Loaiza integró la versión final del documento, coordinó el diseño para favorecer la reproducibilidad del pipeline de backtesting walk-forward y consolidó las correcciones metodológicas solicitadas por la directora. Las discrepancias de redacción o de interpretación surgidas durante la integración se resolvieron por consenso en las reuniones de coordinación semanal, utilizando la evidencia experimental (resultados en results/tables/ y results/figures/) como criterio de desempate.

1. INTRODUCCIÓN

En el dinámico entorno empresarial actual, la Planificación y Análisis Financiero (FP&A) se ha consolidado como una de las funciones estratégicas centrales de las organizaciones, dado que la capacidad de anticipar valores futuros resulta crítica para el cierre contable y la toma de decisiones directivas. Sin embargo, los métodos tradicionales de pronóstico pueden presentar limitaciones ante determinadas no linealidades o cambios estructurales en las series temporales financieras, aunque su rendimiento debe evaluarse empíricamente frente a alternativas más complejas (Hyndman y Athanasopoulos, 2021).

Este trabajo aborda dicha problemática mediante la construcción de un *pipeline* de pronóstico modular que permite comparar arquitecturas clásicas con modelos de aprendizaje automático y aprendizaje profundo en condiciones metodológicamente rigurosas. El rigor de esta evaluación se fundamenta en un esquema de backtesting temporal de ventanas móviles (*walk-forward*), metodología esencial para garantizar la validez del modelo en condiciones reales y evitar la fuga de información o *data leakage* en contextos financieros (Bergmeir y Benítez, 2012).

El núcleo diferencial de esta investigación reside en complementar la evaluación del error estadístico con un análisis de su materialidad relativa. Además de las métricas tradicionales de precisión —MAE, RMSE, SMAPE y MASE—, el estudio incorpora métricas ponderadas por magnitud, como el WAPE y la contribución al error absoluto por volumen, con el propósito de aproximar la relevancia relativa de los errores en función de la magnitud de las observaciones, sin que ello implique la cuantificación directa de un impacto económico real (Makridakis et al., 2025).

1.1. MOTIVACIÓN

La Planificación y Análisis Financiero (FP&A) constituye una función central para la continuidad operativa y la planificación de las organizaciones. El problema central que aborda el presente trabajo es que la selección de modelos de pronóstico en FP&A se realiza frecuentemente sin evidencia comparativa suficiente que permita determinar qué grado de complejidad algorítmica resulta adecuado para cada contexto, una actividad que, a pesar de su criticidad, carece con frecuencia de un respaldo empírico riguroso.

El problema identificado reside en la desconexión existente entre la naturaleza de las series temporales financieras y las herramientas utilizadas para su proyección. Mientras que los datos financieros modernos exhiben comportamientos no lineales, estacionalidades heterogéneas y una alta sensibilidad a variables externas, la práctica común en FP&A suele basarse en criterios heurísticos o juicios subjetivos del analista. Esta dependencia de la “intuición experta” no solo limita la escalabilidad de los procesos, sino que introduce sesgos cognitivos que restan fiabilidad a las estimaciones (Armstrong, 2001).

Existen diferentes causas de este problema. En primer lugar, la elección entre modelos de suavizado exponencial, promedios móviles o arquitecturas más complejas rara vez se apoya en una comparación empírica bajo el mismo protocolo de validación, lo que impide saber a priori qué familia de modelos ofrece el mejor equilibrio entre precisión y estabilidad para un contexto dado (Hyndman y Athanasopoulos, 2021). En segundo lugar, la implementación de técnicas de aprendizaje automático en este dominio se ha visto frenada por la ausencia de protocolos de evaluación adecuados: la aplicación de validaciones cruzadas estándar (K-Fold) en series de tiempo es una causa recurrente de resultados espurios debido a la fuga de información, lo que genera una falsa confianza en modelos que luego fracasan en el entorno real (Bergmeir y Benítez, 2012).

La importancia de este estudio radica en la propuesta de un marco de evaluación que va más allá del error estadístico puro. Resulta necesario establecer *benchmarks* comparativos entre familias de modelos bajo condiciones de backtesting temporal riguroso. Este trabajo aporta un ejemplo aplicado de cómo la ciencia de datos debe integrarse en la gestión empresarial: no como un fin en sí mismo, sino como una herramienta de optimización de recursos.

La relevancia del problema es, en última instancia, económica. La incapacidad de prever con exactitud el flujo de caja o los ingresos se traduce en una gestión ineficiente del capital de trabajo. Un pronóstico impreciso obliga a las empresas a mantener reservas de liquidez improductivas o a incurrir en costes financieros elevados para cubrir déficits imprevistos. Al mostrar que una mayor precisión técnica puede contribuir potencialmente a reducir desviaciones presupuestarias, este trabajo justifica la transición hacia una Planificación Financiera más rigurosa, proporcionando una base cuantitativa para la toma de decisiones que afecta directamente la competitividad y estabilidad de la organización (Fildes et al., 2022).

1.2. PLANTEAMIENTO DEL TRABAJO

El núcleo problemático de este TFE se define como la selección de modelos de pronóstico en FP&A sin evidencia comparativa suficiente que permita determinar qué grado de complejidad algorítmica resulta adecuado para cada contexto. Las series temporales de FP&A (ingresos, flujo de caja, gastos operativos) exhiben comportamientos no lineales, estacionalidades heterogéneas y alta sensibilidad a perturbaciones externas, mientras que las organizaciones siguen apoyándose principalmente en modelos lineales y heurísticas manuales (Hyndman y Athanassopoulos, 2021), sin que exista necesariamente una comparación sistemática que respalde esa elección o que descarte alternativas más simples.

Esta brecha no es un problema meramente académico; es un problema metodológico de fondo. Utilizar un método inadecuado para la complejidad real de los datos —ya sea por simplicidad excesiva o por sofisticación injustificada— puede derivar en proyecciones poco fiables ante cambios de régimen. Esta formulación es coherente con el resultado final de este trabajo: los modelos estadísticos clásicos pueden superar a las arquitecturas de aprendizaje automático y profundo cuando las condiciones del conjunto de datos y del entrenamiento así lo favorecen, lo que subraya la necesidad de evidencia empírica y no de supuestos a priori sobre qué grado de complejidad es preferible.

La intervención propuesta no busca la complejidad por la complejidad, sino la adecuación del método a la naturaleza del dato. Se plantea el desarrollo de un *pipeline* de software modular que actúe como laboratorio de pruebas para determinar qué nivel de inteligencia algorítmica es necesario para cerrar la brecha en términos cuantificables. El trabajo propone una comparativa experimental de familias de modelos categorizadas por su complejidad algorítmica creciente, tal como muestra la Tabla 2.

Tabla 2. Familias de modelos evaluados, ordenados por complejidad algorítmica creciente.

Nivel	Modelos	Capacidad característica
Baseline estadístico	Seasonal Naïve	Referencia mínima: repite el patrón estacional del año anterior

Estadístico clásico	ETS, Holt-Winters, SARIMA	Captura tendencia y estacionalidad; parsimonia paramétrica
Machine Learning	LightGBM	Relaciones no lineales mediante gradient boosting global
Deep Learning	MLP, N-BEATS	Patrones complejos; N-BEATS con descomposición tendencia/estacionalidad

Fuente: elaboración propia.

La finalidad del trabajo es demostrar, mediante un protocolo de backtesting temporal estrictamente controlado, cuál de estas familias ofrece el mejor desempeño bajo las condiciones experimentales definidas para un contexto aproximado de FP&A. La arquitectura de software desarrollada no solo comparará errores técnicos (sMAPE, MASE), sino que integrará métricas ponderadas por magnitud que permitan aproximar la materialidad relativa del error.

1.3. ESTRUCTURA DEL TRABAJO

Para abordar de manera sistemática el problema de la brecha metodológica en el entorno de FP&A, la presente memoria se estructura en siete capítulos principales, siguiendo la organización de una comparativa de soluciones:

- **Capítulo 1 (presente).** Introducción, motivación y planteamiento del problema.
- **Capítulo 2. Contexto y estado del arte.** Análisis del entorno operativo de FP&A y revisión crítica de la literatura sobre familias de modelos de pronóstico, métodos de validación temporal y métricas de evaluación.
- **Capítulo 3. Objetivos concretos y metodología de trabajo.** Objetivo general y objetivos específicos SMART, y descripción de las seis fases de ejecución del proyecto.
- **Capítulo 4. Planteamiento de la comparativa.** Descripción del diseño experimental: dataset, modelos seleccionados, métricas adoptadas, protocolo walk-forward y criterios de éxito.

- **Capítulo 5. Desarrollo de la comparativa.** Resultados cuantitativos del experimento: tabla modelo $\times$ métrica con media y desviación estándar sobre los folds walk-forward, análisis de estabilidad temporal y desagregación por deciles de volumen.
- **Capítulo 6. Discusión y análisis de resultados.** Interpretación crítica de los resultados, análisis de ventajas y limitaciones de cada familia de modelos, y propuesta del *framework* de criterios heurísticos preliminares de selección.
- **Capítulo 7. Conclusiones y trabajo futuro.** Síntesis de hallazgos por objetivo específico, grado de cumplimiento, limitaciones del estudio y líneas de investigación futura.

El Anexo A incluye el acceso al repositorio con el código fuente modular desarrollado en Python y la documentación técnica necesaria para favorecer la reproducibilidad de los experimentos.

2. CONTEXTO Y ESTADO DEL ARTE

El presente capítulo sitúa el problema de investigación en su contexto operativo y teórico. En una primera parte se describe el entorno de la Planificación y Análisis Financiero (FP&A) como función estratégica, las características que hacen especialmente difícil modelizar sus series temporales y la brecha metodológica que persiste en la práctica. En una segunda parte se revisa la evolución de los enfoques de pronóstico documentada en la literatura académica, desde los métodos estadísticos clásicos hasta los modelos fundacionales de última generación, con especial atención a las conclusiones que los propios autores extraen sobre las condiciones en que cada familia resulta más o menos adecuada. El capítulo cierra con una síntesis de las brechas identificadas que motivan directamente la contribución de este trabajo.

2.1.CONTEXTO DEL PROBLEMA

La Planificación y Análisis Financiero (FP&A) es, en esencia, la función que traduce los objetivos estratégicos de una organización en planes financieros cuantificables y proporciona los análisis que orientan las decisiones ejecutivas (Armstrong, 2001). En la práctica corporativa, esto se materializa en ciclos recurrentes de estimación, seguimiento y revisión, abarcando proyecciones de cuentas operativas, ingresos y flujo de caja. No obstante, dado el carácter estrictamente confidencial de la contabilidad interna de las empresas, la investigación académica suele recurrir a bases de datos de dominio público. En este estudio, se emplean las series de la categoría financiera del benchmark M4, reconociendo desde el inicio que estas actúan como un proxy metodológico y no como un equivalente exacto de las cuentas de pérdidas y ganancias (P&L) corporativas.

A pesar de esta divergencia en el origen de los datos, el desafío subyacente es el mismo: las consecuencias del error predictivo son directas y medibles. Desde la perspectiva de la gestión de tesorería corporativa, un pronóstico a la baja puede derivar en la necesidad de recurrir a líneas de crédito para cubrir obligaciones a corto plazo, mientras que una sobreestimación inmoviliza capital en reservas improductivas; en ambos casos, la imprecisión trasciende el ámbito técnico para convertirse en un riesgo económico, subestimando la eficiencia del capital circulante (Petropoulos et al., 2022).

Tanto las series financieras del mercado como las corporativas presentan un conjunto de propiedades que complican significativamente su modelización predictiva. La Tabla 3 sintetiza estas características, sus implicaciones para el modelado y la literatura que las respalda.

Tabla 3. Características de las series temporales financieras y sus implicaciones para el modelado.

Característica	Descripción	Implicación para el modelado
Estacionalidad heterogénea	Distintas series exhiben patrones estacionales propios y variaciones de ciclo temporal.	Un único modelo difícilmente funciona de forma homogénea en todas las series (Hyndman y Athanasopoulos, 2021).
No-estacionariedad y cambios estructurales	Adquisiciones, shocks macroeconómicos o cambios regulatorios generan rupturas abruptas en las dinámicas históricas.	Los parámetros estimados antes del cambio pueden resultar inválidos
Dependencias no lineales	Ajustes retroactivos y eventos extraordinarios de alta volatilidad coexisten en la misma serie.	Los métodos paramétricos estándar pueden presentar limitaciones para capturar determinadas relaciones no lineales sin extensiones o transformaciones adicionales (Hyndman y Athanasopoulos, 2021)
Ruido y valores atípicos	Errores de registro, ajustes contables retroactivos y eventos extraordinarios coexisten en la misma serie.	Los modelos deben mostrar robustez sin perder sensibilidad

		dad a los cambios estructurales reales (Petropoulos et al., 2022).
Longitud de la serie (Real vs. Experimental)	En el entorno corporativo real de FP&A, el historial continuo raramente supera 4–5 años. En contraste, el <i>benchmark</i> M4 ofrece un entorno experimental extendido (mediana de 175 meses).	En la práctica empresarial, la falta de datos limita los algoritmos complejos (Cerqueira et al., 2022); sin embargo, el uso del <i>dataset</i> M4 en este estudio permite evaluar su desempeño bajo un protocolo de validación riguroso.

Fuente: elaboración propia a partir de Hyndman y Athanasopoulos (2021), Cerqueira et al. (2020) y Petropoulos et al. (2022).

Frente a estas dificultades, la práctica habitual en FP&A tiende a adoptar enfoques conservadores. Como documentó Armstrong (2001), la elección de los métodos de pronóstico suele basarse más en la costumbre o en la aparente simplicidad del método que en una verdadera evaluación empírica de su desempeño. Es frecuente encontrar organizaciones que siguen utilizando promedios móviles que ignoran las tendencias subyacentes, proyecciones lineales que asumen escenarios constantes, o simplemente el juicio del analista como recurso principal cuando los modelos cuantitativos no ofrecen una respuesta satisfactoria.

Esta desconexión tiene un coste que rara vez se cuantifica con rigor metodológico. Cuando no existe un protocolo de backtesting adecuado, resulta prácticamente imposible medir cuál es el coste real de no adoptar modelos más sofisticados. Por su parte, Bergmeir y Benítez (2012) demostraron que aplicar una validación cruzada estándar a series temporales invalida los supuestos de independencia entre observaciones de entrenamiento y evaluación, produciendo estimaciones de desempeño sistemáticamente más optimistas que los resultados reales en producción, lo que introduce una falsa confianza que refuerza el *statu quo* metodológico. Esta brecha no es únicamente un problema de acceso a tecnología: es, en gran medida, un problema de ausencia de marcos de evaluación que hagan visible el coste de la imprecisión.

2.2. ESTADO DEL ARTE

La revisión bibliográfica estructurada que se presenta a continuación no pretende ser un catálogo exhaustivo de técnicas, sino una lectura crítica de lo que la literatura académica ha concluido sobre cuándo, cómo y bajo qué condiciones cada familia de modelos aporta valor real en contextos de predicción de series temporales. El recorrido sigue un eje de complejidad creciente, desde los métodos estadísticos clásicos hasta los modelos fundacionales preentrenados, con especial atención a los hallazgos de los grandes *benchmarks* comparativos. La Tabla 4 ofrece una visión consolidada de estas familias.

Tabla 4. Familias de modelos de pronóstico: características, ventajas y limitaciones según la literatura.

Familia	Modelos representativos	Ventajas	Limitaciones
Estadístico clásico	ETS, Holt-Winters, SARIMA	Parsimonia paramétrica; robusto con series cortas; frecuentemente supera a modelos complejos en benchmarks con patrones regulares (Makridakis et al., 2022)	Puede presentar limitaciones ante determinadas relaciones no lineales y cambios estructurales, dependiendo de la especificación y de las transformaciones aplicadas (Hyndman y Athanasopoulos, 2021)
Machine Learning	LightGBM, XGBoost	Captura relaciones no lineales; escalable a múltiples series con feature engineering adecuado (Januschowski et al., 2020)	En enfoques locales, el rendimiento puede verse limitado cuando las series contienen pocas observaciones; esta restricción puede

			mitigarse mediante aprendizaje global sobre múltiples series. Su desempeño también depende del <i>feature engineering</i> (Cerqueira et al., 2022).
Deep Learning tabular	MLP	Modelado de dinámicas complejas sin feature engineering manual; direct forecasting multi-horizonte	Costoso computacionalmente; requiere grandes volúmenes de datos (Lim y Zohren, 2021)
Deep Learning temporal	N-BEATS	Descomposición explícita tendencia/estacionalidad; interpretabilidad estructural; direct forecasting	Mayor complejidad de implementación; requiere volumen de datos suficiente (Oreshkin et al., 2020)
Modelo fundacional	Chronos, FinCast	Transfer learning desde corpus masivos; capacidad zero-shot (Ansari et al., 2024)	Los datos financieros corporativos requieren fine-tuning específico; sensibles a cambios de régimen (Rahimikia et al., 2025)

Fuente: elaboración propia a partir de Hyndman y Athanasopoulos (2021), Januschowski et al. (2020), Lim y Zohren (2021), Ansari et al. (2024) y Rahimikia et al. (2025).

Los métodos de suavizamiento exponencial son el punto de partida más natural para entender cómo se extrae señal de una serie temporal. Su lógica es conceptualmente sencilla: asignar pesos decrecientes a las observaciones pasadas, de modo que los datos más recientes influyan más sobre el pronóstico que los más antiguos. A partir de esta idea básica, el método de Holt incorpora la tendencia lineal y Holt-Winters añade la estacionalidad, conformando una familia que logra representar fenómenos temporales complejos con muy pocos parámetros. Esta parsimonia es, al mismo tiempo, su mayor virtud y su principal limitación: facilita la calibración y la interpretación, pero impone una estructura que no puede capturar las interacciones más complejas de los datos financieros (Hyndman y Athanasopoulos, 2021). Los modelos ARIMA, sistematizados por Box y Jenkins, combinan una componente autorregresiva, un proceso de integración para estabilizar la media y una componente de media móvil; su extensión estacional SARIMA incorpora ciclos recurrentes.

Un hallazgo que la literatura ha consolidado con fuerza en los últimos años es que la simplicidad de estos métodos no equivale a inferioridad en todos los contextos. Makridakis et al. (2022), en el análisis de la competición M5, encontraron que los métodos estadísticos clásicos superaron a muchos algoritmos de *machine learning* en series cortas o con patrones regulares. Este resultado obliga a revisar la narrativa simplista de que “más complejo siempre es mejor”. No obstante, la extrapolación de estos hallazgos debe interpretarse con suma cautela: el *benchmark* M5 está centrado exclusivamente en ventas diarias de *retail* con dinámicas intermitentes e información jerárquica, características que difieren radicalmente de las series financieras corporativas mensuales propias de FP&A, por lo que su transferibilidad directa no puede darse por garantizada.

En el terreno del *machine learning*, los algoritmos de *gradient boosting* —LightGBM y XGBoost— demostraron ser capaces de competir con los métodos estadísticos tradicionales en competencias de gran escala (Januschowski et al., 2020). La clave para lograrlo reside en un trabajo previo cuidadoso de *feature engineering*: diseñar rezagos de la variable objetivo, ventanas estadísticas móviles e indicadores de calendario. Sin embargo, Cerqueira et al. (2022) documentaron que el desempeño de estos algoritmos depende de manera crítica de la cantidad de datos disponibles: cuando la longitud individual de la serie es corta (menos de aproximadamente 500 observaciones) y no existe un número suficiente de series adicionales

para el aprendizaje global, los métodos estadísticos clásicos tienden a superarlos. Esta limitación es propia del aprendizaje local serie a serie; un modelo global entrenado sobre muchas series de longitud individual corta puede no estar sujeto a la misma restricción, ya que compensa la brevedad de cada serie con el volumen total de observaciones disponibles.

El salto hacia el *deep learning* estuvo protagonizado inicialmente por las arquitecturas recurrentes —LSTM y GRU—, que superaron las limitaciones de las redes tradicionales mediante sistemas de compuertas capaces de retener información relevante a lo largo de secuencias largas (Lim y Zohren, 2021). Las arquitecturas basadas en transformers orientadas a secuencias largas, como Informer (Zhou et al., 2021), han mostrado resultados prometedores en horizontes extensos, aunque su ventaja se diluye en series mensuales de longitud moderada. Entre las propuestas de *deep learning* nativo para series temporales, N-BEATS (Oreshkin et al., 2020) merece atención especial: su arquitectura de bloques residuales descompone explícitamente la señal en componentes de tendencia y estacionalidad, lo que aporta interpretabilidad estructural alineada con las necesidades de FP&A.

La frontera más reciente del campo corresponde a los modelos fundacionales, que trasladan al dominio de las series temporales la misma intuición que transformó el procesamiento del lenguaje natural: preentrenar una arquitectura de gran escala sobre un corpus masivo y diverso. Chronos (Ansari et al., 2024) es un ejemplo paradigmático. Sin embargo, Rahimikia et al. (2025) concluyen en su evaluación comprehensiva que los modelos fundacionales genéricos obtienen un rendimiento deficiente en modo *zero-shot* con datos financieros, y que solo los modelos preentrenados específicamente en datos financieros —como FinCast (Zhu et al., 2025)— logran mejoras sustanciales. Esta limitación es coherente con las propiedades de las series financieras descritas en la Tabla 3: la no-estacionariedad, la alta dimensionalidad y los cambios de régimen frecuentes no están bien representados en los corpus de preentrenamiento genéricos. Cabe subrayar que Chronos y FinCast no forman parte de la comparativa desarrollada en este trabajo; se mencionan exclusivamente como referencia de la frontera actual del campo.

Para sintetizar la evidencia empírica que fundamenta las decisiones metodológicas de este estudio, la Tabla 5 presenta un resumen estructurado de las investigaciones clave, evidenciando las limitaciones que motivan el diseño de un *framework* específico para FP&A.

Tabla 5. Resumen de estudios empíricos clave en predicción de series temporales.

Estudio	Dataset y Tamaño	Frecuencia	Método / Modelo Principal	Métrica Principal	Resultado Destacado	Limitación para contexto FP&A
Ma-kridakis et al. (2022)	Competición M5 (42.840 series)	Dia-ria	LightGBM (Gradient Boosting)	WRMSSE	LightGBM obtuvo el mejor resultado de la competición, aprovechando cross-learning y factores exógenos.	Enfocado en ventas de retail de alta frecuencia; dinámicas no equivalentes a contabilidad mensual.
Cer-queira et al. (2022)	M3, NN5, y 90 bases públicas (>90k series)	Múl-tiple	Machine Learning vs. Es-tadísticos	sMAPE, MASE	Los métodos clásicos superan a ML cuando la longitud individual de la serie es corta y no se compensa con aprendizaje global.	Datasets excesivamente ge-néricos, sin enfoque en propie-dades de series financieras (ruido, rupturas).
Oreshkin et al. (2020)	Competición M4 (100.000 series)	Múl-tiple	N-BEATS (Deep Learning)	sMAPE, OWA	Arquitectura de aprendi-zaje profundo que superó un benchmark estadístico y al modelo híbrido ganador de la competición M4; su configu-ración interpretable permite representar componentes de tendencia y estacionalidad.	Requiere recursos compu-tacionales considerables; rendi-miento no probado en series aisladas cortas.

Ansari et al. (2024)	Corpus masivo genérico de series de código abierto	Múltiple	Chronos (Modelo Fundamental)	WAPE, MASE	Capacidad zero-shot altamente competitiva en series de dominios variados.	Arquitectura rígida frente a covariables corporativas; alto costo de inferencia.
Rahimikia et al. (2025) / Zhu et al. (2025)	Datos de mercados financieros	Múltiple	Modelos Fundacionales Financieros (FinCast)	Varios	El modo zero-shot obtiene resultados deficientes en finanzas puras; el fine-tuning específico resulta determinante para aportar valor, según ese estudio.	Modelos en fase incipiente; sensibilidad extrema a los cambios de régimen contable.

Fuente: elaboración propia.

La dimensión metodológica de la evaluación merece un apartado propio, porque su correcta aplicación condiciona la validez de cualquier conclusión sobre qué modelo es preferible. La Tabla 6 presenta la taxonomía de métricas adoptadas en este trabajo.

Tabla 6. Métricas de evaluación de pronóstico: categoría, problema que abordan y limitaciones de uso.

Métrica	Categoría	Problema que aborda	Limitación o consideración
MAE / RMSE	Dependiente de escala	Intuitividad; unidades originales	Impide comparar series de distinta magnitud; RMSE penaliza errores grandes (Petrooulos et al., 2022)
MAPE	Porcentual	Comprensión intuitiva	Asimétrico; indefinido ante valores reales cercanos a cero (Petrooulos et al., 2022)
sMAPE	Porcentual simétrica	Corrige la asimetría del MAPE; acotada en [0, 200]	Sigue siendo problemática ante valores cercanos a cero (Hyndman y Athanopoulos, 2021)
MASE	Error escalado	Comparación robusta entre series; referencia contra naïve estacional	Requiere definir correctamente el modelo de referencia (Hyndman y Athanopoulos, 2021)

WAPE	Ponderación por magnitud (proxy de materialidad)	Pondera errores según volumen financiero	Puede enmascarar errores en cuentas pequeñas si el volumen está dominado por pocas líneas (Makridakis et al., 2022)
Contribución al error	Ponderación por magnitud, desagregada	Desglosa el error por grupo de volumen; identifica qué grupos de series presentan una mayor contribución al error absoluto.	Requiere agrupación estable de series (Makridakis et al., 2022)

Fuente: elaboración propia a partir de Petropoulos et al. (2022), Hyndman y Athanasopoulos (2021) y Makridakis et al. (2022).

Más allá de esta taxonomía estadística, Makridakis et al. (2025) señalan una desconexión crítica: minimizar cualquiera de estas métricas matemáticas no garantiza maximizar el valor para el negocio. Dos pronósticos pueden tener exactamente el mismo sMAPE, pero su mayor contribución al error absoluto puede ser radicalmente distinta si los errores de uno se concentran en las cuentas de mayor volumen. Esta realidad hace necesario incorporar métricas ponderadas por magnitud —como el WAPE— que permitan identificar los segmentos con mayor contribución relativa al error absoluto.

Finalmente, el protocolo de validación temporal condiciona directamente la validez de cualquier conclusión comparativa. Bergmeir y Benítez (2012) analizaron las condiciones bajo las cuales la validación cruzada puede utilizarse en series temporales y destacaron la necesidad de preservar adecuadamente la estructura temporal y la dependencia de los datos. La Tabla 7 resume los problemas de los principales esquemas de validación.

Tabla 7. Métodos de validación temporal: limitaciones y solución que aporta el protocolo walk-forward.

Método	Problema que presenta	Por qué walk-forward lo resuelve
K-Fold estándar	Contaminación temporal: el modelo entrena con datos del futuro para predecir el pasado	Walk-forward garantiza que cada pronóstico usa únicamente la información disponible en ese momento (Bergmeir y Benítez, 2012)
Hold-out simple	Evalúa el modelo en un único período sin considerar la variabilidad del desempeño en el tiempo	Las ventanas móviles generan múltiples iteraciones de evaluación; permiten analizar la estabilidad temporal (Bergmeir y Benítez, 2012)
Validación cruzada sin control temporal	Estimaciones sistemáticamente más optimistas que los resultados reales (Bergmeir y Benítez, 2012)	El esquema walk-forward preserva el orden temporal y reduce el riesgo de contaminación entre entrenamiento y evaluación, proporcionando estimaciones basadas en múltiples orígenes de pronóstico.
Expanding window	Acumula todo el historial; puede otorgar excesivo peso a patrones históricos lejanos	Configuración predeterminada en este trabajo dado que las series no presentan cambios de régimen conocidos (Hyndman y Athanasopoulos, 2021)

Fuente: elaboración propia a partir de Bergmeir y Benítez (2012) y Hyndman y Athanasopoulos (2021).

2.3.CONCLUSIONES DEL CAPÍTULO

El recorrido por el contexto operativo y la literatura académica permite extraer tres conclusiones que orientan directamente el diseño del presente trabajo.

La primera es que la complejidad del modelo debe ser proporcional a la de los datos. No existe una arquitectura universalmente superior: los métodos estadísticos clásicos superan frecuentemente al *machine learning* en series cortas con patrones regulares (Makridakis et al., 2022; Cerqueira et al., 2022), mientras que las arquitecturas de aprendizaje profundo pueden demostrar ventajas en contextos de alta heterogeneidad. Esta contingencia implica que la selección del modelo no puede basarse en la reputación del algoritmo, sino en una evaluación empírica sobre las características concretas de la serie.

La segunda conclusión es que la validación temporal estricta es innegociable. Bergmeir y Benítez (2012) lo demostraron empíricamente: cualquier esquema que no respete la causalidad temporal produce estimaciones artificialmente optimistas que se traducen en decisiones de selección de modelos que luego fracasan en producción.

La tercera conclusión es que las métricas estadísticas pueden complementarse con indicadores ponderados por magnitud que permitan aproximar la materialidad relativa del error. Una mejora en el error estadístico no equivale automáticamente a la generación de valor económico para la organización (Armstrong, 2001; Makridakis et al., 2025). Por ello, las métricas de precisión pueden complementarse con indicadores ponderados por magnitud que permitan aproximar la materialidad relativa del error, sin cuantificar directamente un beneficio económico real.

De esta revisión se desprenden tres brechas que motivan la investigación y articulan los objetivos específicos del trabajo, sintetizadas en la Tabla 8.

Tabla 8. Brechas identificadas en la literatura y respuesta metodológica del trabajo.

Brecha identificada	Evidencia bibliográfica	Respuesta del TFE
Escasez de estudios con series financieras corporativas	Benchmarks disponibles construidos principalmente sobre datos	Aproximación experimental mediante un benchmark financiero mensual, como paso previo a la validación con

	de retail, energía o tráfico (Makridakis et al., 2022)	datos corporativos reales, con lo que cubrimos parcialmente esta brecha
Ausencia de marcos de evaluación orientados al valor en FP&A	Minimizar el error estadístico no garantiza maximizar el valor para el negocio (Armstrong, 2001; Makridakis et al., 2025)	Incorporación de WAPE y análisis de contribución al error absoluto por decil de volumen; brecha cubierta parcialmente, pendiente de validación sobre cuentas corporativas homogéneas y métricas económicas reales.
Falta de criterios objetivos para la selección de modelos en FP&A	Quienes deciden en FP&A carecen de guías cuantitativas para determinar cuándo la mayor sofisticación se justifica	Propuesta preliminar de tres reglas heurísticas derivadas de los resultados del experimento, sin validación externa. Por lo tanto, esta brecha quedó parcialmente cubierta.

Fuente: elaboración propia a partir de Armstrong (2001), Makridakis et al. (2022, 2025) y Cerqueira et al. (2022).

Son precisamente estas tres brechas las que articulan los objetivos específicos del trabajo y justifican el diseño metodológico descrito en el capítulo siguiente.

3. OBJETIVOS CONCRETOS Y METODOLOGÍA DE TRABAJO

El presente capítulo expone el objetivo general del trabajo, los objetivos específicos que lo articulan y la metodología que guiará su ejecución. Los tres componentes se han formulado teniendo en cuenta la naturaleza del problema identificado, el tipo de trabajo correspondiente a una comparativa de soluciones y el horizonte temporal disponible para su desarrollo.

3.1.OBJETIVO GENERAL

Comparar siete modelos de pronóstico sobre 200 series de la categoría Financial Monthly del conjunto M4 mediante backtesting walk-forward y métricas estadísticas y ponderadas por volumen, durante el periodo de desarrollo y validación del TFE, para identificar qué familia ofrece el mejor rendimiento bajo las condiciones experimentales definidas y formular una propuesta preliminar de criterios heurísticos de selección aplicable a la práctica de FP&A.

Este objetivo satisface los criterios SMART definidos por Doran (1981): es **específico**, al delimitar con precisión qué se compara, en qué contexto y bajo qué condiciones metodológicas; es **medible**, dado que el éxito se evalúa a través de métricas cuantitativas de precisión estadística y aproximación a la materialidad; es **alcanzable**, pues el alcance de modelos y el diseño del *pipeline* se ajustan a los recursos y al tiempo disponibles; es **relevante**, por cuanto responde a una necesidad documentada en la práctica de FP&A (Armstrong, 2001; Hyndman y Athanasopoulos, 2021); y está **acotado temporalmente**, dentro del marco de entrega establecido por el programa.

3.2.OBJETIVOS ESPECÍFICOS

Los siguientes objetivos específicos desglosan el objetivo general en tareas delimitadas y verificables, organizadas según la secuencia de ejecución del trabajo:

- **OE1.** Revisar y sintetizar el estado del arte sobre métodos de pronóstico aplicados a series temporales financieras, mediante una revisión bibliográfica estructurada en bases de datos académicas indexadas. La revisión identificará las arquitecturas más representativas, sus fundamentos teóricos, sus limitaciones documentadas y las métricas de evaluación más pertinentes para entornos de FP&A.

- **OE2.** Diseñar e implementar un *pipeline* de pronóstico modular, diseñado para favorecer la reproducibilidad y documentado en Python, que integre al menos cuatro familias de modelos: baseline estadístico (Seasonal Naïve), métodos estadísticos clásicos (ETS, Holt-Winters, SARIMA), algoritmos de aprendizaje automático basados en *gradient boosting* (LightGBM) y arquitecturas de aprendizaje profundo (MLP, N-BEATS).
- **OE3.** Aplicar un protocolo de backtesting temporal con ventanas de validación móviles (*walk-forward*) que garantice la separación estricta entre los conjuntos de entrenamiento y evaluación en cada iteración, preservando el orden causal de las observaciones y eliminando el riesgo de fuga de información entre particiones (Bergmeir y Benítez, 2012).
- **OE4.** Evaluar y comparar el desempeño de los modelos utilizando métricas de error estadístico (MAE, RMSE, MAPE, sMAPE, MASE) y métricas ponderadas por magnitud utilizadas como aproximación a la materialidad financiera (WAPE). Asimismo, realizar un análisis complementario de la contribución al error absoluto ponderado por deciles de volumen, para examinar el rendimiento tanto a nivel global como desagregado.
- **OE5.** Formular un conjunto preliminar de criterios heurísticos de selección de modelos aplicable a FP&A, fundamentado en los resultados del backtesting, y someterlo a validación de coherencia mediante los criterios experimentales definidos de precisión estadística, aproximación a la materialidad y estabilidad temporal.

3.3.METODOLOGÍA DEL TRABAJO

Para alcanzar los objetivos definidos, el trabajo se articuló en seis fases con solapamiento controlado entre ellas. La descripción que sigue presenta cada fase tal y como fue planificada; los ajustes realizados durante la ejecución —derivados principalmente de restricciones computacionales— se documentan explícitamente en las fases correspondientes.

Fase 1. Revisión bibliográfica estructurada de la literatura

Se llevó a cabo una revisión bibliográfica estructurada en bases de datos académicas indexadas (Scopus, Web of Science, IEEE Xplore, Google Scholar) y en el repositorio institucional de la UNIR, desarrollada principalmente durante la segunda quincena de abril de 2026, con una fase de ajuste y complementación en la primera semana de mayo de 2026. Aunque no se

conservó un registro exhaustivo de cada consulta realizada, la búsqueda se orientó por combinaciones de términos como "time series forecasting" AND "FP&A", "walk-forward validation" AND "financial time series", "backtesting" AND "forecast evaluation", y "gradient boosting" OR "deep learning" AND "time series forecasting", consistentes con los descriptores de la literatura incluida en el Capítulo 2. Los criterios de inclusión comprenden trabajos que aborden métodos de pronóstico de series temporales en contextos financieros o empresariales, esquemas de backtesting temporal y métricas de evaluación orientadas a mayor contribución al error absoluto. Como criterios de exclusión se descartaron los trabajos sin evaluación empírica cuantitativa, los centrados en frecuencias intradiarias o de negociación de alta frecuencia —ajenas al ciclo mensual de FP&A— y las publicaciones no arbitradas, con la excepción de preprints recientes sobre modelos fundacionales, incorporados por la novedad del área. El proceso derivó en 26 fuentes incluidas en la bibliografía final, sintetizadas en la matriz comparativa de modelos, métricas y contextos de aplicación incluida en el Capítulo 2, que sirve como base para la selección definitiva de las arquitecturas a evaluar (Petropoulos et al., 2022). Al no haberse conservado un registro exhaustivo de cada consulta, no es posible reportar con precisión el número de resultados inicialmente localizados ni el número exacto de trabajos excluidos en cada base de datos; esta es una limitación reconocida del proceso de revisión. La selección y depuración de las fuentes fue realizada de forma independiente por los tres integrantes del grupo sobre subconjuntos temáticos afines a su responsabilidad técnica (Tabla 1), y las fuentes propuestas por cada integrante fueron contrastadas y consensuadas en las reuniones de coordinación quincenal antes de su incorporación a la matriz comparativa del Capítulo 2.

Fase 2. Adquisición y preparación de datos

Se recopiló el conjunto de series temporales financieras mensuales correspondiente al experimento. Esta fase comprendió la descarga del conjunto M4 Financial Monthly (Makridakis et al., 2020), la aplicación del umbral de filtrado (≥ 72 meses), la normalización del formato y el análisis exploratorio descriptivo. Dicho análisis incluye la caracterización estadística de las longitudes de serie y la verificación del cumplimiento del umbral mínimo. Dado que el conjunto M4 no incluye etiquetas por tipo de cuenta contable, el análisis desagregado se realiza por decil de volumen absoluto de la serie, como aproximación a la materialidad relativa basada en la magnitud de las series; esta decisión queda documentada como limitación del trabajo.

Con respecto al tamaño de la submuestra, el diseño original contemplaba $N = 400$ series estratificadas por cuartil de longitud. Una prueba de tiempo de ejecución sobre la submuestra final mostró que los tres modelos estadísticos locales (ETS, Holt-Winters, SARIMA) —los más costosos por requerir ajuste independiente por serie y fold, particularmente AutoARIMA por su búsqueda automática de componentes— tardan aproximadamente 5,7 minutos en total para $N = 200$, un tiempo que se duplicaría a cerca de 11,4 minutos para $N = 400$. Dado que el entorno de ejecución fue CPU sin aceleración GPU (Windows; véase Anexo A), y que doblar el tamaño muestral solo reduciría la amplitud esperada de los intervalos de confianza bootstrap en un factor aproximado de $\sqrt{2}$ ($\approx 29\%$, por la relación entre error estándar y tamaño de muestra bajo remuestreo simple), se determinó que $N = 200$ ofrecía una relación adecuada entre precisión estadística y coste computacional. Se mantuvo la estratificación proporcional por cuartiles de longitud y la semilla fija (SEED = 42) para favorecer la reproducibilidad.

La reducción mantiene la comparabilidad interna entre los modelos al aplicarse la misma muestra y los mismos folds, aunque limita la precisión y la generalización de los resultados. La estratificación por cuartil de longitud garantiza formalmente que la submuestra preserva la distribución de longitudes del conjunto completo (test de Kolmogorov-Smirnov: estadístico = 0,053, $p = 0,63$, sin diferencia significativa). Aunque el diseño de muestreo solo garantiza esta propiedad para la longitud, la verificación empírica directa sobre la submuestra real muestra que la escala, la volatilidad (CV) y la tendencia también resultan comparables a las de la población completa en este muestreo específico: longitud media de 218,0 frente a 218,2 meses, CV mediano de 0,293 frente a 0,275, y 82,0 % frente a 79,5 % de series con tendencia positiva (Tabla 11). Esta correspondencia no está garantizada por el diseño de estratificación y podría no reproducirse con otra semilla aleatoria; se documenta como evidencia empírica adicional, no como una propiedad formal del método de muestreo. La reducción de $N = 400$ a $N = 200$ sí implica una limitación en la generalización de los resultados, que queda recogida en el Capítulo 6.

Fase 3. Diseño del protocolo de backtesting

Se diseñó e implementó el motor de backtesting temporal walk-forward con expanding window, definiendo los parámetros clave: tamaño mínimo de la ventana de entrenamiento (54 meses), horizonte de pronóstico (18 meses) y desplazamiento entre iteraciones (12 meses). La implementación garantizó que, en ninguna iteración, los datos del período de evaluación

sean accesibles durante el ajuste del modelo. El módulo incluye una función de verificación automática de ausencia de fuga de datos que comprueba la disyunción de los índices de entrenamiento y evaluación en cada fold (Bergmeir y Benítez, 2012).

Fase 4. Implementación y ajuste de modelos

Cada familia de modelos se implementó de forma modular e independiente dentro del pipeline, facilitando su sustitución o extensión sin afectar al resto del sistema. Los modelos estadísticos (ETS y SARIMA) se ajustaron mediante selección automática de componentes por criterio de información (AICc), utilizando AutoETS y AutoARIMA de la librería statsforecast (Garza et al., 2022). Holt-Winters se implementó vía statsmodels (Seabold y Perktold, 2010), con selección entre variante aditiva y multiplicativa basada en los datos. LightGBM (Ke et al., 2017) utiliza un paradigma de global forecasting tabular con rezagos como features y predicción recursiva. MLP y N-BEATS se implementan en PyTorch (Paszke et al., 2019) bajo direct forecasting multi-horizonte. A diferencia de los modelos estadísticos, cuyos componentes se seleccionan automáticamente por AICc, los hiperparámetros de LightGBM, MLP y N-BEATS se fijaron manualmente en valores únicos (detallados en la Tabla 12 correspondiente de la sección "Modelos incluidos en la comparativa"), sin una búsqueda automatizada equivalente; esta asimetría en el proceso de optimización se reconoce como una condición del diseño experimental que puede favorecer a los modelos estadísticos en la comparación de complejidad, y se documenta como limitación en el Capítulo 6. En todos los casos, el ajuste de hiperparámetros se realizó exclusivamente sobre datos de entrenamiento, respetando el principio de no contaminación de la evaluación. El diseño original contemplaba la evaluación de hasta 14 folds por serie; en la ejecución final, y atendiendo al coste computacional en CPU sin aceleración GPU, el máximo se limitó a 5 folds por serie (parámetro --max-folds 5), cubriendo un rango temporal suficiente para evaluar la estabilidad del desempeño y preservar la validez comparativa entre modelos. Todos los modelos, locales y globales, se evaluaron sobre exactamente los mismos folds y ventanas temporales por serie; la diferencia entre paradigmas reside en si el ajuste se realiza de forma independiente por serie (modelos locales) o mediante un único modelo entrenado sobre el conjunto de series disponibles en cada fold (modelos globales), como se detalla en la sección 5.1.

Fase 5. Análisis de resultados y construcción del framework

Los resultados del backtesting se consolidaron y analizaron según las métricas definidas en el OE4. El análisis comprende cuatro dimensiones: comparativa global de modelos por familia, desagregación por deciles de volumen, evaluación de la estabilidad temporal del desempeño a lo largo de las iteraciones walk-forward (coeficiente de variación del sMAPE entre folds), y evaluación de la materialidad relativa del error mediante métricas ponderadas por magnitud y comparación del modelo de mayor precisión frente al modelo de referencia. Con base en estos resultados se elaboró el framework de selección descrito en el OE5.

Fase 6. Redacción, revisión y entrega

La documentación técnica y la memoria del TFE se redactaron de forma continua a lo largo del proyecto, con entregas parciales a la directora en los hitos principales de cada fase. La versión final se sometió a revisión de coherencia, verificación bibliográfica y corrección ortotipográfica antes de su entrega formal en la plataforma de la universidad.

La Tabla 9 sintetiza la trazabilidad entre los objetivos específicos, las fases metodológicas, los entregables generados y los resultados obtenidos, y sirve de guía de verificación para los capítulos posteriores.

Tabla 9. Trazabilidad entre objetivos específicos, fases metodológicas, entregables y resultados.

Objetivo	Fase metodológica	Entregable	Métrica o criterio de verificación	Resultado
OE1	Revisión bibliográfica estructurada de la literatura	Capítulo de contexto y estado del arte; tabla de brechas (Tabla 8)	Cobertura de las familias de modelos y brechas identificadas	Cuatro familias caracterizadas; tres brechas conectadas con los objetivos
OE2	Diseño e implementación del pipeline	Módulos de src/ en el repositorio público	20 pruebas automatizadas (14 de métricas, 6 de backtesting)	Pipeline modular operativo; 20/20 pruebas superadas
OE3	Protocolo de backtesting walk-forward	src/backtesting.py con verificación de no-fuga	Ausencia verificada de fuga de información en los folds	Protocolo validado; hasta 5 folds evaluados por serie
OE4	Ejecución y evaluación comparativa	results/tables/ y results/figures/ del repositorio	Seis métricas e IC bootstrap al 95 %	ETS mejor modelo en las seis métricas; mejora significativa frente al baseline
OE5	Síntesis y propuesta del framework	Propuesta preliminar de tres criterios heurísticos. (Tabla 28)	Aplicabilidad de las reglas al contexto FP&A	Parcialmente alcanzado: pendiente de validación con datos corporativos reales

4. PLANTEAMIENTO DE LA COMPARATIVA

El presente capítulo describe el trabajo previo realizado para definir el diseño experimental de la comparativa, incluyendo la selección y caracterización del conjunto de datos, la identificación de las arquitecturas a evaluar, los criterios de éxito adoptados, las métricas de evaluación y el protocolo de validación temporal que garantiza la validez metodológica de los resultados. Las decisiones aquí documentadas son la concreción operativa de los objetivos específicos formulados en el Capítulo 3 y el punto de partida necesario para interpretar correctamente los resultados que se presentan en el Capítulo 5.

4.1. IDENTIFICACIÓN DEL PROBLEMA Y TRABAJO PREVIO

El problema central que motiva esta comparativa —documentado en los capítulos anteriores— es la ausencia de marcos de evaluación cuantitativos que permitan seleccionar modelos de pronóstico en entornos de FP&A con base en criterios objetivos y un procedimiento de evaluación documentado. Para abordarlo de forma rigurosa, el trabajo previo consistió en tres actividades: una revisión bibliográfica estructurada de la literatura para identificar las familias de modelos con mayor representación en benchmarks comparativos de series temporales financieras; un análisis exploratorio del conjunto de datos seleccionado para caracterizar las series disponibles y determinar los parámetros del experimento; y la definición del protocolo de validación temporal que garantiza la comparabilidad de los resultados.

La revisión de la literatura —desarrollada en detalle en el Capítulo 2— permitió identificar cuatro familias de modelos que representan niveles de complejidad algorítmica bien diferenciados. Esta taxonomía de complejidad creciente estructura el diseño del experimento: no se busca evaluar el mayor número posible de modelos, sino representar cada nivel con los algoritmos más representativos de su familia, de modo que los resultados permitan extraer conclusiones sobre la relación entre complejidad y valor en FP&A.

El análisis exploratorio del conjunto de datos reveló una heterogeneidad considerable en la longitud de las series disponibles. Esta variabilidad tiene implicaciones directas para el diseño del protocolo de backtesting: series demasiado cortas no proporcionan suficientes iteraciones walk-forward para analizar la estabilidad temporal del desempeño. El umbral de 72 meses como longitud mínima de inclusión garantiza que toda serie incluida disponga de al menos

una iteración *walk-forward* completa (54 meses de entrenamiento más 18 de horizonte de evaluación). El número real de iteraciones por serie crece con la longitud disponible: alcanzar el máximo de cinco iteraciones definido en el protocolo (sección 4.5) requiere series de al menos 108 meses ($54 + 18 + 12 \times 4$). Dado que el percentil 25 de longitud de la submuestra es de 74 meses (Tabla 10), una proporción relevante de series dispone de solo una o dos iteraciones, lo que se documenta como limitación del análisis de estabilidad temporal en el Capítulo 6.

4.2.DESCRIPCIÓN DEL CONJUNTO DE DATOS

La selección del conjunto de datos M4 Financial Monthly responde a tres criterios. En primer lugar, su origen en una competición de pronóstico de referencia internacional garantiza que las series han sido sometidas a un proceso de curación/depuración y que los resultados son comparables con los de otros estudios que utilizan el mismo benchmark (Makridakis et al., 2020). En segundo lugar, la categoría financiera mensual constituye una aproximación adecuada al contexto de FP&A en términos de frecuencia temporal, actuando como un escenario experimental aproximado de frecuencia mensual, aunque no sea una representación exacta de la contabilidad corporativa real. En tercer lugar, el volumen de series disponibles tras el filtrado permite construir una submuestra que produce intervalos de confianza bootstrap con precisión razonable: para la diferencia ETS–Seasonal Naïve, el IC al 95 % obtenido ($B = 1.000$, $N = 200$) tiene una amplitud de 1,25 pp ($[-4,52; -3,26]$), suficiente para distinguir con claridad la mejora del baseline sin requerir un tamaño muestral mayor. La Tabla 10 recoge las características principales del conjunto de datos.

Tabla 10. Características del conjunto de datos M4 Financial Monthly utilizado en la comparativa.

Dimensión	Descripción
Fuente	M4 Competition Dataset, categoría Financial Monthly (Makridakis et al., 2020). Conjunto de acceso público diseñado específicamente para el benchmarking de modelos de pronóstico.

Series originales disponibles	10.987 series temporales financieras mensuales.
Criterio de filtrado aplicado	Se retienen únicamente las series con longitud real ≥ 72 meses (6 años), umbral mínimo para garantizar suficiente historial de entrenamiento.
Series retenidas tras filtrado	8.493 series (77,3 % del total original).
Frecuencia temporal	Mensual. Cada observación corresponde a un período de un mes.
Longitud de las series (tras filtrado)	Media: 184 meses Mediana: 175 meses P25: 74 meses P75: 237 meses Máximo: 1.502 meses.
Horizonte de pronóstico	18 meses. Corresponde al horizonte estándar M4 mensual y representa aproximadamente un ciclo y medio de planificación financiera anual.
Naturaleza de las series	Series de variables económicas y financieras diversas, sin subcategorización disponible en los metadatos oficiales del M4 (categoría general Finance). No es posible determinar a partir del dataset qué proporción corresponde a series de mercado, indicadores macroeconómicos o reportes de tipo corporativo; las series no están etiquetadas por tipo de cuenta contable.

Fuente: elaboración propia a partir del M4 Competition Dataset (Makridakis et al., 2020).

Tabla 11. Comparación descriptiva entre la submuestra (N=200) y la población filtrada (N=8.493).

Métrica	Población (N = 8.493)	Muestra (N = 200)
Longitud media (meses)	218,2	218,0
Longitud mediana (meses)	206,0	207,5
Escala mediana (máximo absoluto por serie)	5.612,5	5.496,5
Escala P10 – P90	1.829,0 – 13.499,2	1.843,9 – 14.246,0
Coeficiente de variación mediano (volatilidad)	0,275	0,293
Tendencia mediana (pendiente normalizada)	0,003	0,003
Series con tendencia positiva	79,5 %	82,0 %

Fuente: elaboración propia Test de Kolmogorov-Smirnov sobre la distribución de longitudes: estadístico = 0,053, p = 0,63

Limitación relevante. Las series del M4 no están etiquetadas por tipo de cuenta contable, lo que impide el análisis de contribución al error por categoría contable en el sentido estricto que se plantea en la literatura de FP&A. Como alternativa metodológica, el análisis desagregado se realiza por decil de volumen absoluto de la serie, que es un proxy razonable del impacto financiero relativo de cada error de pronóstico. Esta decisión queda documentada como una limitación del trabajo y como una línea de extensión futura con datos de origen organizacional real.

El análisis por volumen absoluto es válido para este conjunto de datos: la verificación sobre las 10.987 series Financial Monthly del M4 confirma la ausencia de valores negativos o cero en cualquier observación, por lo que el volumen absoluto coincide con el volumen real de la serie. Esta validación es específica del dataset M4 Financial Monthly y no se extiende automáticamente a datos de origen organizacional real, que sí podrían incluir valores negativos (p. ej. pérdidas, ajustes contables).

Tratamiento de valores especiales. El conjunto M4 Financial Monthly no contiene valores negativos ni cero en ninguna de las series analizadas, por lo que no fue necesario un tratamiento específico para estos casos. Los valores faltantes se limitan al relleno final (padding) de las series más cortas que la longitud máxima del formato de origen; se eliminan mediante truncamiento simple al extraer cada serie, sin necesidad de interpolación, dado que no se identificaron huecos internos en los datos. No se aplicó ningún tratamiento de valores atípicos (outliers): ni recorte, ni winsorización, ni filtrado estadístico. Esta decisión se documenta explícitamente como limitación: los valores extremos, si existen, influyen sin ajuste en el proceso de estimación de todos los modelos evaluados, lo que podría explicar parcialmente la dispersión observada en los intervalos de confianza (Capítulo 5).

Submuestra estratificada. Dado que el protocolo walk-forward con múltiples modelos estadísticos (incluido SARIMA con selección automática de parámetros) es computacionalmente inviable sobre las 8.493 series completas en un entorno de CPU, el experimento se ejecuta sobre una submuestra estratificada. El diseño original contemplaba $N = 400$ series; sin embargo, una prueba de tiempo de ejecución mostró que los tres modelos estadísticos locales tardan aproximadamente 5,7 minutos en total para $N = 200$, frente a 11,4 minutos estimados para $N = 400$, y que doblar el tamaño muestral solo reduciría la amplitud esperada de los intervalos de confianza bootstrap en un factor aproximado de $\sqrt{2}$ ($\approx 29\%$). Por ello, la submuestra final se fijó en $N = 200$ series seleccionadas mediante muestreo aleatorio estratificado por cuartil de longitud, con semilla fija (SEED = 42). La longitud de la serie se eligió como variable de estratificación porque determina directamente el número de folds walk-forward disponibles por serie, condicionando la comparabilidad del protocolo de validación temporal entre observaciones; no se estratificó adicionalmente por volatilidad, escala o tendencia porque el M4 no provee etiquetas previas para clasificar estas propiedades antes del muestreo. Esta decisión garantiza: (1) que todos los modelos compiten sobre exactamente las mismas series y los mismos folds (comparación justa); (2) la reproducibilidad controlada del procedimiento bajo las versiones, semillas y condiciones documentadas; y (3) la representatividad de la distribución de longitud del dataset completo (test de Kolmogorov-Smirnov: $p = 0,63$), con evidencia empírica adicional —no garantizada por el diseño— de correspondencia también en escala, volatilidad y tendencia (véase tabla 11).

Los tres modelos globales (LightGBM, MLP, N-BEATS) aplican un escalado MaxAbs independiente por serie: cada serie se divide por su propio valor absoluto máximo antes de construir la matriz de entrenamiento, evitando que las series de mayor escala dominen el ajuste conjunto del modelo global. Al generar cada pronóstico, la predicción se multiplica nuevamente por el factor de escala correspondiente a esa serie antes de calcular cualquier métrica de error, de modo que todas las métricas se reportan en la escala original de cada serie, no en la escala normalizada usada internamente por el modelo.

4.3.MODELOS INCLUIDOS EN LA COMPARATIVA

La selección de modelos sigue la taxonomía de complejidad creciente presentada en el Capítulo 2. Para cada nivel se ha seleccionado el algoritmo más representativo con base en su presencia en la literatura de benchmarking y en la disponibilidad de implementaciones maduras y ampliamente documentadas en Python. La Tabla 12 describe los siete modelos incluidos.

Tabla 12. Modelos incluidos en la comparativa: nivel de complejidad, implementación y justificación.

Nivel	Modelo	Librería	Estrategia	Justificación
Baseline	Seasonal Naïve	NumPy (propia)	Repite el patrón estacional de los últimos 12 meses	Referencia mínima obligatoria (Hyndman y Athanasopoulos, 2021)
Estadístico	ETS	statsforecast (AutoETS)	Selección automática por AICc	Estándar robusto de previsión empresarial y baseline de referencia en la práctica actual de FP&A (Petropoulos et al., 2022; Hyndman & Athanasopoulos, 2021).
Estadístico	Holt-Winters	statsmodels	Variante aditiva o multiplicativa seleccionada por los datos	Versión extendida con estacionalidad explícita (Hyndman y Athanasopoulos, 2021)

Estadístico	SARIMA	statsforecast (AutoARIMA)	Algoritmo Hyndman-Khandakar; orden seleccionado por AICc	Modelo univariado con estacionalidad de referencia (Hyndman y Athanopoulos, 2021)
ML	LightGBM	lightgbm	Global forecasting tabular; 36 lags; predicción recursiva	Mejor resultado de gradient boosting en M5 (Makridakis et al., 2022)
DL	MLP Bottle-neck	PyTorch	Global; direct forecasting 18 pasos; BatchNorm + AdamW	Evalúa si DL tabular supera al gradient boosting (Lim y Zohren, 2021)
DL	N-BEATS	PyTorch	Global; direct; bloques de tendencia y estacionalidad	Arquitectura nativa de series temporales con interpretabilidad estructural (Oreshkin et al., 2020)

Fuente: elaboración propia.

Una aclaración metodológica relevante afecta a los modelos de *machine learning* y *deep learning*: ambos se implementan bajo el paradigma de *global forecasting*, es decir, un único modelo entrenado simultáneamente con todas las series disponibles, tratando cada ventana temporal de cada serie como una muestra independiente. Este enfoque permite que los modelos aprendan patrones compartidos entre series, lo que ha demostrado ser especialmente ventajoso cuando el número de series es grande (Januschowski et al., 2020). La coexistencia de modelos locales (Seasonal Naïve, ETS, Holt-Winters, SARIMA) y globales (LightGBM, MLP, N-BEATS) en un mismo entorno de pruebas constituye un desafío metodológico que puede generar factores de confusión al interpretar las métricas de error. Por consiguiente, esta separación entre enfoques se estructura y discute como una dimensión de análisis propia, lo que permite comparar las implementaciones concretas bajo las restricciones de este experimento, sin atribuir las diferencias observadas exclusivamente a la familia algorítmica.

Además, es pertinente señalar una asimetría estructural en los procesos de optimización que afecta la equidad comparativa estricta entre las familias de algoritmos. Mientras que AutoETS

y AutoARIMA ejecutan una búsqueda interna automatizada y exhaustiva de parámetros para cada serie de forma individual (minimizando criterios de información como el AICc), los modelos globales de ML/DL exploran un subconjunto restringido de hiperparámetros definido por el usuario. Esta divergencia metodológica se asume como parte del diseño experimental, dado que refleja las restricciones prácticas y de costo computacional inherentes a la implementación de algoritmos complejos en entornos reales de FP&A.

Para facilitar la comprensión de las arquitecturas de aprendizaje automático y profundo implementadas, la Tabla 13 detalla los hiperparámetros clave de los modelos globales (LightGBM, MLP y N-BEATS), con el valor efectivamente utilizado en la ejecución y la función específica que cumple cada uno dentro del proceso de entrenamiento y ajuste algorítmico.

Tabla 13. Detalle de hiperparámetros e implementación de los modelos globales, con los valores efectivamente utilizados en la ejecución.

Modelo	Hiperparámetro	Valor utilizado	Descripción
LightGBM	n_estimators	300	Número de árboles iterativos (rondas de boosting)
	learning_rate	0,05	Tasa de aprendizaje general
	max_depth	6	Profundidad máxima del árbol
	num_leaves	31	Número máximo de hojas por árbol
	Regularización	feature_fraction = 0,8; bagging_fraction = 0,8; bagging_freq = 5	Submuestreo de columnas y filas para reducir sobreajuste
	Rezagos (n_lags)	36 meses	Ventana de historial usada como variables predictoras
	Estrategia de predicción	Recursiva	Predice un paso y realimenta la predicción como entrada del siguiente

	Función de pérdida	MAE (objective = regression, metric = mae)	Función minimizada durante el entrenamiento
MLP	Arquitectura	128 → 64 neuronas (2 capas ocultas)	Perceptrón multicapa con cuello de botella
	Activación	ReLU	Función de activación no lineal
	Dropout	0,2 (tras la primera capa oculta)	Regularización para reducir sobreajuste
	Normalización	BatchNorm1d (en ambas capas ocultas)	Estabiliza y acelera el entrenamiento
	Tasa de aprendizaje inicial	0,002	learning_rate_init
	Optimizador	AdamW (weight_decay = 1×10^{-3})	Optimizador con decaimiento de peso desacoplado
	Programador de tasa	StepLR (step_size = 10, gamma = 0,5)	Reduce la tasa de aprendizaje a la mitad cada 10 épocas
	Épocas	40 (fijas, sin early stopping)	Ciclos completos de entrenamiento
	Tamaño de lote	256	batch_size
N-BEATS	Arquitectura	2 stacks: tendencia (grado polinomial 3) + estacionalidad (6 armónicos de Fourier)	stack_types
	Bloques por stack	3	num_blocks_per_stack

	Capas ocultas por bloque	4	n_layers
	Ancho de capa	128 neuronas	layer_width
	Historial de entrada (lookback)	36 meses	input_chunk_length / n_lags
	Horizonte de salida	18 meses	output_chunk_length / horizon
	Optimizador	Adam (sin weight_decay)	optim.Adam
	Función de pérdida	MAE (L1Loss)	Función minimizada durante el entrenamiento
	Tasa de aprendizaje	0,001	lr
	Épocas	20 (fijas, sin early stopping)	Ciclos completos de entrenamiento
	Tamaño de lote	256	batch_size

Fuente: elaboración propia a partir de src/models/ml.py. Los valores por defecto de LightGBM se establecen en LightGBMForecaster.__init__; los de MLP en MLPForecaster.__init__ y la clase _MLPBottleneck; los de N-BEATS en NBEATSForecaster.__init__ y la clase _NBEATSInterpretable.

4.4.MÉTRICAS DE EVALUACIÓN

La selección de métricas responde al principio establecido en el Capítulo 2: la evaluación debe operar en dos planos complementarios. Las métricas estadísticas permiten comparar la precisión técnica de forma independiente de la escala y el dominio. Las métricas ponderadas por magnitud o proxies de materialidad aproximan el valor para el negocio ponderando el error por el volumen de la serie. Es importante precisar que esta ponderación constituye un proxy de materialidad financiera y no una medición directa de dicha materialidad en unidades monetarias comparables, salvo que las series estén expresadas en la misma moneda, unidad y

escala, condición que el conjunto M4 Financial no garantiza. La Tabla 14 describe las seis métricas principales adoptadas; el análisis complementario de contribución al error absoluto se presenta posteriormente mediante la desagregación por deciles de volumen.

Tabla 14. Métricas de evaluación adoptadas: categoría, nivel de análisis y rol en la comparativa.

Métrica	Categoría	Nivel de análisis	Rol en la comparativa
MAE	Error absoluto	Por serie Global	Error en unidades originales; intuición directa del analista
RMSE	Error cuadrático	Por serie Global	Sensibilidad a errores grandes; penaliza outliers
MAPE	Error porcentual	Por serie Global	Comunicación a equipos de negocio; complementa al sMAPE
sMAPE	Error porcentual simétrico	Por serie Global	Métrica principal; estándar M4; permite comparar con literatura (Petropoulos et al., 2022)
MASE	Error escalado	Por serie Global	Comparación robusta frente al naïve estacional; valores <1 indican superación del baseline (Hyndman y Athanasopoulos, 2021)
WAPE	Ponderación por magnitud (proxy de materialidad)	Agregado Por decil	Pondera errores por volumen; aproxima la materialidad financiera, no constituye una medición directa de la materialidad financiera en

			unidades monetarias comparables. (Makridakis et al., 2022)
--	--	--	--

Fuente: elaboración propia a partir de Petropoulos et al. (2022), Hyndman y Athanasopoulos (2021) y Makridakis et al. (2022).

Fórmulas y tratamiento de casos límite. Las seis métricas estadísticas y de ponderación por magnitud se definen formalmente como:

MAE

$$MAE = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|$$

RMSE

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2}$$

MAPE

$$MAPE = \frac{100}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right|$$

sMAPE

$$sMAPE = \frac{100}{n} \sum_{t=1}^n \frac{2|y_t - \hat{y}_t|}{|y_t| + |\hat{y}_t|}$$

MASE

$$MASE = \frac{\frac{1}{h} \sum_{t=1}^h |y_t - \hat{y}_t|}{\frac{1}{n-m} \sum_{j=m+1}^n |y_j - y_{j-m}|}$$

WAPEE

$$WAPPE = \frac{\sum_{t=1}^n |y_t - \hat{y}_t|}{\sum_{t=1}^n |y_t|} \times 100$$

donde y_t es el valor real, $\hat{y}_t$ el pronóstico, n el número de observaciones evaluadas, h el horizonte, m la periodicidad estacional (12 para datos mensuales) y el denominador del MASE se calcula sobre la serie de entrenamiento (naïve estacional en muestra, Hyndman y Koehler, 2006).

El tratamiento de denominadores cercanos a cero se implementó explícitamente para cada métrica: en el MAPE, los términos con $|y_t| \approx 0$ se excluyen del promedio (el MAPE no está definido en ese punto); en el sMAPE, los términos en que numerador y denominador son ambos cercanos a cero —una predicción perfecta de un valor casi nulo— contribuyen 0 en lugar de una división indeterminada; en el WAPE, si el volumen total de la serie es cercano a cero, la métrica no se calcula. En la práctica, este tratamiento no se activó en ninguna serie de la submuestra, dado que el conjunto M4 Financial Monthly no contiene valores negativos ni cero (verificado sobre las 10.987 series de la categoría); se documenta como salvaguarda del pipeline para datos con esa característica, no como un ajuste aplicado a los resultados reportados en este trabajo.

Nota interpretativa sobre MASE. Un $MASE \geq 1,0$ no implica necesariamente que el modelo sea peor que el Seasonal Naïve en los términos en que se reporta el sMAPE, porque ambas métricas usan referencias distintas: el sMAPE del baseline se calcula fuera de muestra, sobre el horizonte de evaluación real, mientras que el denominador del MASE se calcula en muestra, sobre los errores del naïve estacional dentro del período de entrenamiento. Un modelo puede superar al Seasonal Naïve fuera de muestra (mejor sMAPE) y, al mismo tiempo, tener $MASE \geq 1,0$, porque el error en muestra del naïve estacional tiende a ser menor que su error fuera de muestra en series con tendencia o cambios de régimen (Kolassa, 2022). Esta asimetría se desarrolla con mayor detalle en la sección de Estabilidad temporal (5.3).

4.5.PROTOCOLO DE VALIDACIÓN TEMPORAL

El protocolo de backtesting walk-forward constituye un componente metodológico central de la comparativa. Mientras que el hold-out simple evalúa el desempeño a partir de un único corte temporal, por lo que sus resultados pueden estar condicionados por las características del período de prueba seleccionado, el enfoque walk-forward considera múltiples orígenes de pronóstico. Esto permite examinar la estabilidad del desempeño de los modelos en diferentes períodos temporales (Bergmeir y Benítez, 2012). La Tabla 15 presenta los parámetros del protocolo y la justificación de las decisiones adoptadas.

Tabla 15. Parámetros del protocolo de backtesting walk-forward y su justificación.

Parámetro	Valor y justificación
-----------	-----------------------


Ventana mínima de entrenamiento	54 meses (4,5 años). Garantiza al menos cuatro ciclos estacionales completos para el ajuste de parámetros (Hyndman y Athanassopoulos, 2021).
Horizonte de pronóstico	18 meses. Estándar M4 mensual; cubre aproximadamente un ciclo y medio de planificación financiera.
Desplazamiento entre iteraciones	12 meses. Cada nueva ventana avanza un año completo, preservando la estructura estacional de los datos.
Variante de ventana	Expanding window (ventana creciente). El entrenamiento acumula todas las observaciones disponibles hasta el punto de corte de cada iteración. Apropiado dado que las series no presentan cambios de régimen conocidos.
Iteraciones por serie	Variable según longitud. El máximo se fijó en 5 iteraciones por restricción computacional (parámetro --max-folds 5). Para una serie de longitud media (184 meses) podrían generarse hasta 9 iteraciones; en la ejecución final se aplicaron entre 1 y 5 según la longitud de cada serie.
Control de fuga de datos	En ninguna iteración los datos del período de evaluación ($t+1$ a $t+18$) son accesibles durante el ajuste del modelo ni durante la inge-

	niería de features. Verificado automáticamente por el módulo <code>verify_no_leakage</code> (Bergmeir y Benítez, 2012).
--	---

Fuente: elaboración propia a partir de Bergmeir y Benítez (2012) y Hyndman y Athanasopoulos (2021).

Las métricas finales reportadas en el Capítulo 5 corresponden a la media y la desviación estándar de todas las iteraciones walk-forward de todas las series de la submuestra. El número de iteraciones por serie es variable: series con longitud cercana al umbral mínimo de 72 meses producen una sola iteración, mientras que alcanzar el máximo de 5 iteraciones definido por restricción computacional requiere series de al menos 108 meses; el pipeline usa automáticamente las iteraciones más recientes disponibles para cada serie, sin necesidad de relleno artificial cuando hay menos de 5. La distribución exacta de iteraciones retenidas en la submuestra final es: 20 series con 1 iteración, 2 series con 2 iteraciones, ninguna serie con 3 iteraciones, 5 series con 4 iteraciones y 173 series con las 5 iteraciones completas (86,5 % de la submuestra); esta distribución es la base para interpretar el análisis de estabilidad temporal del apartado 6.4, incluido el tratamiento de las series con una única iteración retenida. La Figura 1 ilustra el esquema general de cuatro iteraciones representativas de este protocolo, con los mismos parámetros (ventana inicial de 54 meses, horizonte de 18, step de 12) que rigen la ejecución real.

Figura 1. Esquema de validación walk-forward con ventana creciente (expanding window). Cada fila representa un fold; el área azul corresponde al conjunto de entrenamiento y el área roja al horizonte de evaluación de 18 meses.



Fuente: elaboración propia. El desplazamiento entre iteraciones es de 12 meses (step); la ventana de entrenamiento crece acumulando todas las observaciones históricas disponibles hasta el punto de corte de cada fold.

Limitación de recencia. Para las series más largas de la submuestra (hasta 1.502 meses), el protocolo evalúa únicamente las 5 iteraciones más recientes, lo que concentra la evaluación en, aproximadamente, los últimos 8-9 años de historia disponible. Esto significa que el desempeño de los modelos sobre los regímenes más antiguos de esas series largas no se evalúa: el entrenamiento sí aprovecha todo el historial disponible (ventana expanding), pero la medición del error queda restringida a la porción más reciente de la serie. Esta decisión prioriza la relevancia del desempeño esperado en producción (el futuro cercano importa más que el pasado distante para la toma de decisiones en FP&A) a costa de no capturar cómo se comportarían los modelos ante regímenes económicos más antiguos presentes en series largas. Se documenta como limitación en el Capítulo 6.

Verificación de fuga de datos. El módulo `verify_no_leakage` comprueba automáticamente la disyunción de los índices de entrenamiento y evaluación en cada fold. En la ejecución del experimento, esta verificación se extendió, antes del depósito, a la totalidad de las 200 series de la submuestra (semilla fija SEED = 42, reproducible), tras confirmarse en el predepósito sobre una muestra aleatoria de 10 series. Dado que la verificación es una comprobación de índices —no requiere ajustar ningún modelo—, su coste computacional resultó marginal (verificación completa en segundos). Ninguna de las 200 series presenta fuga de información.

4.6.CRITERIOS DE ÉXITO

Para que la comparativa produzca conclusiones operacionalizables y no simplemente un ranking de modelos es necesario definir con antelación qué condiciones constituyen un resultado significativo. Los criterios de la Tabla 16 operan en dos niveles: cuándo un modelo supera al

baseline, y cuándo la mejora de un modelo complejo sobre otro justifica la inversión adicional en complejidad.

Tabla 16. Criterios de éxito de la comparativa: condiciones de superación del baseline y de diferenciación entre modelos.

Criterio	Condición de superación del baseline	Condición de diferenciación entre modelos complejos
sMAPE global	Reducción ≥ 1 pp absoluto respecto al Seasonal Naïve (referencia exploratoria: 13,667 %)	Reducción estadísticamente consistente entre iteraciones walk-forward
MASE global	MASE $< 1,0$, evaluado individualmente para cada uno de los siete modelos	MASE $< 0,90$ para los modelos de mayor complejidad
WAPE	El WAPE de cualquier modelo no supera el WAPE del baseline en el 30 % de mayor volumen	Reducción del WAPE en los deciles de mayor volumen a medida que aumenta la complejidad
Estabilidad temporal	CV del sMAPE entre iteraciones walk-forward < 25 % para todos los modelos	Los modelos complejos no muestran deterioro significativo en las iteraciones más recientes
Significación estadística	Diferencia $\geq 0,5$ pp en sMAPE entre el mejor modelo y el Seasonal Naïve, sostenida en más del 60 % de los <i>folds</i>	Consistencia evaluada mediante un intervalo de confianza bootstrap sobre diferencias pareadas por serie; una diferencia no significativa implica que la mayor complejidad no se justifica

		bajo las condiciones de este experimento (Bergmeir y Benítez, 2012)
--	--	---

Fuente: elaboración propia. El valor de referencia del Seasonal Naïve (13,667 %) corresponde al resultado experimental final sobre N = 200 series estratificadas. El criterio de estabilidad ($CV < 25 \%$) es un umbral aspiracional; su incumplimiento generalizado refleja la heterogeneidad intrínseca del conjunto M4 Financial y no invalida las conclusiones comparativas (Hyndman y Athanasopoulos, 2021).

Es importante distinguir dos tipos de elementos en esta tabla 16: las reglas de decisión (p. ej., "reducción ≥ 1 pp respecto al baseline", " $CV < 25 \%$ ", "consistencia en más del 60 % de los folds") se definieron antes de ejecutar el experimento y constituyen los criterios de éxito propiamente dichos. El valor numérico del Seasonal Naïve (13,667 % de sMAPE) es, por necesidad metodológica, un resultado del propio experimento: no puede conocerse antes de ejecutar el baseline. Su uso como referencia para aplicar la regla de decisión predefinida es metodológicamente correcto y no invalida el carácter a priori del criterio.

El criterio de consistencia ("el modelo supera al baseline en más del 60 % de los folds") no se había reportado explícitamente hasta ahora. El cálculo directo sobre los 909 pares serie-fold evaluados por modelo muestra que ETS supera al Seasonal Naïve en el 71,4 % de los folds, SARIMA en el 68,2 %, Holt-Winters en el 64,6 %, LightGBM en el 62,5 % y N-BEATS en el 59,0 %; MLP es el modelo con menor consistencia, con un 57,8 % de folds en los que supera al baseline. Tanto MLP como N-BEATS quedan, por tanto, por debajo del umbral del 60 %. Este resultado se documenta explícitamente: ambos modelos de deep learning mejoran la precisión media (sMAPE global) frente al Seasonal Naïve, pero no de forma suficientemente consistente entre iteraciones walk-forward según el criterio de significación predefinido, lo que debe tenerse en cuenta al valorar su idoneidad frente a los modelos estadísticos clásicos.

Formalmente, el criterio WAPE exige que $WAPE_modelo(D8-10) \leq WAPE_baseline(D8-10)$, donde D8-10 es el subconjunto de series pertenecientes a los deciles 8, 9 y 10 de volumen absoluto (el 30 % de mayor volumen de la submuestra).

El criterio $MASE < 1,0$ para todos los modelos resultó ser excesivamente estricto: ningún modelo lo cumple, lo que se explica por la naturaleza del denominador del MASE (error del naïve estacional en muestra, no fuera de muestra; véase la nota interpretativa en la sección de Métricas de evaluación). El umbral de estabilidad (CV del sMAPE $< 25 \%$) se adopta como criterio

exploratorio propio de este trabajo, no como un estándar validado en la literatura de pronóstico financiero —hasta donde se ha revisado, no existe un consenso publicado sobre un umbral universal de CV-sMAPE para estabilidad temporal en contextos de FP&A. Su función es operacionalizar la noción de confiabilidad, no representar un límite normativo.

5. DESARROLLO DE LA COMPARATIVA

El presente capítulo presenta los resultados cuantitativos del experimento comparativo descrito en el Capítulo 4. La exposición es objetiva: se reportan los valores obtenidos sin valorarlos ni interpretarlos; la discusión y el análisis crítico se reservan para el Capítulo 6.

5.1.CONFIGURACIÓN DEL EXPERIMENTO EJECUTADO

El experimento se ejecutó sobre una submuestra estratificada de 200 series del conjunto M4 Financial Monthly, seleccionadas mediante muestreo aleatorio estratificado por cuartil de longitud con semilla fija (`SEED = 42`). El protocolo walk-forward se aplicó con los parámetros documentados en la Tabla 15: ventana inicial de 54 meses, horizonte de 18 meses y desplazamiento de 12 meses (*expanding window*). La verificación automática de ausencia de fuga de datos mediante la función `verify_no_leakage` confirmó que ningún fold contiene solapamiento entre conjuntos de entrenamiento y evaluación.

Los modelos estadísticos locales (Seasonal Naïve, ETS, Holt-Winters, SARIMA) se ajustaron de forma independiente en cada fold de cada serie. Los modelos globales (LightGBM, MLP, N-BEATS) entrenaron un único modelo por fold sobre todas las series disponibles en ese fold y evaluaron la predicción de forma individual. La submuestra evaluada comprende 200 series estratificadas, tamaño reducido desde las 400 planificadas por restricciones de coste computacional, según se justificó en la metodología. El entorno de ejecución fue Python 3.13 en CPU (sin aceleración GPU), con las versiones de librerías especificadas en `requirements.txt`.

5.2.RESULTADOS GLOBALES POR MODELO Y MÉTRICA

Las seis métricas se presentan en tres tablas según su naturaleza: la tabla siguiente recoge las métricas dependientes de escala (MAE, RMSE, en las unidades originales de cada serie); la Tabla 18 recoge las métricas independientes de escala (MAPE, sMAPE, MASE); y la Tabla 19 recoge la métrica de aproximación a la materialidad (WAPE) junto con la estabilidad temporal (CV-sMAPE). MAE y RMSE se reportan en las unidades originales de cada serie y se promedian

entre series de escalas potencialmente muy distintas; por tanto, deben interpretarse como métricas descriptivas para comparar modelos sobre la misma muestra, y no como un error medio en una unidad financiera común (desarrollo completo en la sección de Limitaciones).

Antes de presentar los resultados, conviene anticipar una precisión sobre el MASE: un valor $\geq 1,0$ no equivale a "peor que el Seasonal Naïve" en el mismo sentido que el sMAPE, porque su denominador se calcula sobre el error del naïve estacional *en muestra* (dentro del periodo de entrenamiento), mientras que el sMAPE del baseline se calcula *fuera de muestra*. Como se verá, todos los modelos mejoran el sMAPE del Seasonal Naïve pero ninguno alcanza $MASE < 1,0$; ambos resultados son consistentes entre sí, no contradictorios (desarrollo completo en la sección de Estabilidad temporal).

Tabla 17. Métricas dependientes de escala.

Modelo	MAE	RMSE
Seasonal Naïve	658,08 $\pm$ 983,78	759,10 $\pm$ 1.130,83
ETS (AutoETS)	476,20 $\pm$ 728,93	559,21 $\pm$ 839,59
Holt-Winters	547,29 $\pm$ 880,88	643,46 $\pm$ 1.039,43
SARIMA (AutoA-RIMA)	519,22 $\pm$ 816,87	607,54 $\pm$ 953,57
LightGBM	552,63 $\pm$ 701,38	639,08 $\pm$ 802,14
MLP Bottleneck	564,90 $\pm$ 715,72	652,28 $\pm$ 820,25
N-BEATS Interpretable	583,97 $\pm$ 757,47	677,49 $\pm$ 855,23

Tabla 18. Métricas independientes de escala: sMAPE (%), MAPE (%) y MASE. Media $\pm$ desviación estándar sobre evaluaciones fold $\times$ serie. N = 200 series estratificadas, protocolo walk-forward expanding window, máximo 5 folds por serie.

Modelo	sMAPE (%)	MAPE (%)	MASE
Seasonal Naïve	13,667 $\pm$ 12,658	14,186 $\pm$ 15,611	1,412 $\pm$ 1,102
ETS (AutoETS)	10,005 $\pm$ 10,512	10,571 $\pm$ 12,602	1,017 $\pm$ 0,903
Holt-Winters	11,157 $\pm$ 11,822	12,159 $\pm$ 15,411	1,145 $\pm$ 1,089
SARIMA (AutoARIMA)	10,825 $\pm$ 12,264	11,470 $\pm$ 14,148	1,093 $\pm$ 1,031
LightGBM	11,682 $\pm$ 10,536	11,962 $\pm$ 11,886	1,291 $\pm$ 1,112
MLP Bottleneck	11,844 $\pm$ 10,635	11,906 $\pm$ 11,449	1,351 $\pm$ 1,112
N-BEATS Interpretable	12,375 $\pm$ 11,445	12,328 $\pm$ 12,247	1,340 $\pm$ 1,087

Fuente: elaboración propia. sMAPE: estándar de la competición M4. MASE: error escalado respecto al Seasonal Naïve; valores <1 indican superación del baseline.

Tabla 19. Métrica ponderada por magnitud (WAPE) y estabilidad temporal (CV-sMAPE). WAPE = error porcentual absoluto ponderado por volumen de serie.

Modelo	WAPE (%)	CV-sMAPE (%)
Seasonal Naïve	13,813 $\pm$ 14,744	92,6 %
ETS (AutoETS)	10,081 $\pm$ 10,873	105,1 %
Holt-Winters	11,583 $\pm$ 13,242	106,0 %
SARIMA (AutoARIMA)	10,881 $\pm$ 12,203	113,3 %
LightGBM	11,542 $\pm$ 10,559	90,2 %
MLP Bottleneck	11,637 $\pm$ 10,561	89,8 %

N-BEATS Interpretable	12,074 ± 11,429	92,5 %
-----------------------	-----------------	--------


Fuente: elaboración propia. $CV\text{-}sMAPE = \sigma(sMAPE) / \mu(sMAPE) \times 100$, calculado sobre el conjunto completo de evaluaciones (folds $\times$ series) para cada modelo; no es un promedio por fold ni por serie, sino un indicador global de dispersión relativa. Criterio de estabilidad aspiracional: $CV < 25 \%$ (Tabla 16); la elevada heterogeneidad del dataset M4 Financial genera valores típicamente muy superiores.

El modelo con menor sMAPE medio es **ETS (AutoETS)** con un 10,005 %. El Seasonal Naïve, utilizado como referencia mínima, obtiene un sMAPE de 13,667 %. Todos los modelos estadísticos clásicos (ETS, Holt-Winters, SARIMA) mejoran sustancialmente este valor de referencia.

5.3. ANÁLISIS DE ESTABILIDAD TEMPORAL

La Figura 2 muestra la evolución del sMAPE promedio por posición relativa de *fold* (0 = *fold* más antiguo evaluado, 4 = más reciente) para los modelos locales, restringida a las 173 de las 200 series de la submuestra que retienen los cinco folds completos en los cuatro modelos. Esta restricción garantiza que cada posición de fold promedia exactamente el mismo conjunto de series, evitando que la tendencia observada refleje un cambio en la composición de la muestra en lugar de un efecto temporal genuino. Se observa una tendencia decreciente consistente en ETS, Holt-Winters y SARIMA: el error es mayor en el primer *fold* evaluado y disminuye progresivamente hacia el último. Este patrón es coherente con el diseño de ventana *expanding*: el primer *fold* se ajusta con la ventana mínima de entrenamiento (54 meses), mientras que el último *fold* dispone de hasta 102 meses de historia ($54 + 4 \times 12$), lo que reduce el error de estimación a medida que el modelo accede a más datos. Esta interpretación se ve reforzada por el comportamiento del Seasonal Naïve, que no se ajusta a partir del historial acumulado sino que replica el último ciclo estacional observado: su sMAPE decrece de forma mucho menos pronunciada y se aplanan en los dos últimos folds (11,79 % y 11,96 %, sin mejora entre ambos), en contraste con la mejora continua y monótona de los tres modelos que sí aprovechan un historial de entrenamiento creciente. Esta divergencia es coherente con la explicación basada en el mayor historial disponible en las ventanas *expanding*. No obstante, el patrón observado no permite establecer una relación causal única, ya que también pueden influir cambios temporales en la dificultad de los períodos evaluados.

Figura 2. Estabilidad temporal del sMAPE por modelo y fold walk-forward (modelos estadísticos locales; n = 173 series con historial completo de cinco folds).



Fuente: elaboración propia. El eje X representa la posición relativa de fold (0 = primer corte temporal, valor mayor = corte más reciente). El eje Y es el sMAPE promedio sobre las 173 series con historial completo de cinco folds para ese fold; se excluyen las 27 series restantes de la submuestra porque no generan los cinco folds completos, lo que garantiza una composición constante de la muestra en las cinco posiciones.

Tabla 20. Coeficiente de variación (CV) temporal del sMAPE por modelo, calculado dentro de cada serie y promediado sobre la submuestra (n = 180 series con dos o más folds retenidos; se excluyen 20 series con un único fold).

Modelo	Media CV (%)	Mediana CV (%)	RIC (P25–P75, %)
Seasonal Naïve	48,3	43,5	32,1–57,8
ETS (AutoETS)	53,8	51,4	34,6–66,2
Holt-Winters	53,8	52,8	36,3–69,3
SARIMA (AutoARIMA)	55,1	50,9	37,2–72,4
LightGBM	48,2	46,2	32,5–58,1
MLP Bottleneck	47,2	45,2	31,2–58,0
N-BEATS Interpretable	49,3	47,4	33,2–63,6

Fuente: elaboración propia. Entre el 84,4 % (MLP) y el 90,6 % (Holt-Winters) de las series individuales presenta un CV superior al 25 %, según el modelo; la mediana es en todos los casos inferior a la media, lo que indica una distribución con cola derecha (algunas series muy inestables elevan el promedio).

Tabla 21. Evaluación frente a los criterios de éxito predefinidos en la Tabla 16. Referencia sMAPE Seasonal Naïve: 13,667 % (resultado experimental).

Modelo	sMAPE (%)	Δ sMAPE (pp)	MASE	CV-sMAPE	Supera baseline	Estable
Seasonal Naïve	13,667	0,000	1,412	92,6 %	No (referencia)	No
ETS (Auto-ETS)	10,005	-3,662	1,017	105,1 %	Sí (≥ 1 pp)	No
Holt-Winters	11,157	-2,510	1,145	106,0 %	Sí (≥ 1 pp)	No
SARIMA (AutoARIMA)	10,825	-2,842	1,093	113,3 %	Sí (≥ 1 pp)	No
LightGBM	11,682	-1,985	1,291	90,2 %	Sí (≥ 1 pp)	No
MLP Bottleneck	11,844	-1,823	1,351	89,8 %	Sí (≥ 1 pp)	No
N-BEATS Interpretable	12,375	-1,292	1,340	92,5 %	Sí (≥ 1 pp)	No

Fuente: elaboración propia. Δ sMAPE = sMAPE(modelo) - sMAPE(Seasonal Naïve), expresado en puntos porcentuales. Los valores negativos indican una reducción del error y, por tanto, una mejora respecto al baseline. $CV\text{-}sMAPE = \sigma(sMAPE) / \mu(sMAPE) \times 100$, calculado sobre el conjunto de evaluaciones *fold* $\times$ serie.

La diferencia de -3,662 pp reportada en la Tabla 21 (diferencia entre las medias globales de sMAPE, calculadas sobre el conjunto completo de 909 observaciones *fold* $\times$ serie por modelo) no coincide numéricamente con la diferencia de -3,852 pp reportada posteriormente en la Tabla 22 (media de las diferencias pareadas por serie, calculada promediando primero el sMAPE de cada una de las 200 series y luego promediando esas 200 diferencias). Ambos cálculos son correctos, pero responden preguntas distintas: el primero pondera cada observación

fold×serie por igual —las series más largas, con más *folds*, tienen mayor peso—, mientras que el segundo pondera cada serie por igual. Se confirmó que ambos cálculos usan exactamente las mismas 200 series y 909 observaciones; la discrepancia es exclusivamente un efecto del orden de agregación, no un error de datos. El valor de -3,852 pp es el que sustenta la prueba de significación estadística, por ser la unidad de remuestreo coherente con el diseño *bootstrap* (una serie, un peso).

Con el fin de corroborar estadísticamente la superioridad observada en la Tabla 21, se aplicó un test de bootstrap percentil (Efron & Tibshirani, 1993) sobre las diferencias pareadas por serie entre cada modelo y el baseline Seasonal Naïve. La unidad de remuestreo es la serie (N = 200), con B = 1 000 remuestras y nivel de significación $\alpha = 0,05$ (bilateral). La Tabla 22 presenta las diferencias medias en sMAPE y los intervalos de confianza al 95 %. Para mantener una convención de signos uniforme, las diferencias de sMAPE de las Tablas 21, 22 y 23 se calculan como sMAPE(modelo) - sMAPE(referencia). En consecuencia, los valores negativos indican una reducción del error y, por tanto, una mejora del modelo situado en primer término respecto al modelo de referencia.

Tabla 22. Intervalos de confianza bootstrap al 95 % para la diferencia de sMAPE respecto al Seasonal Naïve.

Modelo	Diferencia media (pp)	IC 95 % inferior	IC 95 % superior	Significativo ($\alpha = 0,05$)
SNaive	0,000	—	—	Referencia
ETS	-3,852	-4,517	-3,264	Sí
Holt-Winters	-2,725	-3,515	-2,028	Sí
SARIMA	-3,154	-3,945	-2,481	Sí
LightGBM	-1,998	-2,572	-1,447	Sí
MLP	-1,898	-2,453	-1,322	Sí
N-BEATS	-1,065	-1,509	-0,596	Sí

Fuente: elaboración propia. Método: percentil bootstrap (Efron & Tibshirani, 1993). N = 200 series, B = 1 000 remuestras, $\alpha = 0,05$ (bilateral), SEED = 42. Diferencia = sMAPE(modelo) - sMAPE(SNaive); valores negativos indican mejora sobre el baseline. El IC no contiene el cero en los seis modelos evaluados frente al Seasonal Naïve.

Justificación del método percentil. Se optó por el método de percentil bootstrap (Efron y Tibshirani, 1993) en lugar de BCa (bias-corrected and accelerated) por su simplicidad computacional y por no requerir el cálculo adicional de la constante de aceleración mediante jackknife. Se reconoce como limitación que el método percentil puede ser menos preciso que BCa en presencia de distribuciones sesgadas; dado que la desviación estándar del sMAPE es comparable o superior a su media en varios modelos (Tabla 19), es plausible cierta asimetría en la distribución de las diferencias pareadas, por lo que los intervalos aquí reportados podrían diferir ligeramente de los que produciría BCa. Esta comparación queda como línea de verificación futura.

Agregación previa por serie. La unidad de remuestreo es la serie, no el par serie-fold: para cada una de las 200 series se calculó primero el sMAPE promedio sobre todos sus folds disponibles (entre 1 y 5, según la longitud de la serie), y el bootstrap remuestrea sobre esas 200 medias por serie, preservando la estructura pareada del diseño.

Comparaciones entre modelos, no solo frente al baseline. El hecho de que los seis modelos superen significativamente al Seasonal Naïve no implica que sean significativamente distintos entre sí. Se realizaron comparaciones directas adicionales mediante el mismo método: ETS obtiene un sMAPE significativamente menor que SARIMA (diferencia media: -0,698 pp; IC 95 %: [-1,118, -0,295]) y que Holt-Winters (diferencia media: -1,127 pp; IC 95 %: [-1,646, -0,674]), así como frente a LightGBM, el mejor modelo de machine learning/deep learning (diferencia media: -1,854 pp; IC 95 %: [-2,419, -1,351]). En cambio, la diferencia entre SARIMA y Holt-Winters no es estadísticamente significativa (diferencia media: -0,429 pp; IC 95 %: [-0,957, 0,096]), por lo que ambos modelos deben considerarse estadísticamente equivalentes en este experimento. Dado que se realizaron diez comparaciones —seis frente al baseline y cuatro adicionales—, se aplicó una corrección de Bonferroni, con un nivel de significación ajustado de $\alpha = 0,005$. Las nueve comparaciones significativas al 95 % se mantienen significativas al nivel ajustado, mientras que la comparación entre SARIMA y Holt-Winters continúa siendo no significativa. Esta evidencia respalda el uso de la denominación "ganador global" para ETS, al confirmarse su superioridad estadística tanto frente al baseline como frente a sus principales competidores directos, no solo frente al Seasonal Naïve.

La tabla siguiente presenta los intervalos de confianza al nivel ajustado del 99,5 % para las diez comparaciones, aportando evidencia empírica directa de que la corrección de Bonferroni no altera el patrón de significación descrito.

Tabla 23. Intervalos de confianza al 99,5 % (nivel ajustado por la corrección de Bonferroni, $\alpha = 0,05/10 = 0,005$) para las diez comparaciones pareadas evaluadas.

Comparación	Diferencia (pp)	IC 99,5 % ajustado (pp)	Significativo
ETS vs Seasonal Naïve	-3,852	-4,862; -3,100	Sí
Holt-Winters vs Seasonal Naïve	-2,725	-3,910; -1,827	Sí
SARIMA vs Seasonal Naïve	-3,154	-4,329; -2,218	Sí
LightGBM vs Seasonal Naïve	-1,998	-2,804; -1,250	Sí
MLP vs Seasonal Naïve	-1,898	-2,803; -1,119	Sí
N-BEATS vs Seasonal Naïve	-1,065	-1,674; -0,464	Sí
ETS vs SARIMA	-0,698	-1,370; -0,102	Sí
ETS vs Holt-Winters	-1,127	-1,891; -0,450	Sí
ETS vs LightGBM	-1,854	-2,800; -1,109	Sí
SARIMA vs Holt-Winters	-0,429	-1,109; 0,344	No

Fuente: elaboración propia. Método: percentil bootstrap (Efron & Tibshirani, 1993), $B = 1\,000$ remuestras, $SEED = 42$, misma unidad de remuestreo (serie) que en la Tabla 22. Las nueve comparaciones significativas al 95 % se mantienen significativas al nivel ajustado del 99,5 %; SARIMA frente a Holt-Winters no es significativa en ninguno de los dos niveles.

Valores exportados en resultados_bonferroni.csv.

La Tabla 24 sintetiza el modelo con mejor rendimiento para cada una de las seis métricas de la comparativa, identificando al ganador global del experimento.

Tabla 24. Modelo con mejor rendimiento por métrica.

Métrica	Mejor modelo	Valor medio
MAE	ETS	476,199
RMSE	ETS	559,207

MAPE	ETS	10,571 %
sMAPE	ETS	10,005 %
MASE	ETS	1,017
WAPE	ETS	10,081 %


Fuente: elaboración propia. ETS obtiene el mejor resultado en las seis métricas evaluadas. Los valores corresponden a la media sobre los folds del walk-forward para N = 200 series del dataset M4 Financial Monthly.

5.4.DESAGREGACIÓN POR DECILES DE VOLUMEN

El análisis por deciles de volumen absoluto constituye una aproximación a la materialidad financiera —por lo que se denomina análisis ponderado por magnitud— y no una medición directa en términos monetarios comparables, dado que el conjunto M4 Financial no garantiza que todas las series compartan moneda, unidad o naturaleza contable.

Los deciles se calculan sobre la submuestra de 200 series ya seleccionada (es decir, después del muestreo estratificado), tomando la media del valor absoluto de cada serie únicamente sobre los primeros 54 meses (la ventana de entrenamiento del primer fold walk-forward), de modo que D1 agrupa las series de menor volumen medio y D10 las de mayor volumen medio. Esta decisión corrige una versión previa del análisis que calculaba el volumen medio sobre la historia completa de cada serie, incluidos periodos que en algunos folds forman parte del horizonte de evaluación: aunque esto nunca constituyó fuga de datos hacia el ajuste de los modelos (ningún modelo recibe la etiqueta de decil como feature), sí introducía información no disponible en el momento de cada pronóstico en la clasificación interpretativa. Con la ventana inicial como base, la clasificación por decil de cada serie es fija y se calcula exclusivamente con datos anteriores al primer horizonte de evaluación de cualquier fold. Esta corrección cambia de forma apreciable la composición de los deciles: el 71,5 % de las series de la submuestra cambia de decil respecto a la clasificación basada en la historia completa (correlación de rango de Spearman entre ambas clasificaciones: 0,825).

Figura 3. Contribución al error absoluto total por decil de volumen y modelo.



Fuente: elaboración propia. D1 = decil de menor volumen absoluto; D10 = mayor volumen. Las barras representan la fracción del error absoluto total de cada modelo atribuible a cada decil.

Tabla 25. WAPE medio por modelo y decil de volumen.


Decil	SNaive	ETS	Holt-Winters	SARIMA	LightGBM	MLP	N-BEATS
D1	20,0 %	14,6 %	17,7 %	15,9 %	15,8 %	16,1 %	17,4 %
D2	13,3 %	8,7 %	9,9 %	9,4 %	11,4 %	11,3 %	10,9 %
D3	10,2 %	7,6 %	8,7 %	7,5 %	8,8 %	8,7 %	9,0 %
D4	17,2 %	12,9 %	14,5 %	14,1 %	14,7 %	14,4 %	15,0 %
D5	17,8 %	13,3 %	14,9 %	14,3 %	15,1 %	15,2 %	16,3 %
D6	16,5 %	12,6 %	14,7 %	13,7 %	13,9 %	14,2 %	15,2 %
D7	13,4 %	8,2 %	10,3 %	8,7 %	10,4 %	9,9 %	11,4 %
D8	10,9 %	8,6 %	9,6 %	9,5 %	9,1 %	9,2 %	9,5 %
D9	10,8 %	7,7 %	8,1 %	8,3 %	8,7 %	10,1 %	8,7 %
D10	8,6 %	6,9 %	7,9 %	7,9 %	8,1 %	7,7 %	7,8 %

Fuente: elaboración propia. WAPE medio calculado sobre el conjunto de evaluaciones fold × serie agrupadas por decil de volumen absoluto de la serie (D1 = menor volumen, D10 = mayor volumen). El promedio de ETS en D8–D10 es 7,8 % (media de las medias por decil) o 7,7 % (WAPE agregado directamente sobre las filas de esos tres deciles), consistente con la cifra de 7,7 % citada en el texto; el de Seasonal Naïve en esos mismos deciles es 10,1 % o 10,0 % respectivamente, consistente con el 10,0 % citado.

5.5.COMPARATIVA VISUAL DE PRONÓSTICOS

La Figura 4 presenta los sMAPE medios con sus desviaciones estándar en formato de barras, facilitando la comparación directa entre familias de modelos.

Figura 4. sMAPE medio por modelo (barras) con desviación estándar (barras de error). Orden ascendente de error.



Fuente: elaboración propia. Menor sMAPE indica mayor precisión. Las barras de error representan la desviación estándar sobre el conjunto de evaluaciones fold × serie.

La desviación estándar del sMAPE representa entre el 90 % y el 113 % de la media según el modelo (p. ej., ETS: media 10,0 %, desviación 10,5 %), lo que produce barras de error de magnitud comparable a la propia barra. Esta dispersión combina la heterogeneidad entre las 200 series de la submuestra con la variabilidad temporal entre *folds* de una misma serie; ambas fuentes no se distinguen visualmente en la figura. Se recomienda complementarla con la tabla de CV temporal por serie, que aísla específicamente la componente temporal.

Como cierre del capítulo, la Tabla 26 sintetiza el grado de cumplimiento de los criterios de éxito predefinidos en la Tabla 16.

Tabla 26. Cumplimiento de los criterios de éxito predefinidos.

Criterio	Umbral predefinido	Resultado experimental	Cumplimiento
sMAPE global	Reducción ≥ 1 pp absoluto respecto al Seasonal Naïve	Los seis modelos reducen $\geq 1,065$ pp; el mejor (ETS) alcanza -3,852 pp	Cumplido
MASE global	MASE $< 1,0$, evaluado por modelo	Mejor valor: 1,017 (ETS); ningún modelo baja de 1,0	No cumplido
WAPE por volumen	El WAPE del modelo no supera al del baseline en los deciles de mayor volumen	ETS reduce el WAPE de los deciles D8–D10 frente al Seasonal Naïve	Cumplido
Estabilidad temporal	CV del sMAPE < 25 % para todos los modelos (aspiracional)	CV temporal por serie entre 47,2 % y 55,1 %; todos los modelos superan el umbral	No cumplido (aspiracional)
Significación estadística	Diferencia frente al baseline sostenida; IC bootstrap excluye el cero	El IC al 95 % excluye el cero en los seis modelos evaluados	Cumplido

Fuente: elaboración propia.

6. DISCUSIÓN Y ANÁLISIS DE RESULTADOS

El presente capítulo aborda la interpretación crítica de los resultados presentados en el Capítulo 5, el análisis de las ventajas y desventajas de cada familia de modelos evaluada, y la propuesta del *framework* de criterios heurísticos preliminares de selección. Su estructura sigue las cuatro dimensiones de análisis definidas en la metodología del trabajo.

6.1. INTERPRETACIÓN DE LA COMPARATIVA GLOBAL


El primer hallazgo relevante es que todos los modelos estadísticos clásicos superan al Seasonal Naïve en más de 1 punto porcentual absoluto de sMAPE, criterio predefinido en la Tabla 16. El mejor modelo en términos de sMAPE global es ETS (AutoETS) con 10,005 % de error medio, frente al 13,667 % del Seasonal Naïve.

El resultado más llamativo de la comparativa es que los métodos estadísticos clásicos (media sMAPE: 10,662 %) superan a los modelos de machine learning y deep learning (media sMAPE: 11,967 %). Esta conclusión debe limitarse estrictamente a las condiciones del diseño experimental: no puede descartarse que el resultado se deba, al menos en parte, a factores no relacionados con la capacidad intrínseca de cada familia de modelos, como el ajuste manual —no automatizado— de los hiperparámetros de LightGBM, MLP y N-BEATS (frente a la selección automática por AICc de ETS/SARIMA), el entrenamiento en CPU sin aceleración GPU, el número limitado de épocas (40 para MLP, 20 para N-BEATS), la heterogeneidad del dataset M4 Financial, el tamaño reducido de la submuestra (200 series), y la arquitectura simplificada de N-BEATS (2 stacks, 3 bloques por stack). En este experimento, los modelos globales no mostraron ventaja de precisión frente a los estadísticos clásicos bajo series con longitud mediana de 175 meses y una submuestra heterogénea. Esto es consistente con la literatura que sugiere que el machine learning tiende a beneficiarse de series más largas o de un mayor número de series con patrones compartidos (Cerqueira et al., 2022), pero no debe interpretarse como una regla general: los modelos de global forecasting pueden, en principio, aprender de múltiples series cortas si estas comparten patrones suficientemente similares, condición que no se verificó explícitamente en esta submuestra.

Comparación con la literatura del M4. Los resultados publicados del M4 no desagregan el desempeño por categoría (Financial, Macro, Micro, etc.), sino por frecuencia temporal, por lo

que no existe un benchmark oficial estrictamente comparable a la submuestra Financial Monthly de este trabajo. Como referencia aproximada, el método Theta —uno de los más competitivos del M4 original— obtuvo un sMAPE de 13,003 % sobre el conjunto Monthly completo, todas las categorías combinadas (Makridakis, Spiliotis y Assimakopoulos, 2018); ETS obtiene en este trabajo un sMAPE de 10,005 % específicamente sobre Financial Monthly, sensiblemente inferior. Esta diferencia no debe interpretarse como evidencia de una implementación superior, sino que probablemente refleja que las series financieras del M4 son, en promedio, más predecibles por métodos estadísticos que el conjunto Monthly completo. Más relevante para este trabajo es un hallazgo cualitativo del M4 original: de los seis métodos de machine learning puro presentados a la competición, ninguno superó al benchmark de combinación (Comb) y solo uno superó al Naïve2 (Makridakis et al., 2020). Este patrón —modelos de ML puro con desempeño inferior a los benchmarks estadísticos combinados— es cualitativamente consistente con lo observado en este trabajo para LightGBM, MLP y N-BEATS frente a ETS, SARIMA y Holt-Winters, aunque los protocolos y las categorías de datos no sean idénticos. La Figura 5 ofrece una visión normalizada del rendimiento relativo de cada modelo en el conjunto completo de métricas.

Figura 5. Mapa de calor de métricas normalizado. Los valores se normalizan por columna en [0,1]; menor valor (verde) indica mejor rendimiento.



6.2.RELACIÓN ENTRE COMPLEJIDAD ALGORÍTMICA Y PRECISIÓN

La taxonomía de cuatro niveles de complejidad planteada en el diseño experimental —base-line, estadístico clásico, machine learning y deep learning— no se traduce en una mejora monotónica del error. Este resultado contradice la narrativa simplista de que "más complejo siempre es mejor" y está en línea con los hallazgos de Makridakis et al. (2022) en la competición M5, donde los métodos estadísticos superaron a muchos algoritmos de aprendizaje automático en series con patrones regulares.

Conviene distinguir cuatro factores que a menudo se confunden bajo la etiqueta genérica de "tamaño de datos": la longitud temporal de cada serie individual, el número total de ventanas de entrenamiento generadas por el protocolo walk-forward, el número de series en la submuestra, y el grado de homogeneidad de patrones entre esas series. Los modelos globales dependen principalmente de los dos últimos factores, mientras que los modelos locales dependen exclusivamente del primero. Esta distinción es relevante porque una submuestra con pocas series pero muy homogéneas podría favorecer a los modelos globales más que una submuestra más numerosa pero heterogénea, como es el caso del M4 Financiamiento.

La explicación más plausible para el rendimiento inferior de los modelos globales en esta evaluación combina varios factores confirmados en este experimento. En primer lugar, el rango de longitud de las series de la submuestra está sistemáticamente por debajo del umbral a partir del cual los modelos de gradient boosting y deep learning comienzan a aprovechar su mayor capacidad expresiva (Cerqueira et al., 2022). En segundo lugar, el paradigma de global forecasting requiere que las 200 series de la submuestra compartan patrones suficientemente similares como para que el entrenamiento cruzado sea beneficioso; si los patrones son heterogéneos, el modelo puede no converger a representaciones útiles en el número de épocas empleado. A estos dos factores se suman condiciones prácticas del experimento: los hiperparámetros de LightGBM, MLP y N-BEATS se fijaron manualmente, sin la búsqueda automatizada que sí reciben ETS y SARIMA (selección por AICc); el entrenamiento se realizó en CPU con un número reducido de épocas (20 para N-BEATS); y la arquitectura de N-BEATS se simplificó deliberadamente (2 stacks, 3 bloques por stack) respecto a configuraciones más profundas habituales en la literatura (Oreshkin et al., 2020). Ninguno de estos factores invalida la com-

paración —reflejan restricciones reales de recursos computacionales, no errores de implementación—, pero sí explican por qué estos modelos podrían no representar el límite superior de su potencial bajo condiciones menos restrictivas.

Coste computacional. Se instrumentó un benchmark homogéneo (`benchmark_timing.py`) que mide, sobre el mismo fold walk-forward —posición relativa 0, disponible para las 200 series de la submuestra— y en el mismo entorno de ejecución, los tiempos de ajuste e inferencia, el tamaño serializado, la memoria pico y la utilización media y máxima de CPU de los siete modelos. Para los modelos locales (SNaive, ETS, Holt-Winters, SARIMA) el tiempo de ajuste es la suma de 200 ajustes independientes, uno por serie; para los modelos globales (LightGBM, MLP, N-BEATS) es una única llamada a `fit_global()` sobre las 200 series simultáneamente. La Tabla siguiente presenta los resultados.

Tabla 27. Coste computacional de los siete modelos sobre el mismo fold, la misma muestra y el mismo entorno de ejecución.

Modelo	Ajuste total (s)	Ajuste medio (s/serie)	Inferencia total (s)	Inferencia media (s/serie)	Tamaño serializado (KB)	Memoria pico (MB)	CPU medio (%)	CPU máximo (%)
SNaive	< 0,001	< 0,001	0,001	< 0,001	0,3	635,3	No registrado ¹	No registrado ¹
ETS	24,1	0,121	0,007	< 0,001	15,0	730,7	98,0	115,2
Holt-Winters	32,1	0,160	0,365	0,002	28,2	732,0	96,6	129,7
SARIMA	46,5	0,233	0,046	< 0,001	10,3	734,7	98,3	124,2
LightGBM	1,0 *	—	0,576	0,003	736,3	775,8	641,0	1153,8
MLP	45,4 *	—	0,108	< 0,001	63,4	848,9	708,9	1092,6
N-BEATS	80,8 *	—	0,401	0,002	1345,1	859,0	837,7	1091,4

Fuente: elaboración propia (benchmark_timing.py). * En los modelos globales, el ajuste corresponde a una única llamada sobre las 200 series, por lo que no se calcula el promedio por serie. La memoria pico representa el RSS máximo del proceso durante el ajuste e incluye aproximadamente 635 MB de consumo base del entorno. En CPU, el 100 % equivale a un núcleo lógico saturado y los valores superiores indican paralelismo multinúcleo. Mediciones realizadas sobre la misma muestra, el mismo fold y el mismo equipo: Windows 11, Intel Core i7-1355U, 31,7 GB de RAM y sin GPU. ¹ No registrado debido a que la ejecución finalizó antes del primer intervalo de muestreo.

Los resultados muestran que el paradigma global no garantiza por sí mismo una ventaja de coste computacional. LightGBM es, con diferencia, el modelo entrenable más rápido de ajustar, excluyendo SNaive, que no requiere un proceso de estimación paramétrica comparable: necesita 1,0 s para las 200 series, frente a los 24,1 s de ETS, el más rápido de los modelos estadísticos locales con ajuste paramétrico. Este resultado se relaciona con su entrenamiento global mediante una única llamada y con el aprovechamiento intensivo del paralelismo multi-núcleo, reflejado en un uso medio de CPU del 641,0 %. Sin embargo, esta ventaja no se extiende a todas las arquitecturas globales: N-BEATS presenta el mayor tiempo de ajuste de los siete modelos evaluados, con 80,8 s, superando a SARIMA —46,5 s—, el más costoso de los modelos locales; por su parte, MLP requiere 45,4 s, un tiempo comparable al de los modelos estadísticos clásicos. Las redes neuronales también presentan una utilización intensiva de CPU, con valores medios del 708,9 % para MLP y del 837,7 % para N-BEATS, mientras que los modelos estadísticos registran valores próximos al 100 %, compatibles con una ejecución predominantemente limitada a un núcleo lógico.

En cuanto a la memoria, N-BEATS registra el mayor valor pico, con 859,0 MB, seguido de MLP, con 848,9 MB, y LightGBM, con 775,8 MB. No obstante, estos valores corresponden al RSS total del proceso de Python e incluyen aproximadamente 635 MB de consumo base asociado al entorno y a las bibliotecas cargadas, por lo que no representan la memoria incremental atribuible exclusivamente a cada modelo. Finalmente, las diferencias también son relevantes en el tamaño serializado: N-BEATS —1.345,1 KB— y LightGBM —736,3 KB— ocupan más espacio en disco que los modelos estadísticos clásicos —entre 10,3 y 28,2 KB— y que MLP —63,4 KB—. En conjunto, los resultados muestran que LightGBM ofrece el mejor tiempo de ajuste, aunque a costa de una mayor utilización paralela de CPU y de un tamaño serializado superior al de los métodos estadísticos; N-BEATS presenta los mayores requerimientos relativos de tiempo, memoria pico y almacenamiento bajo las condiciones evaluadas.

6.3. ANÁLISIS DE MATERIALIDAD: DECILES DE VOLUMEN

La Figura 3 muestra que el error absoluto se concentra en mayor medida en los deciles de mayor volumen (D8–D10): estos tres deciles acumulan el 35,7 % del error absoluto total (MAE acumulado sobre todas las series y folds), frente al 22,1 % correspondiente a los deciles D1–D3. Esta concentración es moderada, no extrema, una vez que los deciles se calculan exclusivamente a partir de la ventana inicial de entrenamiento (sin información de los periodos de

evaluación); refleja la distribución heterogénea de volúmenes financieros en la submuestra. Lo relevante para la evaluación orientada al valor es si los modelos más precisos en sMAPE también reducen la contribución al error en los segmentos de mayor magnitud. La respuesta es afirmativa: en los deciles D8–D10, ETS obtiene el WAPE más bajo (7,7 %), frente al 10,0 % del Seasonal Naïve, una reducción del 22,9 % en el error relativo ponderado por volumen. El ranking de modelos en los deciles de mayor volumen es consistente con el ranking global, lo que confirma que la ventaja de ETS no se circunscribe a series de menor cuantía.

6.4. ESTABILIDAD TEMPORAL Y CONFIABILIDAD OPERACIONAL

La Figura 2 muestra la evolución del sMAPE promedio por fold walk-forward para los modelos locales. El análisis de estabilidad temporal mide el coeficiente de variación (CV) del sMAPE calculado entre los folds de cada serie individual y promediado sobre la submuestra (valores exportados en resultados_cv_temporal.csv). Las series con un único fold retenido (20 de las 200 series de la submuestra, según la distribución de folds documentada en la metodología) no permiten estimar variabilidad temporal, ya que la desviación estándar del sMAPE no está definida con $n = 1$; estas series se excluyen del cálculo, que se realiza sobre las 180 series restantes con dos o más folds retenidos. Este indicador difiere del CV-sMAPE global reportado en las Tablas 19 y 21 —calculado como σ/μ sobre el conjunto agregado de evaluaciones fold $\times$ serie—, que captura conjuntamente la variabilidad temporal y la heterogeneidad entre series; por ello, ambos valores no son directamente comparables. Con este cálculo, la media del CV temporal de ETS se sitúa en un 53,8 % (mediana: 51,4 %; rango intercuartílico: 34,6 %–66,2 %) y la de SARIMA en un 55,1 % (mediana: 50,9 %; rango intercuartílico: 37,2 %–72,4 %), valores que superan ampliamente el umbral del 25 % predefinido en la Tabla 16: entre el 84,4 % y el 90,6 % de las series individuales, según el modelo, presenta un CV superior a ese umbral. Este resultado indica que ningún modelo alcanza el criterio de estabilidad, lo que debe interpretarse correctamente: los valores elevados indican una considerable variabilidad temporal dentro de muchas de las series evaluadas; la heterogeneidad de comportamientos entre series se refleja en la distribución de esos CV individuales —con una dispersión amplia entre el percentil 25 y el 75—, no en un único CV global agregado, y no implica necesariamente un deterioro sistemático del modelo en el tiempo. Con series individuales de comportamiento más homogéneo —como las de un único dominio contable corporativo— la estabilidad esperada sería considerablemente mayor.

Nota sobre el criterio MASE. La Tabla 18 reporta valores de MASE superiores a 1,0 para todos los modelos, lo que indica que el error absoluto medio de los pronósticos supera el error absoluto medio del naïve estacional calculado en muestra. Este resultado no contradice la mejora observada en sMAPE (que sí supera al baseline fuera de muestra), sino que refleja una característica estructural de las series M4 Financial: presentan tendencias y cambios de régimen que hacen que los errores fuera de muestra sean sistemáticamente mayores que los errores en muestra del naïve estacional. Esta observación subraya la importancia de complementar el MASE con métricas porcentuales como el sMAPE a la hora de interpretar el desempeño comparativo en contextos con series no estacionarias (Hyndman y Athanasopoulos, 2021).

6.5.PROPUUESTA PRELIMINAR DE CRITERIOS DE SELECCIÓN DE MODELOS

Con base en los resultados obtenidos, la Tabla 28 sintetiza la propuesta preliminar de criterios heurísticos de selección de modelos para entornos de FP&A, organizada en torno a tres reglas orientativas derivadas de los hallazgos empíricos.

Las reglas que se presentan a continuación constituyen una propuesta preliminar, no un conjunto de umbrales cuantitativos validados de forma independiente. Los valores numéricos de R1 y R3 proceden de referencias de la literatura y de convenciones prácticas razonables, no de una comparación directa realizada en este experimento entre segmentos por encima y por debajo de esos umbrales específicos.

Tabla 28. Propuesta preliminar de criterios heurísticos de selección de modelos de pronóstico para FP&A, no validada externamente.

Regla	Condición de aplicación	Recomendación
R1 — Longitud de serie	Series con menos de 120 observaciones (10 años mensuales)	Bajo historiales cortos, los resultados de este experimento y la literatura de referencia sugieren comenzar la evaluación con ETS o Holt-Winters, con selección automática de componentes, sin descartar por ello el uso de modelos de ML/DL

		cuando exista suficiente información transversal (series homogéneas adicionales) que compense la brevedad del historial individual.
R2 — Volumen y criticidad	Series situadas en los deciles D8–D10 de volumen o, en una aplicación corporativa futura, cuentas clasificadas como materialmente relevantes.	Priorizar la estabilidad temporal (CV-sMAPE) sobre la mínima media de error: ante dos modelos con precisión media similar, preferir el de menor variabilidad entre folds, dado que la previsibilidad del error es tan relevante como su magnitud para la planificación financiera. (Umbral ilustrativo, no derivado de una validación con decisiones reales de FP&A.)
R3 — Datos cross-series	Colección con series heterogéneas o sin garantía de patrones similares	Global forecasting (LightGBM, MLP, N-BEATS) solo cuando exista una colección de series suficientemente amplia y homogénea, determinada mediante validación interna, y no como umbral numérico fijo derivado de este experimento.

Fuente: elaboración propia a partir de los resultados del experimento y la literatura de referencia (Cerqueira et al., 2022; Januschowski et al., 2020).

Tabla 29. Evidencia experimental y bibliográfica por regla del framework de selección.


Regla	Evidencia experimental propia	Evidencia bibliográfica	Grado de confianza

R1 (longitud < 120 obs)	El experimento no comparó explícitamente segmentos por debajo/en-cima de 120 observaciones	Alineado direccionalmente con Cerqueira et al. (2022); la cifra de 120 (10 años) es una convención práctica, no derivada de una fuente específica	Bajo
R2 (priorizar CV sobre sMAPE)	El experimento sí calculó el CV temporal por modelo, y ningún modelo alcanza el umbral aspiracional de 25 %	No se identificó literatura que demuestre que un menor CV se traduce en mejores decisiones de FP&A	Bajo
R3 (colección amplia y homogénea)	El experimento no incluyó escenarios con ≥ 500 series (la submuestra es de 200); no puede confirmarse directamente	Se apoya en Cerqueira et al. (2022) y Januschowski et al. (2020), que documentan el beneficio general de más datos para ML, aunque ninguno fija el umbral exacto de 500	Bajo-medio

Fuente: elaboración propia

En la práctica, un equipo de FP&A aplicaría este framework de forma secuencial durante el ciclo de planificación: clasificaría primero su cartera de cuentas por longitud de historial disponible (R1), identificaría después las cuentas de mayor materialidad financiera para priorizar en ellas la estabilidad del pronóstico (R2) y, finalmente, reevaluaría de forma periódica la conveniencia de modelos globales a medida que la organización acumule un número suficiente de series homogéneas (R3).

Figura 6. Diagrama de decisión secuencial de la propuesta preliminar de criterios heurísticos de selección de modelos para FP&A. Propuesta no validada externamente.



Fuente: elaboración propia. El diagrama sigue el orden de aplicación de las reglas R1 (longitud de serie), R2 (materialidad del volumen) y R3 (disponibilidad de datos *cross-series*) descrito en el texto.

Sobre R2 en particular: dado que ningún modelo evaluado alcanza el umbral de estabilidad predefinido ($CV\text{-}sMAPE < 25\%$, Tabla 21), la recomendación de "priorizar estabilidad" debe entenderse como una orientación cualitativa —preferir, entre las opciones disponibles, la de menor variabilidad relativa— y no como un criterio que garantice alcanzar un nivel de estabilidad aceptable en términos absolutos.

El *framework* propuesto se centra en precisión, estabilidad y disponibilidad de datos *cross-series*, pero una decisión real de selección de modelos en un entorno de FP&A debe considerar también el coste computacional de ajuste e inferencia, la interpretabilidad del modelo para los equipos financieros, el esfuerzo de mantenimiento del *pipeline*, la disponibilidad de variables exógenas, y la frecuencia de reentrenamiento requerida. Estas dimensiones no se cuantifican en este experimento y quedan como líneas de extensión futura (Capítulo 7).

Debe notarse que estas reglas se derivan de un experimento realizado sobre el dataset M4 Financial Monthly, que agrupa series macroeconómicas e indicadores financieros de naturaleza diversa. Las series contables corporativas típicas de un entorno FP&A —ingresos por línea de producto, gastos por centro de coste, cuentas por cobrar— pueden exhibir una mayor homogeneidad interna y una estacionalidad más regular, lo que podría favorecer en mayor medida a los modelos de global forecasting respecto a lo observado en este experimento. La aplicación directa de los umbrales propuestos a entornos corporativos reales requiere validación empírica adicional con datos propios de cada organización.

6.6.LIMITACIONES DEL EXPERIMENTO

Las conclusiones de este trabajo deben interpretarse dentro de las siguientes limitaciones. En primer lugar, existe una ausencia de datos corporativos directos; el conjunto M4 Financial Monthly agrupa series macroeconómicas y financieras de naturaleza diversa, por lo que sus dinámicas no equivalen estrictamente a las de una cuenta de resultados (P&L) real, sujeta a políticas contables, ciclos presupuestarios y decisiones de gestión. Además, la heterogeneidad del dataset puede favorecer a los métodos estadísticos locales frente a los modelos globales. En segundo lugar, el diseño experimental se restringe a una evaluación en una única frecuencia mensual, omitiendo dinámicas de tesorería u operativas que en la práctica de FP&A requieren a menudo pronósticos diarios o semanales. En tercer lugar, la submuestra de $N = 200$ series, si bien permite estimar intervalos de confianza *bootstrap* con precisión razonable (amplitud de 1,25 pp para la diferencia ETS–Seasonal Naïve; IC 95 %: [-4,52; -3,26]), puede no capturar la totalidad de los patrones presentes en el dataset completo de 8.493 series. En cuarto lugar, los modelos de deep learning se entrenaron con un número limitado de épocas dado el entorno de CPU; con más recursos computacionales, su rendimiento podría mejorar. Ligado a esta restricción tecnológica, la comparación de hiperparámetros entre familias no es plenamente equitativa: AutoETS y AutoARIMA realizan una búsqueda automática exhaustiva por serie, mientras que los modelos de ML/DL exploran un espacio de hiperparámetros fijado por el equipo (Tabla 13), lo que puede favorecer relativamente a los primeros. Asimismo, MAE y RMSE se reportan en unidades originales y se promedian entre series de escalas potencialmente muy distintas, por lo que deben interpretarse como métricas descriptivas para comparar modelos sobre la misma muestra, no como un error medio en una unidad financiera co-

mún. El coste computacional, antes no medido de forma homogénea, se instrumentó y reportó en la Tabla 27 (`benchmark_timing.py`), revelando que el paradigma global no garantiza por sí solo una ventaja de tiempo de ajuste (N-BEATS resultó el modelo más lento de los siete evaluados). La medición incorporó el tiempo de ajuste e inferencia, el tamaño serializado, la memoria pico y la utilización media y máxima de CPU. No obstante, la memoria se registró como RSS total del proceso de Python, por lo que incluye aproximadamente 635 MB correspondientes al entorno base y a las bibliotecas cargadas y no representa la memoria incremental atribuible exclusivamente a cada modelo. Asimismo, el uso de CPU de SNaive no pudo registrarse debido a que su ejecución finalizó antes del primer intervalo de muestreo. Estas condiciones limitan parcialmente la granularidad de la comparación, aunque todos los modelos se midieron sobre la misma muestra, el mismo *fold* y el mismo entorno de ejecución.

En quinto lugar, el experimento no incorpora variables exógenas (indicadores macroeconómicos, calendarios de estacionalidad) que los pronosticadores corporativos utilizan habitualmente para mejorar la precisión en horizontes medios; su inclusión podría beneficiar especialmente a los modelos globales. En sexto lugar, la evaluación asigna relevancia económica basándose en el tamaño de la serie, lo que introduce posibles errores por aproximar la materialidad mediante el volumen, ya que en la práctica contable una cuenta de menor volumen puede representar un riesgo financiero mucho más crítico que una cuenta masiva. En séptimo lugar, la metodología se ha centrado exclusivamente en la exactitud del pronóstico puntual, presentando una ausencia de intervalos de predicción y calibración de la incertidumbre, herramientas que resultan indispensables para evaluar correctamente los riesgos. Finalmente, destaca la ausencia de validación empírica con profesionales en ejercicio de FP&A, lo que le confiere al framework propuesto un carácter preliminar. Todas estas limitaciones quedan documentadas como líneas de investigación futura en el Capítulo 7.

7. CONCLUSIONES Y TRABAJO FUTURO

7.1. CONCLUSIONES

El presente trabajo ha desarrollado y evaluado un *pipeline* modular de pronóstico de series temporales financieras mensuales, con el objetivo de comparar el desempeño de siete arquitecturas de modelos bajo un protocolo de backtesting temporal estrictamente controlado. Las conclusiones que se presentan a continuación se articulan directamente con cada uno de los objetivos específicos formulados en el Capítulo 3.

OE1 — Revisión del estado del arte. La revisión bibliográfica estructurada permitió identificar cuatro familias de modelos con una presencia sólida en los estudios y benchmarks analizados sobre series temporales financieras: métodos estadísticos clásicos (ETS, Holt-Winters y SARIMA), algoritmos de machine learning basados en gradient boosting (LightGBM), arquitecturas de aprendizaje profundo tabular (MLP) y arquitecturas nativas para series temporales (N-BEATS). Asimismo, los estudios revisados pusieron de manifiesto que la selección del modelo no debe basarse únicamente en su sofisticación algorítmica, sino que debe considerar las características específicas de las series, como su longitud, estacionariedad, presencia de cambios estructurales y horizonte de planificación. En consecuencia, este objetivo se considera plenamente alcanzado.

OE2 — Implementación del *pipeline* modular. Se desarrolló un *pipeline* diseñado para favorecer la reproducibilidad en Python con separación estricta de responsabilidades entre módulos: `data_loader.py`, `preprocessor.py`, `backtesting.py`, `evaluation.py`, `visualization.py` y el directorio `models/`, que contiene una implementación independiente por familia de modelos. Cada implementación sigue la interfaz `BaseForecaster` o `GlobalBaseForecaster`, lo que permite al cuaderno orquestador tratar todos los modelos de forma uniforme. La arquitectura de importación por bloques `try/except` garantiza que el fallo de un modelo no interrumpe la evaluación de los restantes. Este objetivo se considera plenamente alcanzado.

OE3 — Protocolo walk-forward sin fuga de datos. Se implementó un motor de backtesting temporal con expanding window, step de 12 meses y ventana inicial de 54 meses, que genera múltiples iteraciones de evaluación independientes por serie (hasta un máximo de cinco repeticiones, `max_folds = 5`). La disyunción estricta entre los conjuntos de entrenamiento y evalua-

ción está garantizada de forma determinística por el diseño algorítmico del particionado temporal. Como medida de control adicional, la función *verify_no_leakage* operó como un test unitario sobre las 200 series de la submuestra, confirmando empíricamente la ausencia de fuga de información en la totalidad de la ejecución. Este objetivo se considera plenamente alcanzado y constituye la garantía metodológica fundamental del trabajo.

OE4 — Evaluación con seis métricas. Se implementaron y validaron contra ejemplos calculados manualmente seis métricas de evaluación: MAE, RMSE, MAPE, sMAPE, MASE y WAPE. Las 14 pruebas unitarias del módulo `evaluation.py` pasan sin errores. El análisis se realizó tanto a nivel global (media sobre todas las series y folds) como desagregado por decil de volumen absoluto. Adicionalmente, se aplicó un test de bootstrap percentil ($B = 1\,000$ remuestras, $N = 200$ series) que confirmó que la mejora de ETS sobre el baseline es estadísticamente significativa al 95 % (IC: [-4,52; -3,26] pp). Este objetivo se considera plenamente alcanzado.

OE5 — Propuesta preliminar de criterios de selección de modelos. Con base en los resultados del backtesting, se propone un conjunto preliminar de tres criterios heurísticos de selección, sintetizado en la Tabla 28: (R1) para series con menos de 120 observaciones, los métodos estadísticos clásicos ofrecen el mejor balance entre precisión y estabilidad; (R2) para las cuentas de mayor volumen financiero, la estabilidad temporal debe priorizar sobre la mínima media de error; (R3) el paradigma de *global forecasting* resulta preferible cuando exista una colección de series suficientemente amplia y homogénea, determinada mediante validación interna y no mediante un umbral numérico fijo derivado de este experimento. Este objetivo se considera parcialmente alcanzado, dado que los criterios propuestos son heurísticos y preliminares; una extensión futura con mayor variedad de datasets y validación con usuarios permitiría derivar umbrales cuantitativos más robustos.

Conclusión transversal. El hallazgo empírico más relevante de la comparativa es que los métodos estadísticos clásicos —ETS, Holt-Winters y SARIMA— superan a los modelos de machine learning y deep learning en precisión predictiva global sobre el conjunto M4 Financial Monthly. Sin embargo, ninguna familia algorítmica logra alcanzar el umbral aspiracional de estabilidad. Este resultado general es coherente con la literatura reciente de benchmarking en series de longitud moderada (Makridakis et al., 2022; Cerqueira et al., 2022). Al respecto, resulta imperativo establecer una conclusión explícita sobre los criterios de éxito no cumplidos. En las condiciones de este experimento, los modelos no lograron satisfacer de manera generalizada

ni el objetivo de precisión relativa ($MASE < 1.0$) ni el criterio de estabilidad temporal (CV del $sMAPE < 25\%$). Este incumplimiento conjunto no puede atribuirse exclusivamente a la volatilidad, el ruido y la heterogeneidad intrínseca del dataset empleado: también depende de la forma de cálculo elegida para el CV temporal (dentro de cada serie, sensible a medias de $sMAPE$ cercanas a cero), del reducido número de folds disponible para una parte de la submuestra, de la distinta composición de series entre posiciones de fold y de la configuración de hiperparámetros de los modelos evaluados. Esto confirma que el establecimiento de estos umbrales operó con un carácter estrictamente aspiracional que no invalida el ranking comparativo. En términos operativos, bajo las condiciones del presente experimento — $N = 200$ series, longitud mediana de 175 meses, entrenamiento en CPU sin optimización exhaustiva de hiperparámetros—, los modelos de machine learning y deep learning no ofrecieron ventajas en precisión. No obstante, esto no debe derivar en una recomendación general de no invertir en arquitecturas avanzadas. Organizaciones con colecciones de series más homogéneas, capacidad de incorporar múltiples variables exógenas y acceso a infraestructura de procesamiento GPU podrían extraer un valor predictivo superior de estas tecnologías.

Finalmente, en cuanto a su utilidad real, el pipeline programático desarrollado constituye un entorno válido y diseñado para favorecer la reproducibilidad de la evaluación algorítmica bajo las versiones, semillas y condiciones documentadas. Por su parte, la reflexión sobre la mejora empresarial derivada del framework de selección propuesto debe entenderse como una aplicabilidad potencial orientada a FP&A; dado que el estudio no contó con una empresa participante, el marco requiere de validación externa empírica con profesionales del sector para confirmar su viabilidad antes de guiar decisiones de inversión tecnológica corporativa.

La Tabla 30 resume el grado de cumplimiento de los cinco objetivos específicos, la evidencia que lo sustenta y las limitaciones asociadas a cada uno.

Tabla 30. Grado de cumplimiento de los objetivos específicos: evidencia y limitaciones.

Objetivo	Evidencia	Grado de cumplimiento	Limitación
OE1	Capítulo de contexto y estado del arte; tabla de brechas (Tabla 8)	Alcanzado	Revisión estructurada, sin protocolo formal tipo PRISMA

OE2	Repositorio público con 20/20 pruebas automatizadas superadas	Alcanzado	Validado en un único entorno de ejecución (Python 3.13, CPU)
OE3	Motor walk-forward con verificación automática de ausencia de fuga	Alcanzado	Máximo de 5 folds por serie por coste computacional
OE4	Tablas 17–23 y figuras del capítulo de resultados	Alcanzado	N = 200 series, reducido desde N = 400 por coste computacional
OE5	Propuesta preliminar de tres criterios heurísticos. (Tabla 28)	Parcialmente alcanzado	Pendiente de validación con series corporativas reales de FP&A

Fuente: elaboración propia.

7.2. LÍNEAS DE TRABAJO FUTURO

Las limitaciones documentadas en el Capítulo 6 sugieren las siguientes líneas de investigación que aportarían valor añadido al trabajo realizado, organizadas en dos bloques según su relación con la validación del framework de selección propuesto:

Imprescindibles para validar el framework

- **Validación longitudinal en una organización real:** La prueba definitiva del framework requiere su despliegue en un entorno corporativo. Esto implica un diseño cuasi-experimental para comparar el pronóstico emitido por el pipeline algorítmico frente al pronóstico humano tradicional (el forecast actual de la empresa). Esta comparativa debe medir empíricamente la reducción del error estadístico, la optimización del tiempo invertido por el analista financiero y, en última instancia, evaluar el impacto presupuestario real derivado de una mayor precisión operativa.
- **Validación cualitativa con paneles de expertos:** El marco de selección debe ser sometido al escrutinio de profesionales en ejercicio de FP&A para confirmar que los criterios cuantitativos considerados y las orientaciones heurísticas propuestas

están alineados con la intuición de negocio, las normativas contables y los procesos de toma de decisiones ejecutivas.

- **Análisis de viabilidad económica y costes computacionales:** La adopción de tecnologías de aprendizaje automático avanzado exige medir no solo el desempeño estadístico, sino también el coste computacional (Time-to-Value). Resulta prioritario modelar los costes de implantación (infraestructura de procesamiento, licenciamiento, mantenimiento y talento) frente al valor económico rescatado por la mejora en la predicción.

Ampliaciones técnicas

- **Estrategias de ensamblado y selección dinámica:** En lugar de seleccionar globalmente una única familia de modelos, resulta prometedor implementar una selección dinámica a nivel de serie temporal individual, así como el uso de métodos de ensamblado (*ensemble learning*) para combinar promedios de pronósticos de múltiples algoritmos, maximizando así la robustez del cálculo frente a escenarios de extrema volatilidad.
- **Modelos fundacionales especializados:** Los resultados de Rahimikia et al. (2025) y Zhu et al. (2025) sugieren que los modelos fundacionales preentrenados en grandes volúmenes de datos financieros logran superar las limitaciones del modo zero-shot en entornos heterogéneos. Su evaluación en FP&A bajo el mismo protocolo walk-forward constituye la frontera técnica inmediata de este trabajo.
- **Optimización bayesiana de hiperparámetros con validación temporal:** Sustituir la parametrización manual o exploratoria por una búsqueda bayesiana con validación cruzada temporal interna, maximizando el rendimiento relativo de arquitecturas como LightGBM, MLP y N-BEATS sin comprometer la integridad de la validación externa.
- **Análisis granular de horizontes múltiples:** Desagregar el desempeño predictivo por sub-horizontes (ej., 1–3 meses, 4–6, 7–12, 13–18). Este análisis permitiría identificar qué familia de modelos domina a corto plazo (cierre táctico) frente a la que mejor captura el largo plazo (presupuesto estratégico).
- **Incorporación de variables exógenas:** Transitar de un diseño univariado a uno multivariante que integre indicadores macroeconómicos (tipos de interés, inflación,

índices de actividad) mediante arquitecturas compatibles —como SARIMA con regresores o el Temporal Fusion Transformer—, aportando robustez frente a cambios estructurales frecuentes (Lim et al., 2021).

Referencias bibliográficas

- Ansari, A. F., Stella, L., Turkmen, C., Zhang, X., Mercado, P., Shen, H., Shchur, O., Rangapuram, S. S., Pineda Arango, S., Kapoor, S., Zschiegner, J., Maddix, D. C., Mahoney, M. W., Januschowski, T., de Jong, V., Bohlke-Schneider, M., & Wang, Y. (2024). Chronos: Learning the language of time series. arXiv:2403.07815. <https://arxiv.org/abs/2403.07815>
- Armstrong, J. S. (2001). *Principles of forecasting: A handbook for researchers and practitioners*. Kluwer Academic Publishers. <https://doi.org/10.1007/978-0-306-47630-3>
- Bergmeir, C., & Benítez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences*, 191, 192–213. <https://doi.org/10.1016/j.ins.2011.12.028>
- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5.^a ed.). Wiley.
- Cerqueira, V., Torgo, L., & Mozetič, I. (2020). Evaluating time series forecasting models: An empirical study on performance estimation methods. *Machine Learning*, 109, 1997–2028. <https://doi.org/10.1007/s10994-020-05910-7>
- Cerqueira, V., Torgo, L., & Soares, C. (2022). A case study comparing machine learning with statistical methods for time series forecasting: Size matters. *Journal of Intelligent Information Systems*, 59(2), 415–433. <https://doi.org/10.1007/s10844-022-00713-9>
- Doran, G. T. (1981). There's a S.M.A.R.T. way to write management's goals and objectives. *Management Review*, 70(11), 35–36.
- Efron, B., & Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall/CRC. <https://doi.org/10.1007/978-1-4899-4541-9>
- Fildes, R., Ma, S., & Kolassa, S. (2022). Retail forecasting: Research and practice. *International Journal of Forecasting*, 38(4), 1283–1318. <https://doi.org/10.1016/j.ijforecast.2019.06.004>
- Garza, A., Canseco, M. M., Challú, C., & Olivares, K. G. (2022). StatsForecast: Lightning fast forecasting with statistical and econometric models. arXiv:2207.03175. <https://arxiv.org/abs/2207.03175>
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3.^a ed.). OTexts. <https://otexts.com/fpp3/>

- Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688. <https://doi.org/10.1016/j.ijforecast.2006.03.001>
- Januschowski, T., Wang, Y., Torkkola, K., Erkkilä, T., Hasson, H., & Gasthaus, J. (2020). Forecasting with trees. *International Journal of Forecasting*, 36(1), 167–173. <https://doi.org/10.1016/j.ijforecast.2019.10.004>
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T. Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3146–3154.
- Kolassa, S. (2022). Why the «bet» point forecast depends on the error or accuracy measure. En M. Gilliland, L. Tashman, & U. Sglavo (Eds.), *Business forecasting: Practical problems and solutions* (pp. 113–122). Wiley.
- Lim, B., Arık, S. Ö., Loeff, N., & Pfister, T. (2021). Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4), 1748–1764. <https://doi.org/10.1016/j.ijforecast.2021.03.012>
- Lim, B., & Zohren, S. (2021). Time-series forecasting with deep learning: A survey. *Philosophical Transactions of the Royal Society A*, 379(2194), 20200209. <https://doi.org/10.1098/rsta.2020.0209>
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). *The M4 Competition: Results, findings, conclusion and way forward*. *International Journal of Forecasting*, 34(4), 802–808. <https://doi.org/10.1016/j.ijforecast.2018.06.001>
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M4 competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting*, 36(1), 54–74. <https://doi.org/10.1016/j.ijforecast.2019.04.014>
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting*, 38(4), 1346–1364. <https://doi.org/10.1016/j.ijforecast.2021.11.013>

- Makridakis, S., Spiliotis, E., Hollyman, R., Petropoulos, F., Swanson, N., & Gaba, A. (2025). The M6 forecasting competition: Bridging the gap between forecasting and investment decisions. *International Journal of Forecasting*, 41(4), 1315–1354. <https://doi.org/10.1016/j.ijforecast.2024.11.002>
- Oreshkin, B. N., Carпов, D., Chapados, N., & Bengio, Y. (2020). N-BEATS: Neural basis expansion analysis for interpretable time series forecasting. En *Proceedings of the 8th International Conference on Learning Representations (ICLR 2020)*. <https://openreview.net/forum?id=r1ecqn4YwB>
- Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimeshine, N., Antiga, L., Desmaison, A., Köpf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A., Chilamkurthy, S., Steiner, B., Fang, L., ... Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. *Advances in Neural Information Processing Systems*, 32, 8024–8035.
- Petropoulos, F., Apiletti, D., Assimakopoulos, V., Babai, M. Z., Barrow, D. K., Ben Taieb, S., Bergmeir, C., Bessa, R. J., Bijak, J., Boylan, J. E., Browell, J., Carnevale, C., Castle, J. L., Cirillo, P., Clements, M. P., Cordeiro, C., Cyrino Oliveira, F. L., De Baets, S., Dokumentov, A., . . . Ziel, F. (2022). Forecasting: Theory and practice. *International Journal of Forecasting*, 38(3), 705–871. <https://doi.org/10.1016/j.ijforecast.2021.11.001>
- Rahimikia, E., Ni, H., & Wang, W. (2025). Re(Visiting) time series foundation models in finance. arXiv:2511.18578. <https://arxiv.org/abs/2511.18578>
- Seabold, S., & Perktold, J. (2010). Statsmodels: Econometric and statistical modeling with Python. En *Proceedings of the 9th Python in Science Conference* (pp. 92–96). <https://doi.org/10.25080/Majora-92bf1922-011>
- Zhou, H., Zhang, S., Peng, J., Zhang, S., Li, J., Xiong, H., & Zhang, W. (2021). Informer: Beyond efficient transformer for long sequence time-series forecasting. *Proceedings of the AAAI Conference on Artificial Intelligence*, 35(12), 11106–11115. <https://doi.org/10.1609/aaai.v35i12.17325>
- Zhu, Z., Chen, H., Qu, Q., & Chung, V. (2025). FinCast: A foundation model for financial time-series forecasting. En *Proceedings of the 34th ACM International Conference on Information*

and *Knowledge Management* (CIKM 2025) (pp. 4539–4549).
<https://doi.org/10.1145/3746252.3761261>

8. ANEXO A. CÓDIGO FUENTE Y DATOS ANALIZADOS

El código fuente completo desarrollado durante este trabajo se encuentra disponible en el siguiente repositorio de GitHub:

https://github.com/jmmachadol/tfm_FP-A

8.1. ESTRUCTURA DEL REPOSITORIO


```
tfm_FP-A/
├─ LICENSE.md
├─ README.md
├─ requirements.txt
├─ run_experiment.py
├─ benchmark_timing.py          # Benchmark homogéneo de coste computacional (Tabla 27)
├─ update_results_latex.py      # Actualiza cap5_resultados.tex y cap6_discusion.tex
│                               # con los resultados reales (fuente LaTeX del Anexo)
├─ export_to_word.py / .sh     # Exporta la memoria LaTeX a Word
│
├─ src/
│   ├── config.py              # Parámetros del experimento y rutas
│   ├── utils.py               # Semillas globales y logging
│   ├── data_loader.py         # Descarga con caché del M4 Financial Monthly
│   ├── preprocessor.py        # Filtrado, submuestra estratificada y escalado
│   ├── backtesting.py         # Motor walk-forward y verificación de fuga
│   ├── evaluation.py          # Métricas y bootstrap
│   ├── visualization.py       # Generación de figuras
│   └─ models/
│       ├── base.py
│       ├── baseline.py        # Seasonal Naïve
│       ├── statistical.py      # ETS, Holt-Winters, SARIMA
│       └─ ml.py               # LightGBM, MLP, N-BEATS
│
├─ tests/
│   ├── test_backtesting.py     # 6 pruebas
│   └─ test_evaluation.py       # 14 pruebas
│
├─ results/
│   ├── tables/                # CSV con resultados (804 KB), incluye series_metadata.csv
│   └─ figures/                # Figuras generadas (356 KB)
```

└─	Memoria/	
└─	Fuente LaTeX/	# Fuente en LaTeX de la memoria
└─	Versiones y Entregas/	# Historial de entregas

8.2.DIAGRAMA DE ARQUITECTURA DEL PIPELINE

La Figura 7 presenta la arquitectura modular del *pipeline* desarrollado, mostrando el flujo de datos desde la carga del dataset hasta la generación de los resultados comparativos.

Figura 7. Diagrama de flujo del pipeline de pronóstico para FP&A. Se distinguen cuatro bloques funcionales: adquisición y preprocesamiento de datos, generación del protocolo walk-forward, ajuste e inferencia de los siete modelos, y evaluación con las seis métricas. El cuaderno orquestador coordina la ejecución integrada de todos los módulos.



[Nota: Los modelos locales (SNaive, ETS, HW, SARIMA) ajustan un modelo independiente por serie y fold. Los modelos globales (LightGBM, MLP, N-BEATS) entrenan un unico modelo por fold sobre todas las series. Ambos paradigmas se comparan bajo el mismo protocolo walk-forward y el mismo conjunto de metricas.]

Fuente: elaboración propia.

Los autores son los únicos propietarios del repositorio y únicos responsables del código fuente. Los datos utilizados son de acceso público (M4 Competition Dataset) y están disponibles en el repositorio oficial de la competición M4 (<https://github.com/Mcompetitions/M4-methods>).

Nota de confidencialidad: este TFE no está asociado a datos internos de ninguna organización. Los datos utilizados son exclusivamente los del conjunto M4, de acceso público.

8.3.REPRODUCIBILIDAD

Para reproducir el experimento completo:

El entorno de ejecución utilizado es Python 3.13.7 con las siguientes dependencias principales: numpy 2.3.5, pandas 2.3.2, statsmodels 0.14.6, statsforecast 2.0.3, lightgbm 4.6.0, torch 2.11.0. El archivo requirements.txt del repositorio fija todas las versiones para favorecer la reproducibilidad del experimento. El hardware de referencia es Windows 11, procesador Intel Core i7-1355U (10 núcleos físicos, 12 lógicos), 31,7 GB de RAM, sin aceleración GPU (valores exportados en entorno_hardware.csv); los tiempos de ajuste e inferencia, el tamaño serializado, la memoria pico y la utilización media y máxima de CPU se documentan en la Tabla 27. Esta versión del repositorio corresponde al commit 9012b28 (2026-07-22); al no emplear tags de versión formales, dicho commit hash constituye la referencia de trazabilidad de esta entrega. El repositorio incluye un archivo LICENSE.md en el que se especifican las condiciones de uso del código fuente. Este se comparte con fines de evaluación académica, revisión metodológica y trazabilidad de los resultados, sin que su disponibilidad implique la concesión de una licencia abierta. Los recursos de terceros conservan sus respectivas condiciones de uso.

1. Instalar las dependencias: `pip install -r requirements.txt`
2. Ejecutar: `python run_experiment.py --n-series 200 --max-folds 5`
3. Ejecutar la suite de pruebas automatizadas: `pytest tests/test_evaluation.py`
y `pytest tests/test_backtesting.py`

La ejecución de ambas suites concluye con 14/14 y 6/6 pruebas superadas (20/20 en total), verificado sobre el entorno de referencia descrito en este anexo. Esta evidencia puede reproducirse ejecutando los comandos anteriores tras la instalación de las dependencias.

Figura 8. Salida de la ejecución de la suite de pruebas automatizadas (pytest), 20/20 superadas

```
bash

$ python tests/test_evaluation.py
PASS test_empty_raises
PASS test_error_contribution
PASS test_length_mismatch_raises
PASS test_mae
PASS test_mape
PASS test_mape_excludes_zero_true
PASS test_mase_seasonality_one
PASS test_mase_seasonality_two
PASS test_nonfinite_raises
PASS test_perfect_forecast_is_zero
PASS test_rmse
PASS test_smape
PASS test_smape_handles_zero_pair
PASS test_wape
14/14 pruebas superadas.

$ python tests/test_backtesting.py
PASS test_detects_injected_leakage
PASS test_expanding_fold_count_and_geometry
PASS test_no_leakage_multiple_lengths
PASS test_rolling_keeps_fixed_window
PASS test_short_series_yields_no_fold
PASS test_test_window_is_always_future
6/6 pruebas superadas.

Total: 20/20 pruebas superadas
```

Fuente: elaboración propia.

4. Actualizar la memoria con los resultados: `python update_results_latex.py`

5. Medir los tiempos de ajuste e inferencia, el tamaño serializado, la memoria pico y la utilización de CPU de los siete modelos: `python benchmark_timing.py`

El módulo `src/Utils.py` fija las semillas de NumPy, PyTorch y el módulo `random` de la biblioteca estándar antes de cualquier operación aleatoria, lo que favorece la reproducibilidad y reduce la variabilidad entre ejecuciones, sujeta a las limitaciones de determinismo de las librerías (en particular operaciones en PyTorch) y del entorno de hardware y software utilizado.